Magíster en
Inteligencia Artificial

PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
ESCUELA DE INGENIERÍA

Sistema Inteligente de Monitoreo de Biodiversidad Aviar en Chile: Identificación Multimodal y Modelado de Distribución Espaciotemporal

PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
ESCUELA DE INGENIERÍA
DEPARTAMENTO DE CIENCIA DE LA COMPUTACIÓN

Sistema Inteligente de Monitoreo de Biodiversidad Aviar en Chile: Identificación Multimodal y Modelado de Distribución Espaciotemporal

Sebastián Vidal

Noviembre 2026

Informe de Actividad de Graduación para optar al Grado de
Magíster en Inteligencia Artificial.

Profesor Supervisor
Marcelo Mendoza

Tabla de contenido

Índice de figuras **xii**

Índice de tablas **xv**

Ficha del proyecto **xvi**

Resumen **xvii**

1. Introducción **1**

1.1. Motivación y contexto 1

1.2. Descripción general del problema 3

1.3. Contribuciones 4

1.3.1. Contribuciones en términos de precisión 5

1.3.2. Contribuciones en términos de eficacia 5

1.4. Estructura del trabajo 6

2. Trabajo relacionado **7**

2.1. Identificación de aves por audio (bioacústica computacional) 7

2.2. Identificación de aves por imagen y fusión multimodal 9

2.3. Modelos de distribución de especies (SDM) 11

2.4. Brecha de la literatura 13

3. Bases teóricas **15**

3.1. Preguntas de investigación, objetivo general y objetivos específicos 15

3.2. Clasificación supervisada con redes neuronales 16

3.2.1. El problema de clasificación y la salida softmax 17
3.2.2. Verosimilitud y entropía cruzada 17
3.2.3. Redes neuronales y su entrenamiento 18
3.3. Sobreajuste, regularización y aumentación de datos 19
3.4. Redes convolucionales y EfficientNet 20
3.4.1. La operación de convolución 20
3.4.2. Conexiones residuales 21
3.4.3. EfficientNet 21
3.5. *Transformers*: atención, ViT y AST 23
3.5.1. Atención 23
3.5.2. Vision Transformer y Audio Spectrogram Transformer 23
3.6. *Transfer learning* y *frozen embeddings* 24
3.7. Del audio al espectrograma log-mel 25
3.7.1. Señal, muestreo y transformada de Fourier 25
3.7.2. Escala mel, logaritmo y normalización 26
3.8. Protocolos de inferencia: ventanas, agregación y TTA 28
3.9. Fusión multimodal 29
3.10. Modelos de distribución de especies 31
3.10.1. Qué modela un modelo de distribución 31
3.10.2. Datos de solo presencia y pseudoausencias 31
3.10.3. MaxEnt y la regresión logística 33
3.10.4. Árboles de decisión, Random Forest y gradient boosting 33
3.10.5. Red neuronal conjunta multiespecie 35
3.11. Métricas de evaluación 36
3.11.1. Matriz de confusión, *accuracy* y F1 36

3.11.2. Curva ROC y AUC 37
3.11.3. Incertidumbre de las métricas 39
3.12. Autocorrelación espacial y validación por bloques 39
3.13. Metodología de trabajo, fuentes de datos y *baselines* 41
3.13.1. Metodología de trabajo 41
3.13.2. Fuentes de datos 41
3.13.3. Selección de *baselines* 42
3.14. Justificación técnica de la metodología 43
3.15. Efectos positivos esperados 44

4. Levantamiento de datos **46**
4.1. Repositorio reproducible y acceso a las fuentes 46
4.2. Conjunto de especies objetivo 46
4.3. Corpus de audio 48
4.3.1. Censo y disponibilidad 48
4.3.2. Descarga y composición del corpus 49
4.3.3. Preprocesamiento y particiones 50
4.4. Corpus de imagen 52
4.5. Avistamientos y covariables ambientales 52
4.5.1. Registros de presencia 52
4.5.2. Pseudoausencias y conjunto de datos del SDM 53
4.5.3. Covariables ambientales 54
4.6. Hallazgos del levantamiento y desviaciones del plan 56
4.6.1. Escasez de datos en las especies amenazadas 56
4.6.2. Desviaciones respecto del plan 57

5. Resultados **58**

5.1. Protocolo experimental 58

5.2. Identificación por audio 59

5.2.1. Modelos entrenados 59

5.2.2. Desempeño global 61

5.2.3. Desempeño por especie y por grupo de conservación 63

5.3. Identificación por imagen 66

5.4. Fusión multimodal 67

5.4.1. *Late fusion* frente a cada modalidad 67

5.4.2. Comparación de estrategias de fusión 70

5.5. *Baselines* de referencia 70

5.6. Modelo de distribución espaciotemporal 73

5.6.1. Modelos comparados 73

5.6.2. ¿Aportan los datos satelitales no estructurados? 76

5.6.3. Validación espacial por bloques 77

5.6.4. Mapas de distribución estimada 78

5.7. Prototipo integrado 81

5.8. Síntesis frente a los objetivos 81

6. Conclusiones, desafíos y trabajo futuro **83**

6.1. Respuesta a las preguntas de investigación 83

6.2. Discusión 84

6.3. Desafíos y limitaciones 85

6.4. Aspectos éticos 87

6.5. Lecciones aprendidas y recomendaciones 88

6.6. Trabajo futuro 89

6.7. Conclusión general 89

Referencias **91**

A. Conjunto de especies objetivo **100**

B. Hiperparámetros y detalles de entrenamiento **102**

C. Métricas por especie **107**

Índice de figuras

1.1. Arquitectura general del sistema: las fuentes de datos (azul) se preprocesan (blanco) y alimentan los modelos (amarillo), dos clasificadores de audio e imagen cuyas probabilidades se combinan por *late fusion*, y un modelo de distribución espaciotemporal comparado con MaxEnt; en verde, las salidas. El listado del RCE define las especies objetivo. 4

3.1. Elementos de una red convolucional: (a) un filtro de 3×3 recorre la entrada y produce el mapa de características (Ecuación 3.7); (b) arquitectura típica de clasificación, con bloques de convolución y *pooling* seguidos de *pooling* global, capa densa y softmax; (c) bloque residual (Ecuación 3.8). Elaboración propia a partir de Bishop y Bishop (2024) y He et al. (2016). 22

3.2. Arquitectura del *Audio Spectrogram Transformer*: el espectrograma se divide en parches de 16×16 con solapamiento, cada parche se proyecta linealmente y, con su embedding posicional y el token de clase, atraviesa el codificador *Transformer*; la salida del token de clase alimenta la capa de clasificación. Tomada de Gong et al. (2021). 24

3.3. Representación de entrada del clasificador de cantos para una ventana de 5 s de zorzal (*Turdus falcklandii*, XC954086): (a) forma de onda; (b) espectrograma de potencia; (c) diez de los 128 filtros del banco mel; (d) espectrograma log-mel de 128×501 que recibe la CNN; (e) SpecAugment y (f) *mixup* con una ventana de chincol, las dos aumentaciones de entrenamiento. 27

3.4. Pipeline de procesamiento de audio de la CNN, desde la grabación original hasta la predicción a nivel de grabación. El AST sigue el mismo esquema con ventanas de 10 s remuestreadas a 16 kHz y su propio banco de filtros. 28

3.5. Protocolos de inferencia. (a) Audio: la grabación se divide en ventanas de 5 s, cada una pasa por la CNN y las probabilidades se promedian (Ecuación 3.15); la *ventana única* usa solo la central (en amarillo). (b) Imagen: cinco recortes de 384×384 y sus volteos horizontales forman las diez vistas de la TTA; el *recorte central* usa una sola (en amarillo). Fotografía de chucao de pmarinaraya (iNaturalist, CC BY-NC 4.0). 29

3.6. Estrategias de fusión multimodal: *early fusion* (se concatenan las características extraídas de cada modalidad), *joint fusion*, que corresponde a la *intermediate fusion* de esta tesis (cada modalidad pasa por su propia red antes de concatenarse), y *late fusion* (cada modalidad predice por separado y las predicciones se agregan). Los subtipos I y II distinguen si las características de entrada son crudas o extraídas. Tomada de Huang et al. (2020), CC BY 4.0. 30

3.7. Presencias y pseudoausencias del modelo de distribución: (a) 500 registros de chucao (*Scelorchilus rubecula*); (b) fondo uniforme sobre Chile continental, descartado; (c) fondo de grupo objetivo, tomado de los avistamientos de las demás aves del conjunto, que reproduce la geografía del esfuerzo de observación y es el que usa la tesis. 32

3.8. Modelos de distribución basados en árboles y modelo lineal: (a) Random Forest promedia B árboles entrenados sobre muestras *bootstrap* (Ecuación 3.20); (b) gradient boosting suma árboles ajustados secuencialmente al pseudorresiduo (Ecuación 3.21); (c) MaxEnt como regresión logística penalizada sobre las *features* $h(\mathbf{c})$ (Ecuación 3.19). Esquemas propios a partir de Breiman (2001), Friedman (2001) y Elith et al. (2011). 34

3.9. Red neuronal conjunta multiespecie del modelo de distribución. Las seis covariables (azul) se concatenan con el *embedding* aprendido de la especie (amarillo) y atraviesan dos capas ocultas de 64 unidades hasta un logit cuya sigmoide es la probabilidad de presencia (Ecuación 3.22); todas las especies comparten las capas ocultas. 36

3.10. Curvas ROC de la CNN de audio (prueba, protocolo agregado) para tres especies con al menos seis grabaciones de prueba: una con AUC igual a uno (*Eugralla paradoxa*), la mediana (*Scytalopus fuscus*, 0,998) y la de menor AUC (*Anthus correndera*, 0,926). La diagonal es el clasificador al azar; el panel (b) amplía el recuadro de (a). 38

3.11. Partición espacial por bloques de 200 km usada para validar los modelos de distribución: muestra de 8 000 de los 34 926 puntos del conjunto del SDM, coloreados según el *fold* de su bloque (46 bloques repartidos al azar en cinco *folds* de tamaño equilibrado). Cada *fold* de prueba contiene bloques completos ausentes del entrenamiento. 40

3.12. Semivariograma esquemático: semivarianzas empíricas por clase de distancia y modelo esférico ajustado, con sus tres parámetros: efecto pepita (valor en el origen), meseta (valor estable) y rango (distancia a la que se alcanza la meseta), que aquí fija el tamaño de los bloques de validación. . 41

4.1. Construcción del conjunto de 55 especies objetivo: de las 147 aves clasificadas por el RCE se conservan las de distribución continental, luego las de interés de conservación y por último las que tienen datos suficientes; a esas 14 se suman 6 endémicas y 35 comunes. 47

4.2. Grabaciones de Xeno-canto con localidad en Chile por especie del conjunto objetivo, coloreadas por grupo. Entre paréntesis, la categoría del RCE cuando la especie ha sido evaluada. 49

4.3. Composición de los corpus por especie; las especies se ordenan por grupo de conservación (franja de color) y número de grabaciones. Izquierda: grabaciones de audio del corpus de entrenamiento según su origen. Derecha: fotografías con grado de investigación de iNaturalist. Las dos especies con menos de 15 fotografías no participan del clasificador de imagen. 51

4.4. Registros de presencia obtenidos de GBIF (eBird e iNaturalist) para las 55 especies. Arriba: densidad espacial en celdas de 0,5° para todos los registros, para el verano y para el invierno austral. Abajo: distribución por año y por mes. 54

4.5. Covariables ambientales sobre la grilla de 0,1° de Chile continental: NDVI, temperatura media anual, precipitación anual (escala truncada en 3000 mm) y elevación. 55

5.1. Pérdida de entrenamiento y de validación de la CNN de audio sin regularización y con la regularización completa. Sin regularización la red memoriza el conjunto de entrenamiento y la pérdida de validación deja de bajar; con regularización ambas curvas se mantienen cercanas. 60

5.2. Curvas de entrenamiento de los tres clasificadores unimodales del sistema (CNN y AST de audio, EfficientNet-B3 de imagen): *accuracy* y F1 macro en validación (arriba) y pérdida de entrenamiento (abajo). La línea vertical marca la época del mejor *checkpoint*, que es el evaluado en prueba. 61

5.3. *Accuracy* en prueba de los clasificadores de audio con ventana única y con agregación por grabación. 62

5.4. Matriz de confusión de la CNN de audio (conjunto de prueba, agregado por grabación) restringida a las especies con *recall* inferior a 0,8 y a las especies con que se confunden; el color indica la fracción de la fila y el número, las grabaciones. Los errores están dispersos: ningún par de especies acumula más de tres casos. 64

5.5. F1 por especie en el conjunto de prueba del clasificador de audio (CNN, agregado por grabación) y del clasificador de imagen (EfficientNet-B3 con TTA), coloreado por grupo de conservación y ordenado por el F1 de audio. Las dos especies sin fotografías suficientes no participan del clasificador de imagen. 65

5.6. Fusión multimodal evaluada con pareo por especie (1590 pares, 53 especies). Izquierda: la *late fusion* frente a cada modalidad sobre los mismos pares (media de 20 repeticiones; las barras de error, apenas visibles, son la desviación estándar). Derecha: comparación controlada de tres estrategias de fusión con cabezas entrenadas sobre los *frozen embeddings* de ambos modelos. 68

5.7. Sensibilidad de la *late fusion* al peso del audio α (media aritmética de probabilidades), con la CNN o el AST como rama de audio; banda: desviación estándar sobre 20 repeticiones del pareo. 69

5.8. F1 medio por grupo de conservación del modelo generativo en *zero-shot* y *few-shot*, frente al clasificador de imagen ajustado. La fotografía de referencia mejora sobre todo a las endémicas, sin cerrar la brecha con el modelo propio. 73

5.9. AUC-ROC medio de los modelos de distribución sobre las 54 especies modeladas. La línea punteada marca el *baseline* MaxEnt. 74

5.10. AUC-ROC por especie de MaxEnt y Random Forest (partición aleatoria), ordenadas por el valor de Random Forest; la franja de color indica el grupo de conservación. 75

5.11. Experimentos con información satelital. Izquierda: AUC-ROC medio al agregar el *embedding* satelital o parches de cobertura de suelo a las covariables base. Derecha: pareo temporal del *embedding* satelital al año de cada observación, sobre el subconjunto 2017–2025 (53 especies). . . . 76

5.12. Probabilidad de presencia en enero estimada por Random Forest para tres especies de distribución contrastante, con una muestra de sus avistamientos superpuesta. 79

5.13. Eje temporal del modelo: probabilidad de presencia estimada para *Limosa haemastica* en enero y en julio. 80

Índice de tablas

2.1. Desempeño de BirdNET por región en la evaluación mundial de Funosas et al. (2026): área bajo la curva precisión–*recall* (AUC-PR) por continente; el *recall* varía entre 0,24 y 0,52 según el continente. 8

2.2. Comparación del trabajo relacionado y posicionamiento de esta propuesta. 13

3.1. Fuentes de datos integradas en el proyecto. El plan original contemplaba ERA5 (Hersbach et al., 2020) y Sentinel-2 (Drusch et al., 2012); su reemplazo se explica en el Capítulo 4. 42

3.2. *Baselines* del proyecto, por tarea y por dimensión de comparación. 43

4.1. Categorías de conservación del RCE que aparecen en este trabajo y número de especies del conjunto objetivo en cada una. 47

4.2. Grabaciones de Xeno-canto con localidad en Chile por grupo de especies del conjunto objetivo. 48

4.3. Corpus de audio descargado y preprocesado. 50

4.4. Covariables del modelo de distribución. 56

4.5. Desviaciones entre lo planificado y lo implementado. 57

5.1. Efecto de la regularización en la CNN de audio: misma arquitectura, datos, épocas y optimizador, con y sin aumentación, *mixup*, suavizado de etiquetas, *dropout* y profundidad estocástica; ambas corridas conservan el decaimiento de pesos y la selección del mejor *checkpoint* en validación. Pérdidas al final de las 100 épocas; *accuracy* en prueba. 60

5.2. Clasificadores de audio en el conjunto de prueba (393 grabaciones, 55 especies). El protocolo agregado promedia las probabilidades de hasta 12 ventanas (CNN) u 8 (AST) de la grabación. 62

5.3. Métricas extendidas de los clasificadores unimodales (solo audio o solo imagen) en el conjunto de prueba (protocolo operacional). AUC-ROC macro (cada especie frente a las demás); top-5: la especie correcta está entre las cinco más probables; latencia mediana por muestra en Apple M4 Pro (MPS), incluido el cálculo de características. 63

5.4. Desempeño por grupo de conservación. F1 medio por especie en el conjunto de prueba (audio: CNN, agregado por grabación; imagen: EfficientNet-B3 con TTA; fusión: pareo por especie) y AUC-ROC medio del SDM. 66

5.5. Clasificadores de imagen en el conjunto de prueba (1040 fotografías, 53 especies). 67

5.6. *Late fusion* evaluada con pareo por especie repetido: media y desviación estándar sobre 20 repeticiones de 1590 pares (53 especies), para las dos ramas de audio disponibles. 68

5.7. *Baselines* de referencia frente a los modelos ajustados (conjuntos de prueba). *Frozen embeddings*: regresión logística sobre las representaciones de un modelo preentrenado sin ajustar. IA generativa: modelo de IA generativa multimodal consultado con la fotografía y la lista cerrada de especies. 71

5.8. Modelos de distribución comparados: AUC-ROC medio sobre las 54 especies con al menos 20 presencias y número de especies en que cada modelo supera a MaxEnt. Partición aleatoria estratificada 70/30 y validación cruzada espacial por bloques de 200 km (5 *folds*). 74

5.9. Comparaciones pareadas por especie entre modelos de distribución: diferencia media de AUC-ROC con intervalo *bootstrap* al 95 %, número de especies en que el primer modelo supera al segundo y valor *p* del test de Wilcoxon de rangos con signo (bilateral). 78

5.10. Intervalos de confianza al 95 % de las métricas principales de identificación. *Bootstrap* percentil con 2000 remuestreos de las muestras de prueba (fusión: 300 remuestreos estratificados por especie de grabaciones y fotografías, con el pareo recalculado); los *baselines* de *frozen embeddings* usan el intervalo normal de una proporción. 81

5.11. Cumplimiento de los objetivos específicos. 82

5.12. Costo computacional de los modelos en Apple M4 Pro (MPS). El ViT-S/16 se entrenó solo como comparación. 82

A.1. Conjunto objetivo de 55 especies y disponibilidad de datos. 100

B.1. Clasificadores de audio. 103

B.2. Clasificador de imagen y cabezas de fusión. 104

B.3. Modelos de distribución de especies. 105

B.4. *Baselines* de referencia de la identificación de especies. 106

C.1. Métricas por especie en los conjuntos de prueba: F1 del clasificador de audio (CNN EfficientNet-B0 y AST, agregado por grabación), F1 del clasificador de imagen (EfficientNet-B3 con TTA) y AUC-ROC del modelo de distribución (MaxEnt y Random Forest, partición aleatoria). "–" indica que la especie no participa de ese modelo. 107

Ficha del proyecto

FICHA DEL PROYECTO

Título
Sistema Inteligente de Monitoreo de Biodiversidad Aviar en Chile: Identificación Multimodal y Modelado de Distribución Espaciotemporal.

Autor
Sebastián Vidal — svidals@estudiante.uc.cl

Profesor Supervisor
Marcelo Mendoza

Temáticas (palabras clave)
Aprendizaje profundo; bioacústica; clasificación multimodal; visión por computador; modelos de distribución de especies; monitoreo de biodiversidad.

Resumen

Chile alberga 528 especies de aves nativas, 12 de ellas endémicas, y 71 de las 147 clasificadas por el Reglamento de Clasificación de Especies están amenazadas (Ministerio del Medio Ambiente, 2026). Su monitoreo depende de especialistas y de trabajo de campo costoso, mientras la ciencia ciudadana y los satélites acumulan datos que apenas se aprovechan. Este trabajo desarrolla y evalúa un sistema de aprendizaje profundo que identifica especies de aves chilenas a partir de audio y/o imagen mediante fusión multimodal, y que modela su distribución espaciotemporal a partir de avistamientos, clima e índices de vegetación.

Se integraron en un repositorio reproducible grabaciones de Xeno-canto (2508), fotografías de iNaturalist vía GBIF (7060), 100.270 avistamientos de eBird e iNaturalist y covariables ambientales de Google Earth Engine, para 55 especies de Chile continental con foco en las amenazadas y endémicas. En audio se ajustan una CNN (EfficientNet-B0) y el *Audio Spectrogram Transformer* sobre espectrogramas log-mel; en imagen, EfficientNet-B3 con aumentación en tiempo de prueba. Ambas ramas se combinan por *late fusion* y se contrastan con clasificadores unimodales, con *frozen embeddings* y con un modelo de IA generativa multimodal. En distribución se comparan MaxEnt, Random Forest, gradient boosting y una red neuronal multiespecie, con partición aleatoria y validación espacial por bloques.

La fusión identifica 53 especies con 0,945 de *accuracy* (intervalo de confianza al 95 % de 0,924 a 0,959), por sobre el audio solo (0,865), la imagen sola (0,816), el modelo generativo (0,817) y la meta del 85 %. Random Forest supera a MaxEnt en AUC-ROC con partición aleatoria (0,884 frente a 0,863, $p < 0{,}001$), pero bajo validación espacial todos los modelos convergen a 0,80–0,82; la red neuronal no supera a MaxEnt y los *embeddings* satelitales no aportan.

El sistema cumple sus objetivos y deja tres aportes: la evidencia de que la fusión audio-imagen con datos no emparejados de ciencia ciudadana supera a cada modalidad; un resultado negativo bien fundamentado sobre el aprendizaje profundo en modelos de distribución tabulares; y un repositorio reproducible con un prototipo integrado, extensible a otras especies y regiones.

1 Introducción

1.1 Motivación y contexto

La biodiversidad sostiene los procesos que hacen posible la vida humana: regula el clima, mantiene el equilibrio de los ecosistemas y sustenta las actividades productivas. La pérdida de diversidad biológica reduce la productividad y la estabilidad de los ecosistemas y compromete los servicios que estos proveen a la sociedad. A escala global, la Plataforma Intergubernamental sobre Biodiversidad y Servicios Ecosistémicos estima que cerca de un millón de especies se encuentran en riesgo de extinción como consecuencia de actividades humanas, con tasas de declive sin precedentes en la historia reciente (IPBES, 2019).

Chile no es ajeno a esta crisis. El listado oficial del Reglamento de Clasificación de Especies (RCE), actualizado a marzo de 2026 tras su vigésimo proceso, registra 1591 especies clasificadas, de las cuales 208 se encuentran En Peligro Crítico, 446 En Peligro y 340 Vulnerables. A ellas se suman 20 especies Extintas o Extintas en Estado Silvestre (Ministerio del Medio Ambiente, 2026). El 62,5 % de las especies clasificadas está en alguna categoría de amenaza, proporción que ya superaba el 60 % en el Reporte del Estado del Medio Ambiente de 2021 (Ministerio del Medio Ambiente, 2021). Es una señal de alerta para la conservación del patrimonio natural. La zona central del país forma parte del *hotspot* de biodiversidad "Chile central" (bosques lluviosos invernales y valdivianos), una de las 25 regiones del planeta con mayor concentración de especies endémicas y mayor pérdida de hábitat, que conserva solo alrededor del 30 % de su vegetación original (Myers et al., 2000).

Las aves son sensibles a los cambios del hábitat, tienen amplia distribución y son relativamente fáciles de detectar. Por eso se utilizan como bioindicadores del estado de los ecosistemas: la mayoría de los índices de biodiversidad con que se evalúa el cumplimiento de acuerdos internacionales se construye sobre datos de aves (Fraixedas et al., 2020). En Chile, la Estrategia Nacional de Conservación de Aves las define como "especies centinelas" cuya presencia se relaciona con ecosistemas más diversos, aguas no contaminadas y baja presencia de especies exóticas invasoras (Ministerio del Medio Ambiente, 2022). El mismo instrumento reconoce que el monitoreo de aves a escala nacional es caro en dinero y en

tiempo, que depende de especialistas y que la escasez de financiamiento es, según los ornitólogos del país, la principal barrera al avance de la disciplina.

El caso de las aves ilustra la magnitud del problema. Chile alberga 528 especies de aves nativas, el 5 % de las aves del mundo, de las cuales 322 se reproducen en el país. Doce son endémicas: nueve del territorio continental y tres del archipiélago de Juan Fernández (Barros et al., 2015; Ministerio del Medio Ambiente, 2022). Según la misma Estrategia, hasta el proceso 17 del RCE se había evaluado el estado de conservación de 114 especies y tres subespecies de aves. De ellas, 59 resultaron amenazadas (En Peligro Crítico, En Peligro o Vulnerable), 25 Casi Amenazadas y dos con Datos Insuficientes. Los procesos posteriores han seguido incorporando aves: el listado oficial vigente incluye 147 especies de aves clasificadas por el RCE, de las cuales 7 se encuentran En Peligro Crítico, 31 En Peligro y 33 Vulnerables, es decir, 71 especies amenazadas (48 %), además de 32 Casi Amenazadas (Ministerio del Medio Ambiente, 2026). Detectar oportunamente cambios en estas poblaciones exige herramientas de monitoreo más eficientes y de mayor cobertura espacial y temporal.

Paralelamente, existe un volumen creciente de datos de ciencia ciudadana y de sensores remotos que permanece en gran parte subutilizado para el monitoreo automático. eBird, el mayor proyecto de ciencia ciudadana del mundo, superó en 2025 los dos mil millones de observaciones de aves, aportadas por 1,1 millones de observadores en 253 países (Sullivan et al., 2014; Cornell Lab of Ornithology, 2025). Xeno-canto reúne más de 750.000 grabaciones de cantos de más de 10.000 especies (Vellinga y Planqué, 2015; Hamer et al., 2023). iNaturalist y GBIF concentran millones de fotografías geolocalizadas (Van Horn et al., 2018). Misiones satelitales como Sentinel-2 entregan imágenes multiespectrales de 10 m de resolución con revisita de pocos días (Drusch et al., 2012). En Chile esta información ya ha demostrado su valor. El Atlas de las Aves Nidificantes de Chile se construyó a partir de más de 675.000 registros de eBird aportados por 1815 personas (Medrano et al., 2018). La propia Estrategia Nacional identifica a la ciencia ciudadana como una herramienta central para un futuro sistema nacional de monitoreo. Este trabajo busca aprovechar esa información con aprendizaje profundo e integrar varias modalidades en un sistema único de apoyo a la conservación de la avifauna chilena.

1.2 Descripción general del problema

El sistema aborda dos problemas complementarios, ilustrados en la Figura 1.1. El primero es la **identificación multimodal de especies**: dada una grabación de canto y/o una fotografía, determinar automáticamente la especie de ave correspondiente entre un conjunto cerrado de especies chilenas. Se trata de un problema de clasificación *fine-grained* ("de grano fino"): a diferencia de distinguir categorías muy distintas entre sí, como un ave de un automóvil, aquí todas las clases son subcategorías de una misma familia, aves, que comparten la estructura general y se diferencian por detalles sutiles del plumaje, la silueta o el canto (Wei et al., 2022). El segundo es el **modelado de la distribución espaciotemporal**: estimar la probabilidad de presencia de una especie en función de la ubicación geográfica, la época del año y variables ambientales, a partir de registros de solo presencia provenientes de ciencia ciudadana (Elith y Leathwick, 2009).

Ambos problemas se abordan con aprendizaje automático. Para la identificación, el audio se representa como espectrogramas mel procesados por redes convolucionales y/o por el *Audio Spectrogram Transformer*. Las imágenes se procesan mediante *transfer learning* con arquitecturas como EfficientNet y/o ViT. Las predicciones de ambas modalidades se combinan por *late fusion*, es decir, ponderando las probabilidades que entrega cada clasificador, lo que permite operar también cuando solo una modalidad está disponible. Otras estrategias de fusión (*early* e *intermediate fusion*) se evalúan para comparar metodologías. Para la distribución, se entrenan modelos de distribución de especies (SDM) basados en redes neuronales y en Random Forest que integran registros de avistamientos de eBird e iNaturalist (vía GBIF) con covariables climáticas, índices de vegetación satelitales y elevación calculados en Google Earth Engine. Estos modelos se comparan con MaxEnt (Phillips et al., 2006), el método de referencia en ecología.

Tres preguntas guían el trabajo: si un sistema multimodal identifica mejor que los clasificadores de una sola modalidad y que un modelo de IA generativa, si un modelo de distribución basado en aprendizaje automático supera a MaxEnt, y cómo afecta la escasez de datos a las especies amenazadas. Se formalizan, junto con los objetivos, en la Sección 3.1.

El alcance se limita a Chile continental, con foco en especies endémicas y en estado de conservación Vulnerable, En Peligro o En Peligro Crítico según el RCE del Ministerio del Medio Ambiente. Se excluyen las islas oceánicas (Juan Fernández, Rapa Nui,

Desventuradas) por su avifauna diferenciada y por la escasez de registros disponibles.

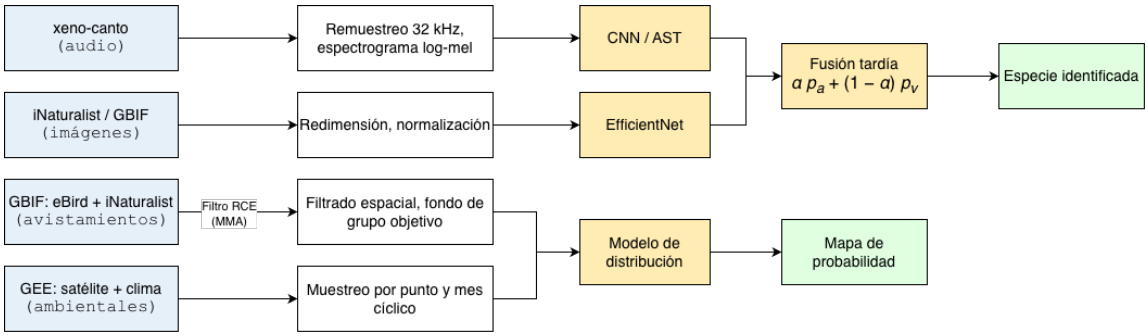


Figura 1.1: Arquitectura general del sistema: las fuentes de datos (azul) se preprocesan (blanco) y alimentan los modelos (amarillo), dos clasificadores de audio e imagen cuyas probabilidades se combinan por *late fusion*, y un modelo de distribución espaciotemporal comparado con MaxEnt; en verde, las salidas. El listado del RCE define las especies objetivo.

1.3 Contribuciones

Los enfoques previos para la identificación de aves suelen abordar una sola modalidad. En audio, BirdNET (Kahl et al., 2021) es hoy la herramienta más difundida, pero una evaluación global reciente muestra que su capacidad predictiva es máxima en Norteamérica, Oceanía y Europa y solo moderada en Centro y Sudamérica, con *recall* que oscila entre 0,24 y 0,52 según el continente, lo que refleja diferencias en la cobertura de especies de sus datos de entrenamiento (Funosas et al., 2026). En imagen, los clasificadores *fine-grained* se han desarrollado sobre conjuntos como CUB-200-2011 (Wah et al., 2011) e iNaturalist, dominados por avifaunas del hemisferio norte. La combinación de audio e imagen para aves ha sido explorada solo recientemente y con especies norteamericanas (Van Horn et al., 2022). En el modelado de distribución, MaxEnt sigue siendo el método de referencia en ecología y uno de los de mejor desempeño con datos de solo presencia (Elith et al., 2011; Valavi et al., 2022), mientras que los SDM basados en aprendizaje profundo son un área emergente (Deneu et al., 2021; Cole et al., 2023). No se identificó en la literatura un sistema integrado que combine identificación multimodal y modelado de distribución para la avifauna chilena.

Las principales contribuciones de este trabajo son:

1. Un **clasificador multimodal** de 55 especies de aves chilenas (53 en ambas modalidades), con *late fusion* de audio e imagen, evaluado frente a clasificadores de una sola modalidad

(solo audio o solo imagen), a clasificadores sobre *frozen embeddings* y a un modelo de IA generativa multimodal.

2. Un **modelo de distribución espaciotemporal** que integra avistamientos, clima, índices de vegetación y elevación, comparado con MaxEnt mediante redes neuronales, Random Forest y gradient boosting, con partición aleatoria y validación cruzada espacial, incluida una evaluación del aporte de los parches de cobertura de suelo y los *embeddings* de imágenes satelitales.
3. Un **repositorio reproducible** que integra fuentes de datos heterogéneas, con un pipeline documentado y reanudable de descarga, normalización, partición, entrenamiento y evaluación, y un prototipo que integra los modelos, reutilizable para otras especies o regiones.
4. Una **caracterización cuantitativa de la escasez de datos** de audio, imagen y avistamientos para las especies amenazadas de Chile, hallazgo que condiciona el diseño de cualquier sistema de monitoreo orientado a la conservación, junto con la evidencia de qué estrategias la mitigan en cada modalidad.

1.3.1 Contribuciones en términos de precisión

1. El clasificador multimodal supera a los clasificadores de una sola modalidad y a un modelo de IA generativa multimodal, y alcanza 0,945 de *accuracy* sobre 53 especies, por sobre la meta del 85 %, en línea con lo observado en el *benchmark* audiovisual SSW60, donde la fusión de modalidades supera a cada modalidad por separado. Las ramas de audio (0,858 y 0,870) e imagen (0,848) cumplen o rozan la meta por sí solas.
2. El modelo de distribución basado en Random Forest supera a MaxEnt en AUC-ROC con partición aleatoria (0,884 frente a 0,863), pero no al extrapolar a bloques espaciales no vistos, donde todos los modelos empatan. La red neuronal propuesta inicialmente no lo supera en ningún protocolo, un resultado negativo que se documenta con evidencia y que matiza la expectativa de la literatura sobre SDM profundos.

1.3.2 Contribuciones en términos de eficacia

1. El sistema automatiza la identificación y el monitoreo, reduce la dependencia de inspección experta en terreno y permite procesar grandes volúmenes de registros que hoy no pueden revisarse manualmente.

2. El uso exclusivo de fuentes públicas y de cómputo en la nube (Google Earth Engine para el muestreo de las covariables ambientales) elimina el costo de adquisición de datos y evita la descarga y el almacenamiento local de imágenes satelitales.
3. Los modelos de distribución permiten priorizar zonas de monitoreo y apoyar la planificación territorial para la conservación, en línea con las acciones de investigación y monitoreo que promueve la Estrategia Nacional de Conservación de Aves.

1.4 Estructura del trabajo

El resto del documento se organiza como sigue. El Capítulo 2 revisa el trabajo relacionado en tres áreas, avanzando desde lo general a lo específico: identificación bioacústica con aprendizaje profundo, clasificación de aves por imagen (incluida la fusión multimodal) y modelos de distribución de especies. El capítulo cierra con una tabla comparativa y la identificación de la brecha de la literatura. El Capítulo 3 presenta las bases teóricas: la pregunta de investigación con el objetivo general y los objetivos específicos, la formalización matemática de los problemas de clasificación, *late fusion* y distribución, las herramientas, metodologías y métricas seleccionadas, sus virtudes en el contexto del problema y los efectos positivos esperados. El Capítulo 4 documenta el levantamiento de datos: la construcción de los corpus de audio, imagen y avistamientos con sus covariables, los hallazgos derivados de la escasez de datos en especies amenazadas y las desviaciones respecto del plan. El Capítulo 5 presenta los resultados de los clasificadores de audio e imagen, de la fusión multimodal, de los *baselines* de referencia y del modelo de distribución frente a MaxEnt, junto con el prototipo integrado y el costo computacional. El Capítulo 6 responde las preguntas de investigación, discute los hallazgos, declara las limitaciones y los aspectos éticos, recoge las lecciones aprendidas y propone el trabajo futuro.

2 Trabajo relacionado

Este capítulo revisa el estado del arte en las áreas que sustentan el proyecto, avanzando desde lo general a lo específico, e identifica la brecha de la literatura que ofrece la oportunidad de investigación. La revisión se organiza en tres subáreas: identificación de aves por audio (bioacústica computacional), identificación por imagen (incluida la fusión multimodal) y modelos de distribución de especies (SDM). Cada sección describe brevemente la técnica, revisa los trabajos más influyentes y destaca los aspectos que condicionan el diseño de esta propuesta. El capítulo cierra con una tabla comparativa (Tabla 2.2) y la formulación explícita de la brecha.

2.1 Identificación de aves por audio (bioacústica computacional)

La bioacústica computacional estudia la detección y clasificación automática de sonidos animales a partir de grabaciones. Su desarrollo con aprendizaje profundo ha seguido de cerca al de la clasificación general de audio: la señal se transforma en una representación tiempo–frecuencia (habitualmente un espectrograma en escala mel, Sección 3.7), que se procesa como una imagen mediante redes convolucionales (CNN, Sección 3.4) o, más recientemente, mediante *transformers* de audio (Sección 3.5).

Representaciones de entrada

El espectrograma mel comprime el eje de frecuencia según una escala perceptual y expresa la energía en escala logarítmica, lo que concentra la información relevante para vocalizaciones animales y permite reutilizar arquitecturas de visión por computador. En este proyecto se adopta el espectrograma log-mel como representación principal por su compatibilidad con los modelos preentrenados que se describen a continuación.

Preentrenamiento a gran escala y modelos de referencia

La disponibilidad de AudioSet, un catálogo de más de dos millones de clips de audio anotados con 527 clases de sonidos (Gemmeke et al., 2017), permitió demostrar que las arquitecturas CNN diseñadas para imágenes se transfieren de forma efectiva a la clasificación

de audio. Sobre esta base se construyeron familias de modelos de audio preentrenados. Posteriormente, el *Audio Spectrogram Transformer* (AST) aplicó directamente un *Vision Transformer* a parches del espectrograma y alcanzó el estado del arte en AudioSet (Gong et al., 2021). Su arquitectura se describe en la Sección 3.5. Estos modelos son candidatos naturales para la identificación bioacústica de especies, dado que sus representaciones internas codifican patrones espectrotemporales genéricos que pueden especializarse con relativamente pocos datos.

En el dominio específico de las aves, BirdNET es el modelo más difundido: una red convolucional profunda con conexiones residuales (Sección 3.4) entrenada sobre espectrogramas de Xeno-canto y otras colecciones, que en su versión original reconocía 984 especies de Norteamérica y Europa en grabaciones de campo (Kahl et al., 2021). Las versiones posteriores superan las 6000 especies. Su adopción en monitoreo acústico pasivo es masiva, pero su desempeño varía fuertemente entre especies y contextos, por lo que debe validarse localmente antes de usarse para inferencia ecológica. La primera evaluación mundial de BirdNET, con 4224 grabaciones de 67 sitios en todos los continentes anotadas por expertos locales, confirmó esta heterogeneidad (Tabla 2.1): el desempeño es máximo en los continentes de donde provienen la mayoría de sus datos de entrenamiento y cae en Sudamérica (Funosas et al., 2026). Estos resultados justifican entrenar o adaptar modelos específicos para la avifauna chilena en lugar de depender de un clasificador global.

Tabla 2.1: Desempeño de BirdNET por región en la evaluación mundial de Funosas et al. (2026): área bajo la curva precisión–*recall* (AUC-PR) por continente; el *recall* varía entre 0,24 y 0,52 según el continente.

Región	AUC-PR	Cobertura en los datos de entrenamiento
Norteamérica, Oceanía y Europa	0,16–0,23	alta
Centro y Sudamérica	0,13	moderada
África y Asia	inferior a 0,13	baja

Embeddings bioacústicos transferibles

Una línea reciente muestra que los clasificadores de aves a gran escala producen *embeddings* que se transfieren mejor a nuevas tareas bioacústicas que los de modelos de audio general: entrenando clasificadores lineales sobre las representaciones de BirdNET y de Perch (un modelo de Google entrenado en Xeno-canto), Ghani *et al.* obtuvieron desempeño

superior a AudioMAE y otros modelos generativos en tareas de aves, anfibios, mamíferos marinos e insectos, incluso en régimen de pocos ejemplos por clase (Ghani et al., 2023). El *benchmark* BIRB formaliza esta evaluación como un problema de recuperación de información con desplazamiento de distribución entre grabaciones focales y paisajes sonoros (Hamer et al., 2023). Esta evidencia importa para las especies con pocas grabaciones, como las amenazadas de Chile, y justifica considerar el *fine-tuning* de modelos preentrenados en aves como estrategia complementaria al AST.

Evaluación en condiciones de campo y *benchmarks*

Los desafíos anuales BirdCLEF son el *benchmark* de referencia: sus ediciones recientes plantean la identificación de especies en paisajes sonoros continuos de regiones con pocos datos (por ejemplo, África oriental en 2023), donde los participantes deben lidiar con etiquetas débiles, solapamiento de vocalizaciones y desplazamiento de dominio entre las grabaciones focales de Xeno-canto usadas para entrenar y los paisajes sonoros de prueba (Kahl et al., 2023). Las soluciones ganadoras combinan CNN preentrenadas, aumentación de datos y ensamblado de modelos. Xeno-canto, la fuente principal de estos desafíos y de este proyecto, es una colección de ciencia ciudadana con anotación débil (una especie focal por grabación, con posibles especies de fondo), duración muy variable y fuerte desbalance entre especies (Vellinga y Planqué, 2015).

Desbalance y clases con pocos ejemplos

El desbalance de clases es inherente a los datos bioacústicos: las especies comunes acumulan miles de grabaciones y las raras apenas decenas. Entre las estrategias establecidas está la aumentación en el dominio del espectrograma, como SpecAugment, que enmascara bandas de tiempo y frecuencia (Park et al., 2019). Otra es la interpolación de ejemplos mediante *mixup* (Zhang et al., 2018). Una tercera son las funciones de pérdida que reponderan las clases, como la pérdida focal (Lin et al., 2017) o la pérdida balanceada por número efectivo de muestras (Cui et al., 2019). Estas técnicas conectan directamente con el hallazgo de escasez de audio en especies amenazadas que se reporta en el Capítulo 4.

2.2 Identificación de aves por imagen y fusión multimodal

Clasificación *fine-grained*

La identificación de aves por fotografía es el caso paradigmático de la clasificación visual *fine-grained*: distinguir subcategorías de una misma clase de objetos (especies dentro del grupo "aves") que comparten la estructura global y difieren en detalles locales, como la forma del pico o los patrones del plumaje, con alta variabilidad dentro de cada clase por pose, iluminación y fondo. El conjunto CUB-200-2011, con 11.788 imágenes de 200 especies norteamericanas, ha sido durante más de una década el *benchmark* de referencia. iNaturalist 2017, con más de 850.000 imágenes de 5089 especies y datos fuertemente desbalanceados entre clases, acercó el problema a las condiciones reales de los datos de ciencia ciudadana (Van Horn et al., 2018). En ambos, el *transfer learning* desde modelos preentrenados en ImageNet es la práctica estándar. Las arquitecturas residuales establecieron la base. EfficientNet introdujo el escalado compuesto de profundidad, ancho y resolución, con mejor precisión y menos parámetros (Tan y Le, 2019). El *Vision Transformer* mostró que un *transformer* aplicado a parches de imagen supera a las CNN cuando se preentrena a gran escala (Dosovitskiy et al., 2021). Las bases de estas arquitecturas se presentan en el Capítulo 3.

Estrategias de fusión multimodal

El aprendizaje multimodal busca representar y combinar información de distintas modalidades. Según el momento en que ocurre esa combinación, Baltrušaitis et al. (2019) distinguen tres estrategias: *early*, *intermediate* y *late fusion*. La primera concatena las características de entrada y entrena un único clasificador. La segunda hace interactuar las representaciones latentes de cada rama antes de decidir. La tercera entrena un clasificador por modalidad y combina sus probabilidades. Esta última es robusta cuando falta una modalidad en inferencia, porque basta usar la predicción del clasificador disponible, permite entrenar cada rama con datos no emparejados y es simple de calibrar. Su limitación es que no modela interacciones de bajo nivel entre las señales de entrada. Las tres se formalizan en la Sección 3.9 y se comparan empíricamente en el Capítulo 5.

Fusión audio–imagen en fauna

La literatura que combina audio e imagen para identificación de animales es reciente y limitada. El *benchmark* SSW60 (Sapsucker Woods 60), de Cornell, es el primer conjunto

que permite clasificar las mismas 60 especies de aves en imagen, audio y video. Sus autores muestran que la fusión audiovisual supera a cada modalidad por separado y que el conocimiento se transfiere entre modalidades (Van Horn et al., 2022). Pero sus especies son norteamericanas y sus datos audiovisuales provienen de video emparejado. No se identificaron trabajos que combinen audio e imagen para avifauna sudamericana ni que lo hagan a partir de fuentes no emparejadas (Xeno-canto e iNaturalist), como propone este proyecto.

2.3 Modelos de distribución de especies (SDM)

Los SDM relacionan registros de ocurrencia de una especie con variables ambientales para estimar su distribución potencial en el espacio y, eventualmente, en el tiempo. Constituyen una herramienta central de la ecología y la planificación de la conservación.

MaxEnt y el problema de solo presencia

La mayoría de los datos disponibles, incluidos los de ciencia ciudadana, son de solo presencia: registran dónde se observó una especie, pero no dónde se buscó sin éxito. MaxEnt aborda este problema con una idea simple: entre todas las formas de repartir la probabilidad de presencia sobre el territorio, elige la más "neutra" posible (la de máxima entropía) que sea compatible con lo observado, es decir, con que las condiciones ambientales promedio de los sitios donde se vio la especie coincidan con las del modelo. El resultado es una probabilidad de presencia que crece de forma exponencial con una combinación de las covariables, formalmente equivalente a una regresión logística o de Poisson regularizada (Phillips et al., 2006). La Sección 3.10 presenta sus ecuaciones. Un *benchmark* reciente con código reproducible confirma que MaxEnt bien configurado sigue estando entre los métodos de mejor desempeño para datos de solo presencia, junto con *boosted regression trees* y ensambles (Valavi et al., 2022), lo que lo convierte en un *baseline* exigente y no trivial.

Sesgo de muestreo y pseudoausencias

Como los datos solo dicen dónde se vio a la especie, el modelo necesita puntos de contraste, las *pseudoausencias* o puntos de fondo, que representan los lugares donde la especie podría no estar. Si esos puntos se reparten al azar por el territorio aparece un problema: los registros

de ciencia ciudadana se concentran en zonas accesibles y pobladas, de modo que el modelo aprende dónde hay observadores en lugar de dónde hay hábitat adecuado. La solución más usada es elegir los puntos de fondo con el mismo sesgo que las presencias, por ejemplo, a partir de registros de otras especies del mismo grupo, lo que mejora sustancialmente las predicciones (Phillips et al., 2009). La Figura 3.7 del Capítulo 3 ilustra la diferencia. El número y la ubicación de las pseudoausencias también influyen en el desempeño, y para eBird existen guías que recomiendan filtrar por protocolo y esfuerzo y submuestrear espacialmente (Johnston et al., 2021).

SDM con aprendizaje profundo

Los SDM neuronales reemplazan las funciones de respuesta paramétricas de la regresión (una curva fija por covariable) por redes que aprenden interacciones no lineales entre covariables y que pueden compartir representaciones entre muchas especies, como se formaliza en la Sección 3.10. Botella *et al.* propusieron el primer enfoque de este tipo a escala continental (Botella et al., 2018). Deneu *et al.* demostraron que las CNN que reciben parches de imágenes ambientales alrededor de cada ocurrencia superan a los modelos puntuales al capturar la estructura espacial del paisaje (Deneu et al., 2021). Estopinan *et al.* mostraron que incorporar series temporales de Sentinel-2 aporta información estacional que beneficia especialmente a las especies con pocas ocurrencias (Estopinan et al., 2022). En paralelo, las representaciones neuronales implícitas espaciales (SINR) codifican directamente coordenadas y fecha en una red multiespecie entrenada con registros de iNaturalist, produciendo mapas globales de miles de especies (Cole et al., 2023). Específicamente para aves, SatBird combina imágenes satelitales y datos de eBird en un conjunto de referencia para predecir tasas de encuentro de cientos de especies (Teng et al., 2024).

Validación espacial

Los datos de ocurrencia presentan autocorrelación espacial: registros cercanos comparten ambiente y, si se reparten al azar entre entrenamiento y prueba, el modelo obtiene estimaciones de desempeño optimistas. Roberts *et al.* argumentan que la validación cruzada debe respetar la estructura de los datos mediante bloques espaciales, temporales o jerárquicos (Roberts et al., 2017). El paquete `blockCV` implementa la generación de *folds* espacialmente separados y la estimación del rango de autocorrelación para dimensionar los bloques (Valavi et al., 2019). Este protocolo se adopta para la comparación entre el SDM neuronal

y MaxEnt.

2.4 Brecha de la literatura

La Tabla 2.2 resume los trabajos más representativos revisados, según modalidad, región geográfica, número de especies y tarea abordada.

Tabla 2.2: Comparación del trabajo relacionado y posicionamiento de esta propuesta.

Trabajo	Modalidad	Región	N.º esp.	Tarea
Kahl et al. (2021) (BirdNET)	Audio	Norteamérica, Europa	984	Clasificación
Ghani et al. (2023)	Audio	Global (Xeno-canto)	>10.000	Transferencia de *embeddings*
Kahl et al. (2023) (BirdCLEF)	Audio	África oriental	264	Detección en paisajes sonoros
Wah et al. (2011) (CUB-200)	Imagen	Norteamérica	200	Clasificación *fine-grained*
Van Horn et al. (2018)	Imagen	Global	5089	Clasificación con datos desbalanceados
Van Horn et al. (2022) (SSW60)	Audio, imagen, video	Norteamérica	60	Clasificación audiovisual
Phillips et al. (2006) (MaxEnt)	Ambiental	General	n.a.	Distribución (solo presencia)
Deneu et al. (2021)	Ambiental (parches)	Francia	miles (flora)	Distribución (SDM profundo)
Cole et al. (2023) (SINR)	Coordenadas + fecha	Global	47.375	Distribución multiespecie
Teng et al. (2024) (SatBird)	Satelital + eBird	EE. UU./Kenia	670	Tasas de encuentro
Este trabajo	**Audio, imagen, ambiental**	**Chile continental**	**55**	**Clasificación + distribución**

A partir de esta revisión se identifican tres brechas concretas. La primera es geográfica: los clasificadores bioacústicos y visuales de referencia se entrenan y evalúan sobre avifaunas de Norteamérica y Europa, y la evidencia global muestra que su desempeño se degrada en Sudamérica. No se identificaron modelos entrenados para las especies chilenas amenazadas. La segunda es de modalidad: la fusión de audio e imagen en fauna se ha explorado únicamente con datos emparejados de especies norteamericanas, sin trabajos que la apliquen a fuentes de ciencia ciudadana no emparejadas ni a avifaunas del hemisferio sur. La tercera es de método: los SDM con aprendizaje profundo son un área emergente que aún no se

ha aplicado a la distribución de aves en Chile, donde la práctica sigue apoyándose en MaxEnt. No existe, por tanto, un sistema integrado que combine identificación multimodal y modelado de distribución con aprendizaje profundo para la avifauna chilena. Esa es la oportunidad que aborda este proyecto.

3 Bases teóricas

Este capítulo plantea las preguntas de investigación y los objetivos sobre la brecha identificada en el Capítulo 2 y presenta, desde la base, los fundamentos de los métodos que usa el sistema: cómo clasifica y cómo se entrena una red neuronal, qué son una red convolucional y un *transformer*, cómo se convierte un sonido en una imagen que esas redes pueden leer, cómo se combinan dos modalidades, cómo se modela la distribución de una especie a partir de registros de solo presencia y cómo se evalúa todo lo anterior. Cierra con la metodología de trabajo, las fuentes de datos y los *baselines*, y con la justificación técnica de las decisiones tomadas.

3.1 Preguntas de investigación, objetivo general y objetivos específicos

Preguntas de investigación

PI1. ¿Puede un sistema de aprendizaje profundo multimodal identificar especies de aves chilenas a partir de audio y/o imagen con mejor desempeño que los clasificadores unimodales (solo audio o solo imagen) y que un modelo de IA generativa multimodal?

PI2. ¿Puede un modelo de distribución de especies basado en aprendizaje automático (redes neuronales, Random Forest o gradient boosting), que integra avistamientos de ciencia ciudadana, clima e índices de vegetación satelitales, superar a MaxEnt bajo un protocolo de validación espacial?

PI3. ¿Cómo afecta la escasez de datos de las especies amenazadas al desempeño de estos modelos? ¿Qué estrategias de aumentación y balanceo mitigan ese efecto?

Objetivo general

Desarrollar y evaluar un sistema de monitoreo de biodiversidad aviar que integre la identificación multimodal (audio e imagen) y el modelado de distribución espaciotemporal para especies de aves de Chile continental, con foco en especies endémicas y amenazadas.

Objetivos específicos

OE1. Construir un conjunto de datos curado y reproducible a partir de fuentes heterogéneas (Xeno-canto, iNaturalist/GBIF, registros de avistamientos, covariables ambientales satelitales y climáticas vía Google Earth Engine y el RCE del MMA), con particiones libres de fuga de información.

OE2. Entrenar y evaluar clasificadores de audio (CNN/AST) e imagen (EfficientNet), e integrarlos mediante *late fusion*, alcanzando una *accuracy* superior al 85 % en al menos 50 especies.

OE3. Entrenar modelos de distribución espaciotemporal basados en aprendizaje automático (redes neuronales, Random Forest y gradient boosting) y compararlos con un *baseline* MaxEnt, incluida la validación cruzada espacial por bloques.

OE4. Comparar el clasificador propuesto con un modelo de IA generativa multimodal mediante *prompting* (*zero-shot* y *few-shot*), para situar su desempeño frente a una herramienta de uso general.

OE5. Documentar el desempeño (*accuracy*, F1 macro, AUC-ROC, tiempos de entrenamiento e inferencia) y las limitaciones, en particular el efecto de la escasez de datos en las especies amenazadas.

La meta del 85 % de *accuracy* del OE2 se fijó en la propuesta del proyecto como un nivel exigente pero alcanzable para un problema *fine-grained* de más de cincuenta clases con pocos datos por especie. Es el nivel a partir del cual un asistente de identificación acierta en más de cinco de cada seis consultas, lo que lo vuelve útil como apoyo a un observador. Queda muy por encima de lo que logra el clasificador global de referencia en Sudamérica (BirdNET, con *recall* entre 0,24 y 0,52 según el continente, Tabla 2.1) y es comparable al que alcanzan los clasificadores regionales entrenados con conjuntos de datos mucho mayores. Un umbral más bajo no serviría como herramienta de apoyo, y uno más alto no sería realista con pocas decenas de grabaciones por especie.

3.2 Clasificación supervisada con redes neuronales

3.2.1 El problema de clasificación y la salida softmax

Clasificar es asignar una entrada $\mathbf{x}$ (una ventana de audio, una fotografía) a una de K clases disjuntas $\mathscr{C}_1, \ldots, \mathscr{C}_K$, aquí las $K = 55$ especies objetivo. Un clasificador útil no solo decide: entrega, para cada clase, una probabilidad posterior $p(\mathscr{C}_k \mid \mathbf{x})$ que expresa cuánta evidencia hay a favor de esa especie. Separar la estimación de probabilidades de la decisión final permite rechazar casos dudosos, compensar clases desbalanceadas y combinar las salidas de varios modelos, que es justamente lo que hará la fusión multimodal. La regla que minimiza el número de errores es elegir la clase de mayor probabilidad posterior (Bishop y Bishop, 2024, pp. 140–147):

$$\hat{y} = \operatorname*{arg\,max}_{k \in \{1,\ldots,K\}} \; p(\mathscr{C}_k \mid \mathbf{x}). \tag{3.1}$$

Una red neuronal produce para cada clase un puntaje real a_k (*logit*) y convierte esos puntajes en probabilidades con la función *softmax*, llamada así porque es una versión suavizada del máximo: si un puntaje domina a los demás, su probabilidad tiende a uno (Bishop y Bishop, 2024, p. 152):

$$p(\mathscr{C}_k \mid \mathbf{x}) = y_k = \frac{\exp(a_k)}{\sum_{j=1}^{K} \exp(a_j)}, \qquad 0 \le y_k \le 1, \quad \sum_{k=1}^{K} y_k = 1. \tag{3.2}$$

3.2.2 Verosimilitud y entropía cruzada

Para entrenar la red hace falta una medida de cuán lejos están sus probabilidades de las etiquetas verdaderas. Cada etiqueta se codifica como un vector $\mathbf{t}_n$ con un uno en la clase correcta y ceros en el resto (codificación 1-de-K). La verosimilitud de las N etiquetas de entrenamiento es el producto de las probabilidades que la red asigna a las clases correctas, $\prod_n \prod_k y_{nk}^{t_{nk}}$. Maximizarla equivale a minimizar su logaritmo negativo, la *entropía cruzada* (Bishop y Bishop, 2024, p. 162):

$$E(\mathbf{w}) = -\sum_{n=1}^{N} \sum_{k=1}^{K} t_{nk} \ln y_k(\mathbf{x}_n, \mathbf{w}), \tag{3.3}$$

donde $\mathbf{w}$ reúne todos los parámetros de la red. La entropía cruzada penaliza con fuerza las predicciones seguras y equivocadas (si $y_k \to 0$ para la clase correcta, $-\ln y_k \to \infty$) y su gradiente respecto de los logits tiene la forma simple $y_k - t_k$, la diferencia entre la probabilidad

predicha y la etiqueta. Es la pérdida con que se entrenan todos los clasificadores de esta tesis.

Cuando las clases tienen tamaños muy distintos, la red tiende a favorecer a las mayoritarias. Una corrección habitual es ponderar la pérdida de cada clase por un peso ω_k que decrece con su número de ejemplos n_k. La pérdida balanceada por número efectivo de muestras usa $\omega_k \propto (1-\beta)/(1-\beta^{n_k})$ (Cui et al., 2019). En el límite $\beta \to 1$ el peso tiende a $1/n_k$, el inverso de la frecuencia, que es la variante implementada aquí (normalizada para que los pesos promedien uno):

$$E_{\text{pond}}(\mathbf{w}) = -\sum_{n=1}^{N}\sum_{k=1}^{K} \omega_k\, t_{nk} \ln y_{nk}, \qquad \omega_k = \frac{1/n_k}{\frac{1}{K}\sum_{j=1}^{K} 1/n_j}. \tag{3.4}$$

3.2.3 Redes neuronales y su entrenamiento

Una red neuronal es una composición de transformaciones lineales y funciones no lineales. En la forma más simple, el perceptrón multicapa, cada capa l calcula $\mathbf{z}^{(l)} = h\big(\mathbf{W}^{(l)}\mathbf{z}^{(l-1)}\big)$ a partir de la salida de la capa anterior, con $\mathbf{z}^{(0)} = \mathbf{x}$ y $\mathbf{W}^{(l)}$ una matriz de pesos aprendibles (Bishop y Bishop, 2024, pp. 181–187). La no linealidad h es imprescindible: sin ella toda la red colapsaría en un modelo lineal. La más usada es la unidad lineal rectificada, $\mathrm{ReLU}(a) = \max(0, a)$, barata y libre del problema de los gradientes que se desvanecen con la sigmoide. Con suficientes unidades, una red de dos capas puede aproximar cualquier función continua, pero el teorema solo garantiza la existencia. En la práctica la profundidad permite representar la misma función con muchos menos parámetros y aprender representaciones jerárquicas, de rasgos simples a conceptos.

El entrenamiento minimiza la pérdida por *descenso de gradiente*: en cada paso los parámetros se mueven en la dirección contraria al gradiente, $\mathbf{w}^{(\tau)} = \mathbf{w}^{(\tau-1)} - \eta \nabla E(\mathbf{w}^{(\tau-1)})$, con una tasa de aprendizaje η. Como el gradiente sobre todo el conjunto es costoso, se estima sobre minilotes de n_b ejemplos (descenso de gradiente estocástico). Una pasada completa por los datos es una *época*. El gradiente de cada parámetro se obtiene por retropropagación. El optimizador Adam mantiene promedios móviles del gradiente (s_i) y de su cuadrado (r_i) para adaptar el tamaño del paso a cada parámetro (Bishop y Bishop, 2024, pp. 222–224):

$$w_i^{(\tau)} = w_i^{(\tau-1)} - \eta\, \frac{\hat{s}_i}{\sqrt{\hat{r}_i} + \delta}, \tag{3.5}$$

con $\hat{s}_i$ y $\hat{r}_i$ corregidos por el sesgo de su inicialización en cero y δ una constante pequeña de estabilidad. La variante AdamW, usada en esta tesis, aplica el decaimiento de pesos de forma desacoplada del gradiente (Loshchilov y Hutter, 2019). La tasa de aprendizaje se reduce a lo largo del entrenamiento (programación de coseno), porque conviene empezar con pasos grandes y terminar con pasos finos.

3.3 Sobreajuste, regularización y aumentación de datos

Una red con millones de parámetros puede memorizar el conjunto de entrenamiento, incluido su ruido, y fallar con datos nuevos: es el *sobreajuste*. Se detecta comparando el error de entrenamiento con el de un conjunto de validación: el primero baja siempre, mientras que el segundo baja y luego sube cuando la red empieza a memorizar (Bishop y Bishop, 2024, pp. 266–267). La *regularización* agrupa las técnicas que inducen a la red a preferir soluciones más simples o más invariantes. La experiencia práctica se resume en una regla: casi siempre generaliza mejor una red grande con regularización que una red pequeña sin ella (Bishop y Bishop, 2024, p. 254). Las técnicas usadas en esta tesis son las siguientes.

- **Decaimiento de pesos.** Se agrega a la pérdida un término $\frac{\lambda_{\text{wd}}}{2}\mathbf{w}^{\mathrm{T}}\mathbf{w}$ que penaliza los pesos grandes. Su gradiente $\lambda_{\text{wd}}\mathbf{w}$ empuja cada peso hacia cero salvo que los datos lo sostengan (Bishop y Bishop, 2024, p. 260).
- **Parada temprana.** Se conserva el modelo de la época con mejor desempeño en validación, lo que limita cuánto puede ajustarse la red.
- ***Dropout*.** Durante el entrenamiento se desactivan al azar unidades de la red. La red resultante es un promedio aproximado de muchas subredes y ninguna unidad puede depender de otra específica (Bishop y Bishop, 2024, pp. 279–281).
- **Profundidad estocástica.** En redes con bloques residuales (Sección 3.4) se omiten bloques completos al azar, con probabilidad creciente hacia la salida. Acorta la red durante el entrenamiento y regulariza como el *dropout*, pero a nivel de bloque (Huang et al., 2016).
- **Suavizado de etiquetas.** En vez de exigir probabilidad uno para la clase correcta, la etiqueta se reparte: $t_k = 1 - \varepsilon + \varepsilon/K$ para la clase correcta y ε/K para las demás (la

variante que implementa PyTorch), con $\varepsilon = 0{,}1$. Evita que la red se vuelva demasiado segura y mejora la calibración de sus probabilidades (Szegedy et al., 2016).

- **Aumentación de datos.** Se amplía el conjunto de entrenamiento con copias transformadas de cada ejemplo que conservan la etiqueta: recortes, volteos y cambios de color en imágenes, o ruido y cambios de ganancia en audio. Cada vez que el ejemplo se presenta se aplica una transformación distinta (Bishop y Bishop, 2024, pp. 257–258). Es la forma más efectiva de enseñar invariancias cuando hay pocos datos.
- ***Mixup*.** Se entrena con mezclas convexas de pares de ejemplos y de sus etiquetas (Zhang et al., 2018):

$$\tilde{\mathbf{x}} = \lambda \mathbf{x}_i + (1-\lambda)\mathbf{x}_j, \qquad \tilde{\mathbf{t}} = \lambda \mathbf{t}_i + (1-\lambda)\mathbf{t}_j, \qquad \lambda \sim \mathrm{Beta}(a,a), \tag{3.6}$$

  lo que obliga a la red a comportarse de forma suave entre ejemplos y reduce la memorización. Aquí $a = 0{,}2$.
- **SpecAugment.** Aumentación específica de espectrogramas: se enmascaran franjas aleatorias de frecuencia y de tiempo, de modo que la red no pueda apoyarse en una sola banda o en un solo instante del canto (Park et al., 2019). La Figura 3.3 muestra un ejemplo de ambas aumentaciones de audio.

3.4 Redes convolucionales y EfficientNet

3.4.1 La operación de convolución

Una fotografía (o un espectrograma) es una grilla de valores con fuerte estructura local: dos píxeles vecinos suelen parecerse y un rasgo (un borde, una mancha, un trino) ocupa una región pequeña y puede aparecer en cualquier posición. Una red densa ignora esa estructura y necesitaría miles de millones de pesos para una imagen de alta resolución. La red convolucional (CNN) incorpora en su diseño la localidad, la jerarquía, la equivariancia y la invariancia a traslaciones, y por eso necesita muchos menos datos (Bishop y Bishop, 2024, pp. 289–290). Su operación básica, la *convolución*, desliza un pequeño filtro o *kernel* $\mathbf{U}$ de $s \times s$ pesos sobre toda la entrada $\mathbf{I}$ y calcula en cada posición el producto punto entre

el filtro y el parche que cubre (Bishop y Bishop, 2024, p. 292):

$$C(p,q) = \sum_{l=1}^{s} \sum_{m=1}^{s} I(p+l, q+m)\, u_{lm} + b, \tag{3.7}$$

donde C es el *mapa de características*, u_{lm} los pesos del filtro y b un sesgo. Cada filtro actúa como un detector que se "enciende" (tras la ReLU) cuando el parche se parece a su patrón. Como el mismo filtro recorre toda la imagen, un rasgo se detecta esté donde esté, con muy pocos parámetros. Una capa aplica C_{out} filtros distintos sobre los C_{in} canales de entrada, con $(s^2 C_{\text{in}} + 1)\, C_{\text{out}}$ parámetros en total. El *pooling* resume bloques vecinos con el máximo o el promedio: conserva si un rasgo está presente y con qué fuerza, descarta parte de su posición exacta y reduce la resolución, de modo que las capas siguientes "ven" regiones cada vez mayores (Bishop y Bishop, 2024, pp. 296–298). Apilando capas de convolución y *pooling*, los rasgos simples de las primeras capas (bordes, tonos sostenidos) se combinan en patrones complejos (un pico, una sílaba del canto) y, al final, un *pooling* global y una capa densa con softmax producen las K probabilidades (Figura 3.1).

3.4.2 Conexiones residuales

Al apilar decenas de capas el entrenamiento se vuelve inestable: el gradiente que llega a las primeras capas se degrada y la red profunda rinde peor que una más corta. La solución de las redes residuales (ResNet) es sumar la entrada de cada bloque a su salida (He et al., 2016):

$$\mathbf{z}_l = \mathbf{F}_l(\mathbf{z}_{l-1}) + \mathbf{z}_{l-1}, \tag{3.8}$$

de modo que el bloque aprende solo el *residuo* respecto de la identidad, que puede reproducirse con pesos pequeños. Esto suaviza la superficie de error y permite entrenar redes de cientos de capas. BirdNET, EfficientNet y los *transformers* usan conexiones residuales.

3.4.3 EfficientNet

EfficientNet (Tan y Le, 2019) es la familia de CNN que usa esta tesis en ambas modalidades. Su bloque básico, MBConv, es un bloque residual "invertido": una convolución 1×1 expande los canales (por seis), una convolución *depthwise* de 3×3 o 5×5 filtra cada canal por separado (mucho más barata que una convolución completa), un módulo *squeeze-and-excitation* reescala los canales según su importancia global y una convolución 1×1 proyecta

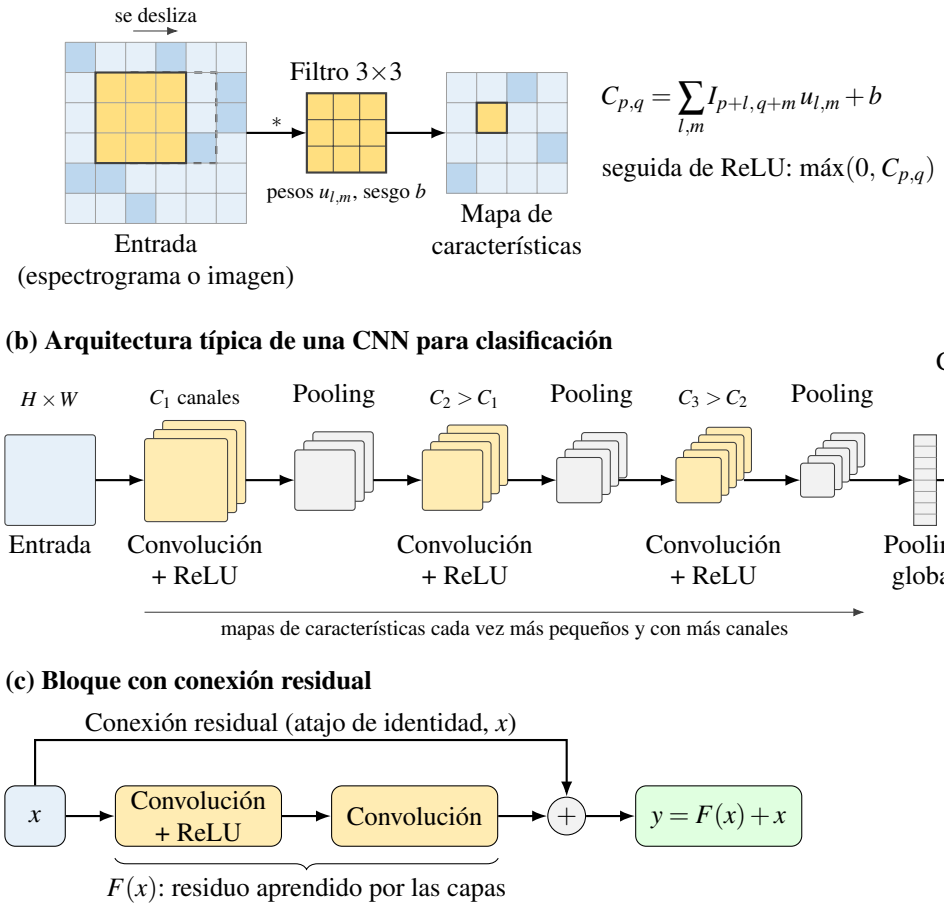


Figura 3.1: Elementos de una red convolucional: (a) un filtro de 3×3 recorre la entrada y produce el mapa de características (Ecuación 3.7); (b) arquitectura típica de clasificación, con bloques de convolución y *pooling* seguidos de *pooling* global, capa densa y softmax; (c) bloque residual (Ecuación 3.8). Elaboración propia a partir de Bishop y Bishop (2024) y He et al. (2016).

de vuelta al número de canales original, donde se suma el atajo residual. EfficientNet-B0 encadena un *stem* convolucional, siete etapas con 16 bloques MBConv en total, una convolución 1×1 a 1 280 canales, *pooling* global y la capa de clasificación; Tan y Le (2019) muestran el esquema completo. Con 4,1 millones de parámetros es la CNN de audio de esta tesis. La contribución metodológica de EfficientNet es el *escalado compuesto*: en lugar de agrandar la red solo en profundidad, ancho o resolución, los tres se escalan juntos con un único exponente ϕ,

$$d = \alpha^{\phi}, \qquad w = \beta^{\phi}, \qquad r = \gamma^{\phi}, \qquad \alpha\,\beta^2\gamma^2 \approx 2, \tag{3.9}$$

con $\alpha, \beta, \gamma \geq 1$ fijados por una búsqueda sobre B0, de modo que cada incremento de ϕ duplica aproximadamente el costo de cómputo. B3, el tercer paso de la familia (profundidad $\times 1{,}4$ y ancho $\times 1{,}2$ respecto de B0, resolución nativa de 300 px), tiene 10,8 millones de parámetros y es el clasificador de imagen; aquí se usa con una entrada de 384 px.

3.5 *Transformers*: atención, ViT y AST

3.5.1 Atención

Un *transformer* procesa un conjunto de N vectores o *tokens* (palabras de una frase, parches de una imagen, trozos de un espectrograma) y produce otro conjunto de N vectores con una representación más rica (Bishop y Bishop, 2024, p. 357). Su operación central, la *atención*, construye cada salida como una mezcla de todas las entradas con pesos que dependen de los propios datos: para interpretar un token, la red "mira" con más peso a los tokens relevantes, estén donde estén. Cada token genera tres vectores mediante matrices aprendibles: una *consulta* $\mathbf{q}$, una *clave* $\mathbf{k}$ y un *valor* $\mathbf{v}$. La similitud consulta–clave se mide con el producto punto, se normaliza con un softmax y pondera los valores (Vaswani et al., 2017):

$$\text{Atención}(\mathbf{Q},\mathbf{K},\mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^{\mathrm{T}}}{\sqrt{D_k}}\right)\mathbf{V}, \qquad \mathbf{Q} = \mathbf{X}\mathbf{W}^{(q)},\ \mathbf{K} = \mathbf{X}\mathbf{W}^{(k)},\ \mathbf{V} = \mathbf{X}\mathbf{W}^{(v)}, \tag{3.10}$$

donde $\mathbf{X}$ apila los N tokens como filas y D_k es la dimensión de las claves. Dividir por $\sqrt{D_k}$ evita que el softmax se sature. Una sola cabeza tiende a promediar patrones distintos, así que se usan n_h cabezas en paralelo con parámetros propios, cuyas salidas se concatenan y proyectan: es el análogo de usar varios filtros en una capa convolucional. Un bloque codificador alterna la atención multicabeza, que mezcla información *entre* tokens, con un perceptrón multicapa compartido, que transforma cada token por separado, ambos con conexión residual y normalización de capa. Como las matrices se comparten entre tokens, el modelo no sabe en qué posición está cada uno, y por eso se suma a cada token un vector de posición aprendido (Bishop y Bishop, 2024, pp. 366–374).

3.5.2 Vision Transformer y Audio Spectrogram Transformer

Aplicar atención a cada píxel es inviable, porque el costo crece con el cuadrado del número de tokens. El *Vision Transformer* (ViT) divide la imagen en parches de $P \times P$ píxeles ($P =$

16), aplana cada parche y lo proyecta linealmente a un vector de dimensión D, obteniendo $N = H_{\text{img}} W_{\text{img}} / P^2$ tokens para una imagen de $H_{\text{img}} \times W_{\text{img}}$ píxeles (Dosovitskiy et al., 2021). Se antepone un token especial de clase cuya salida, tras los bloques codificadores, alimenta la capa de clasificación. El *Audio Spectrogram Transformer* (AST) aplica exactamente el mismo diseño al espectrograma log-mel tratado como imagen (Gong et al., 2021): parches de 16×16 con paso de 10 (solapados), proyección a $D = 768$, embedding posicional, token de clase, 12 bloques codificadores con 12 cabezas y una capa densa de K salidas (Figura 3.2). El modelo de esta tesis tiene 86,2 millones de parámetros, veinte veces más que la CNN. A diferencia de la CNN, que capta bien relaciones locales pero tiene dificultades con dependencias de largo alcance en el espectrograma, la atención conecta cualquier par de parches desde la primera capa (Bishop y Bishop, 2024, p. 400). El precio es que, al tener menos sesgos inductivos, necesita más datos o un buen preentrenamiento.

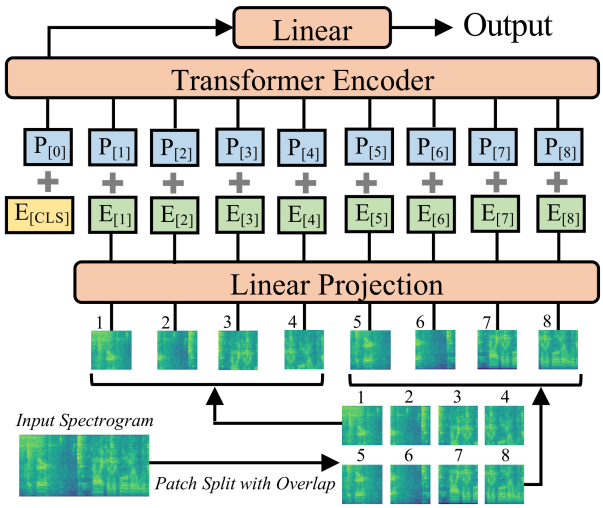


Figura 3.2: Arquitectura del *Audio Spectrogram Transformer*: el espectrograma se divide en parches de 16×16 con solapamiento, cada parche se proyecta linealmente y, con su embedding posicional y el token de clase, atraviesa el codificador *Transformer*; la salida del token de clase alimenta la capa de clasificación. Tomada de Gong et al. (2021).

3.6 *Transfer learning* y *frozen embeddings*

Una red entrenada con millones de imágenes naturales aprende en sus primeras capas rasgos genéricos (bordes, texturas) y en las últimas rasgos propios de su tarea. Para un problema nuevo con pocos datos, el *transfer learning* reutiliza esa red preentrenada: se

reemplaza la capa de clasificación por una de K salidas y se reentrena toda la red con una tasa de aprendizaje pequeña (*fine-tuning*), o bien se congela el cuerpo de la red y se entrena solo la nueva capa (Bishop y Bishop, 2024, pp. 189–190). El segundo caso equivale a usar la red como extractor de características fijas, sus *frozen embeddings*, y ajustar un clasificador lineal encima. Es la referencia de bajo costo que Ghani et al. (2023) proponen para bioacústica y uno de los *baselines* de esta tesis. Aquí se ajustan por completo una EfficientNet-B0 de ImageNet para audio, una EfficientNet-B3 de ImageNet para imagen y un AST preentrenado en AudioSet, y ese ajuste se compara con los *frozen embeddings* de los mismos modelos; como comparación en imagen se ajusta además un ViT-S/16 preentrenado en ImageNet-21k.

3.7 Del audio al espectrograma log-mel

3.7.1 Señal, muestreo y transformada de Fourier

Un sonido es una variación de la presión del aire en el tiempo. Al grabarlo, el computador lo muestrea: lee el valor de la señal F_s veces por segundo (la *frecuencia de muestreo*; la CNN de esta tesis trabaja a 32 kHz), lo que da una secuencia de números $x(n)$. El teorema de muestreo garantiza que no se pierde información si la señal no contiene frecuencias superiores a $F_s/2$, la frecuencia de Nyquist (Müller, 2021, pp. 50, 61). Con 32 kHz se cubren hasta 16 kHz, suficiente para las vocalizaciones de aves, que rara vez superan los 10 kHz a 12 kHz.

La forma de onda muestra cuándo suena algo pero oculta qué frecuencias contiene. La transformada de Fourier hace lo contrario (Müller, 2021, pp. 39–41). Compara la señal con sinusoides de cada frecuencia: el coeficiente es grande cuando la señal "sube y baja" al ritmo de esa sinusoide. Para una secuencia de L muestras, la transformada discreta de Fourier (DFT) es (Müller, 2021, p. 52)

$$X(k) = \sum_{n=0}^{L-1} x(n)\, e^{-2\pi i k n/L}, \qquad k = 0, \ldots, L-1, \tag{3.11}$$

donde el índice k corresponde a la frecuencia física kF_s/L hercios. Para no perder el "cuándo", la transformada de Fourier de tiempo corto (STFT) aplica la DFT a tramos cortos de la señal: se multiplica la señal por una ventana w de L muestras (en la CNN, $L = 1024$,

32 ms), se calcula la DFT y se desplaza la ventana en pasos de H muestras ($H = 320$, 10 ms) (Müller, 2021, pp. 53–55):

$$\mathscr{X}(m,k) = \sum_{n=0}^{L-1} x(n+mH)\, w(n)\, e^{-2\pi i k n/L}. \tag{3.12}$$

El *espectrograma* es la potencia $|\mathscr{X}(m,k)|^2$ dibujada como imagen, con el tiempo en horizontal (cuadro m, cada 10 ms) y la frecuencia en vertical. La ventana impone un compromiso: cuanto más larga, mejor resuelve las frecuencias y peor los instantes, y viceversa. Ninguna ventana localiza ambas cosas con precisión arbitraria (Müller, 2021, pp. 100–102). Los 32 ms elegidos resuelven los trinos rápidos de las aves con una resolución en frecuencia de 31 Hz.

3.7.2 Escala mel, logaritmo y normalización

El espectrograma lineal es "demasiado genérico": el oído no resuelve igual todas las frecuencias ni percibe la intensidad de forma lineal (Virtanen et al., 2018, pp. 21, 76). La percepción del tono es aproximadamente logarítmica: 220, 440 y 880 Hz suenan "igual de distantes" entre sí (Müller, 2021, p. 22). La escala mel formaliza esa percepción con una fórmula empírica (O'Shaughnessy, 1987):

$$\mathrm{mel}(f) = 2595 \log_{10}\!\left(1 + \frac{f}{700}\right). \tag{3.13}$$

Sobre esa escala se define un banco de $M = 128$ filtros triangulares $\mathbf{B} \in \mathbb{R}^{M\times(L/2+1)}$, estrechos en los graves y anchos en los agudos (Figura 3.3c), que agrupan los coeficientes de la STFT en bandas. La energía de cada banda se comprime con un logaritmo, porque el rango dinámico del espectrograma es enorme y la escala logarítmica hace visibles los componentes débiles pero relevantes (Müller, 2021, pp. 56, 99):

$$X_{\mathrm{mel}}(m,j) = 10 \log_{10}\!\Big(\sum_{k} B_{jk}\, |\mathscr{X}(m,k)|^2 + \delta\Big), \qquad j = 1,\ldots,M, \tag{3.14}$$

con δ una constante pequeña que evita el logaritmo de cero. El resultado, el espectrograma log-mel, es compacto y basta por sí solo como entrada a una red (Virtanen et al., 2018, p. 81). Antes de entrar a la red se estandariza (media cero y varianza uno), lo que mantiene la primera capa en zona no saturada. Una ventana de 5 s (160.000 muestras) produce así,

con relleno simétrico de $L/2$ muestras en los bordes, $\lfloor 160000/320 \rfloor + 1 = 501$ cuadros: una "imagen" de 128×501 valores. Tratarla con una CNN tiene sentido porque, con el eje de frecuencia logarítmico, un filtro de pocas bandas cubre siempre la misma razón de frecuencias y puede aprender patrones espectrotemporales invariantes a pequeñas transposiciones (Virtanen et al., 2018, p. 132). El AST usa su propio *front-end*, el mismo con que fue preentrenado en AudioSet: remuestrea cada ventana de 10 s a 16 kHz y calcula un log-mel de 128 bandas con ventana de 25 ms y paso de 10 ms (1 024 cuadros). La Figura 3.3 ilustra toda la cadena con una grabación real del corpus y la Figura 3.4 la resume.

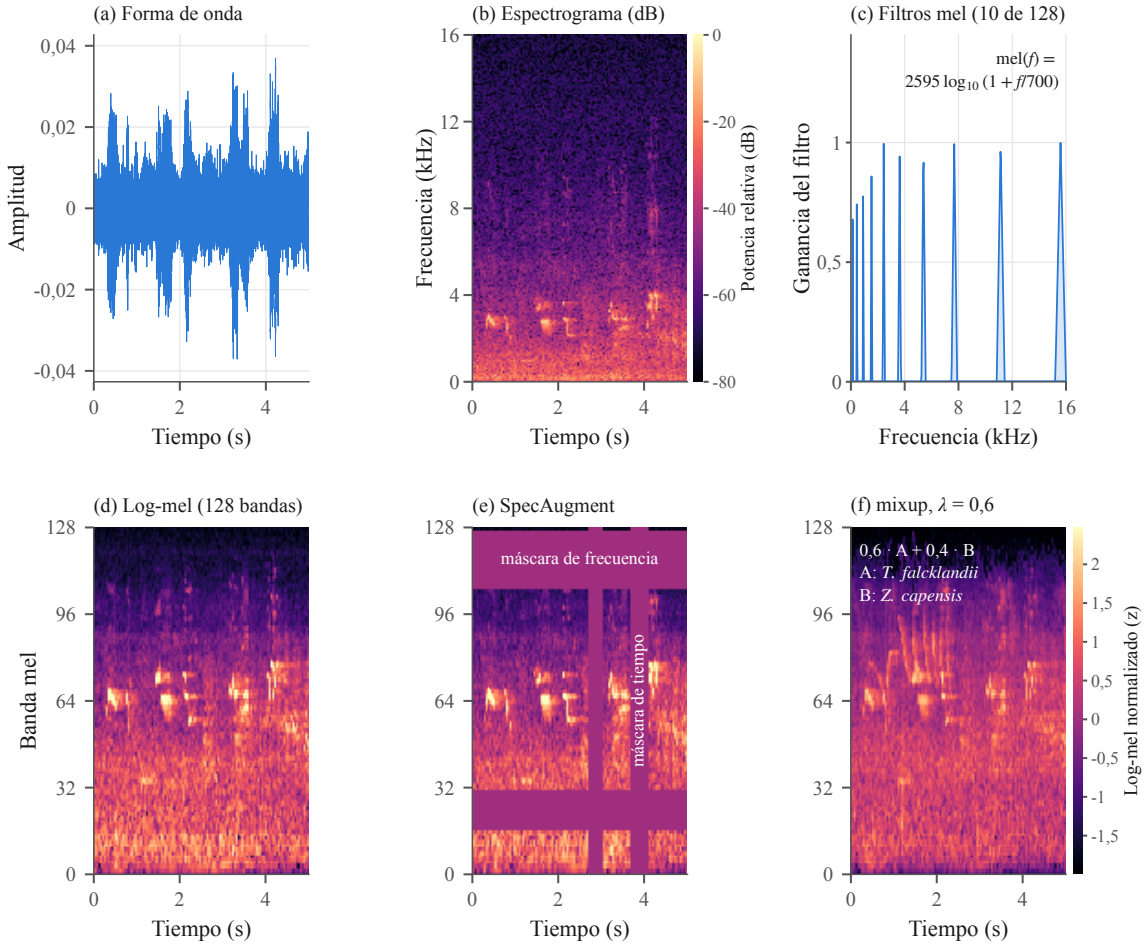


Figura 3.3: Representación de entrada del clasificador de cantos para una ventana de 5 s de zorzal (*Turdus falcklandii*, XC954086): (a) forma de onda; (b) espectrograma de potencia; (c) diez de los 128 filtros del banco mel; (d) espectrograma log-mel de 128×501 que recibe la CNN; (e) SpecAugment y (f) *mixup* con una ventana de chincol, las dos aumentaciones de entrenamiento.

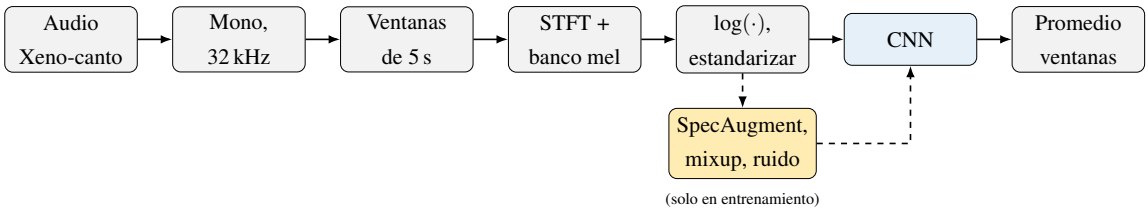


Figura 3.4: Pipeline de procesamiento de audio de la CNN, desde la grabación original hasta la predicción a nivel de grabación. El AST sigue el mismo esquema con ventanas de 10 s remuestreadas a 16 kHz y su propio banco de filtros.

3.8 Protocolos de inferencia: ventanas, agregación y TTA

Las redes convolucionales con capa densa necesitan una entrada de tamaño fijo, pero las grabaciones duran desde un segundo hasta varios minutos. Por eso el modelo clasifica *ventanas* de duración fija (5 s en la CNN, 10 s en el AST), y la predicción de una grabación se obtiene recolectando y agregando las predicciones de sus ventanas, cuidando que la evaluación se haga a nivel de grabación y no de ventana. Si una grabación produce W ventanas $x^{(1)},\dots,x^{(W)}$, la regla de agregación usada es el promedio de probabilidades seguido del máximo (Virtanen et al., 2018, pp. 26, 30):

$$\bar{p}_k = \frac{1}{W}\sum_{w=1}^{W} p(\mathscr{C}_k \mid x^{(w)}), \qquad \hat{y} = \arg\max_k \bar{p}_k. \tag{3.15}$$

El promedio diluye las ventanas sin vocalización o con ruido entre las que sí contienen al ave, lo que lo hace robusto a la anotación débil de Xeno-canto, donde la especie está etiquetada para la grabación completa pero no para cada instante (Sección 2.1). En esta tesis se reportan dos protocolos: *ventana única*, que clasifica solo la ventana central ($W = 1$), y *agregado*, con hasta $W = 12$ ventanas de 5 s equiespaciadas que cubren la grabación en la CNN, y hasta $W = 8$ de 10 s en el AST (Figura 3.5a).

Para la imagen el análogo es la *aumentación en tiempo de prueba* (TTA): en lugar de clasificar un solo recorte central de la fotografía, se clasifican diez vistas (los recortes de las cuatro esquinas y del centro, y sus reflejos horizontales) y se promedian las probabilidades con la misma Ecuación 3.15 (Figura 3.5b). Es la aumentación de datos aplicada en inferencia: suaviza errores debidos al encuadre a cambio de diez pasadas por el modelo.

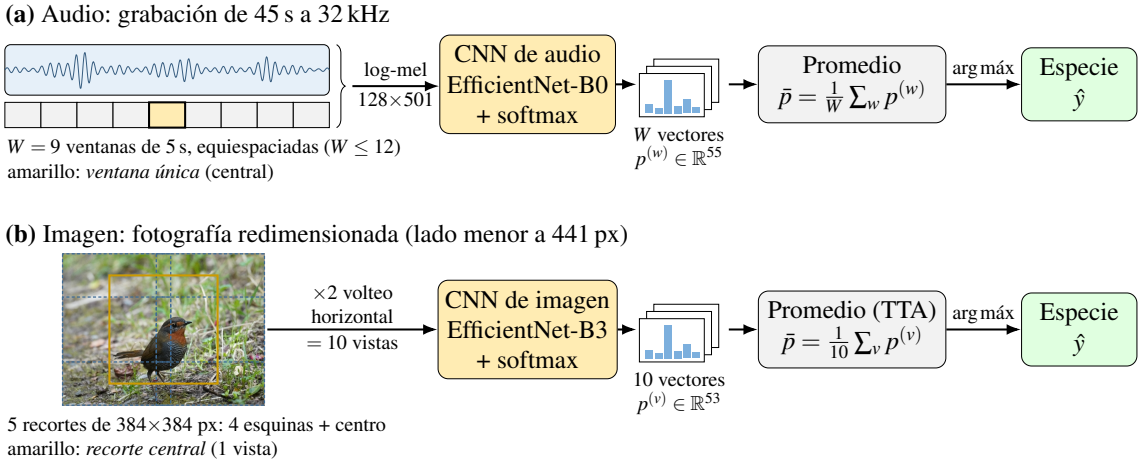


Figura 3.5: Protocolos de inferencia. (a) Audio: la grabación se divide en ventanas de 5 s, cada una pasa por la CNN y las probabilidades se promedian (Ecuación 3.15); la *ventana única* usa solo la central (en amarillo). (b) Imagen: cinco recortes de 384×384 y sus volteos horizontales forman las diez vistas de la TTA; el *recorte central* usa una sola (en amarillo). Fotografía de chucao de pmarinaraya (iNaturalist, CC BY-NC 4.0).

3.9 Fusión multimodal

Sea $\mathcal{Y} = \{1, \ldots, K\}$ el conjunto de especies. Cada observación consiste en una señal de audio $x^{(a)}$ y/o una imagen $x^{(v)}$, con etiqueta $y \in \mathcal{Y}$. Se entrenan dos clasificadores independientes, f_a y f_v, cada uno con su propia red y su propio conjunto de datos, que producen las probabilidades $p_a(k \mid x^{(a)})$ y $p_v(k \mid x^{(v)})$ con la Ecuación 3.2. Las tres formas de combinar las modalidades (Baltrušaitis et al., 2019) se distinguen por el nivel en que ocurre la combinación (Figura 3.6).

- ***Early fusion.*** Se concatenan las representaciones internas de ambas ramas (sus *embeddings* $\mathbf{h}_a \in \mathbb{R}^{1280}$ y $\mathbf{h}_v \in \mathbb{R}^{1536}$) y un único clasificador g decide: $\hat{y} = \arg\max_k g([\mathbf{h}_a; \mathbf{h}_v])_k$. Puede modelar interacciones entre modalidades, pero exige que ambas estén presentes.
- ***Intermediate fusion.*** Cada *embedding* pasa primero por una proyección propia a un espacio común de 256 dimensiones y la concatenación de las proyecciones alimenta el clasificador. Agrega parámetros que deben aprenderse de los datos emparejados.
- ***Late fusion.*** Cada rama decide por su cuenta y se combinan las probabilidades con una

media ponderada por $\alpha \in [0,1]$:

$$\hat{y} = \arg\max_{k \in \mathcal{Y}} \; \alpha \, p_a(k \mid x^{(a)}) + (1-\alpha)\, p_v(k \mid x^{(v)}). \tag{3.16}$$

Si falta una modalidad, $\hat{y}$ se obtiene de la otra, lo que hace al sistema robusto a modalidades faltantes y permite entrenar cada rama con datos no emparejados. Una alternativa es la media geométrica, $\propto p_a^{\alpha}\, p_v^{1-\alpha}$ (un producto de expertos). Con $\alpha = 1/2$ y un prior uniforme sobre las especies equivale, salvo normalización, a la combinación *naive Bayes* $p(\mathscr{C}_k \mid x^{(a)})\, p(\mathscr{C}_k \mid x^{(v)}) / p(\mathscr{C}_k)$, que supone las dos modalidades condicionalmente independientes dada la especie (Bishop y Bishop, 2024, pp. 146–147). Penaliza más a las clases que una modalidad descarta con seguridad.

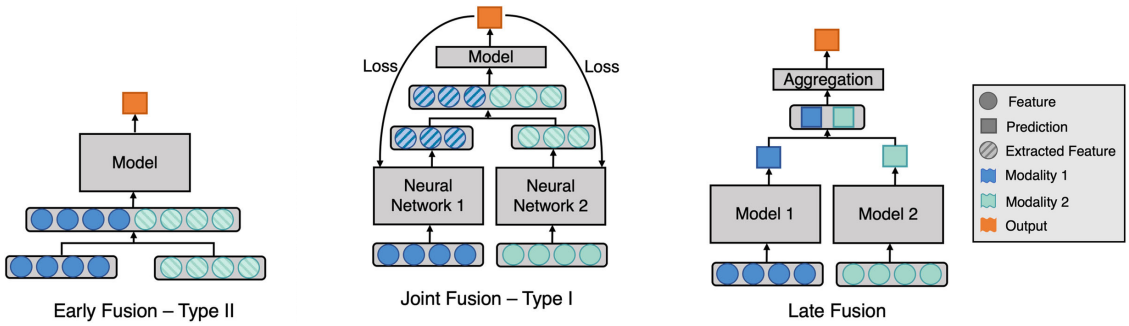


Figura 3.6: Estrategias de fusión multimodal: *early fusion* (se concatenan las características extraídas de cada modalidad), *joint fusion*, que corresponde a la *intermediate fusion* de esta tesis (cada modalidad pasa por su propia red antes de concatenarse), y *late fusion* (cada modalidad predice por separado y las predicciones se agregan). Los subtipos I y II distinguen si las características de entrada son crudas o extraídas. Tomada de Huang et al. (2020), CC BY 4.0.

Evaluación con fuentes no emparejadas. Las grabaciones de Xeno-canto y las fotografías de iNaturalist no corresponden a los mismos individuos, de modo que no existen pares naturales de audio e imagen. Para evaluar la fusión se construyen pares sintéticos: cada grabación del conjunto de prueba de audio se empareja al azar con una fotografía del conjunto de prueba de imagen de la misma especie, repitiendo el emparejamiento varias veces y reportando media y desviación estándar de las métricas. Este protocolo mide la ganancia de combinar evidencia de ambas modalidades, que es el escenario de uso previsto (un observador que dispone de una grabación y una fotografía de la misma ave), pero no captura correlaciones entre el canto y la apariencia de un mismo individuo. Esta limitación se declara en el análisis de resultados.

3.10 Modelos de distribución de especies

3.10.1 Qué modela un modelo de distribución

Un modelo de distribución de especies (SDM, o modelo de idoneidad de hábitat) relaciona empíricamente las observaciones de una especie con las condiciones ambientales de los sitios donde se la observó, y proyecta esa relación a todo el territorio para estimar dónde podría estar (Guisan et al., 2017, p. 11). Lo que captura es el *nicho realizado*: el conjunto de condiciones (temperatura, precipitación, vegetación, altitud) en que la especie efectivamente se encuentra, una vez descontadas la competencia y la historia, que es lo único observable con datos de campo (Guisan et al., 2017, pp. 32, 36). El modelo supone que la especie está en pseudoequilibrio con su ambiente y que la muestra cubre los ambientes que ocupa. Por ser correlativo, apoya hipótesis pero no las prueba (Guisan et al., 2017, pp. 46, 53). Formalmente, para cada especie k se dispone de presencias $\mathscr{P}_k = \{(s_i, t_i)\}$, con s_i la ubicación y t_i la fecha, y cada punto se describe con un vector de covariables $\mathbf{c}(s,t) \in \mathbb{R}^d$: temperatura media anual y precipitación anual de WorldClim, elevación, NDVI y la codificación cíclica del mes, $(\sin 2\pi t/12, \cos 2\pi t/12)$, que deja diciembre y enero contiguos. El NDVI (índice de vegetación de diferencia normalizada) mide el "verdor" a partir de la luz que refleja la superficie en dos bandas del espectro (Tucker, 1979):

$$\mathrm{NDVI} = \frac{\rho_{\mathrm{NIR}} - \rho_{\mathrm{Red}}}{\rho_{\mathrm{NIR}} + \rho_{\mathrm{Red}}}, \tag{3.17}$$

donde ρ_{NIR} y ρ_{Red} son las *reflectancias* (fracción de la luz incidente que la superficie devuelve) en el infrarrojo cercano y en el rojo. La vegetación verde refleja mucho infrarrojo y absorbe el rojo, así que su NDVI se acerca a uno, mientras que el suelo desnudo, el agua y la nieve dan valores cercanos a cero o negativos. Índices como este "realzan" una señal que las bandas por separado ocultan (Guisan et al., 2017, p. 98).

3.10.2 Datos de solo presencia y pseudoausencias

Los registros de ciencia ciudadana son de *solo presencia*: dicen dónde se vio a la especie, nunca dónde se la buscó sin éxito. Un modelo que contraste presencias con ausencias necesita entonces puntos de contraste artificiales, los *puntos de fondo* o *pseudoausencias*, que representan las condiciones ambientales disponibles en el territorio (Guisan et al., 2017, pp. 131–134). La opción con menos supuestos es muestrearlos al azar por toda el

área de estudio. Pero los datos oportunistas no se recogen al azar: se agrupan en zonas accesibles y a lo largo de las vías de comunicación (Guisan et al., 2017, p. 56), y ese sesgo de GBIF ha crecido con el tiempo. Con un fondo uniforme el modelo aprende dónde hay observadores, no dónde hay hábitat. El método del *grupo objetivo* corrige el sesgo tomando como pseudoausencias los registros de otras especies del mismo grupo (aquí, las demás aves del conjunto), porque esos registros comparten exactamente el esfuerzo de observación de las presencias (Phillips et al., 2009). La Figura 3.7 muestra la diferencia con los datos de esta tesis.

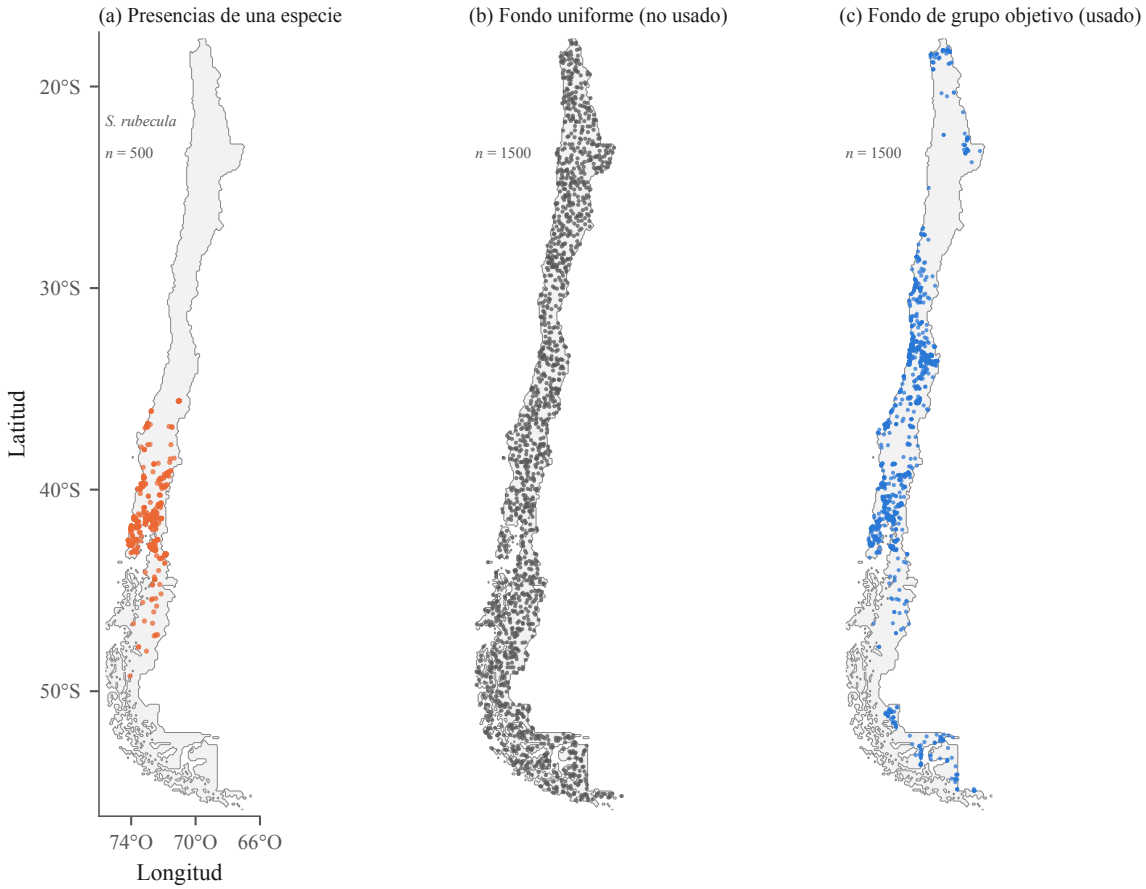


Figura 3.7: Presencias y pseudoausencias del modelo de distribución: (a) 500 registros de chucao (*Scelorchilus rubecula*); (b) fondo uniforme sobre Chile continental, descartado; (c) fondo de grupo objetivo, tomado de los avistamientos de las demás aves del conjunto, que reproduce la geografía del esfuerzo de observación y es el que usa la tesis.

3.10.3 MaxEnt y la regresión logística

MaxEnt es el método de referencia para datos de solo presencia. Su idea: de todas las distribuciones de probabilidad sobre el territorio compatibles con lo observado, elegir la de máxima entropía, la más "neutra" (Guisan et al., 2017, p. 217). En la formulación de Elith et al. (2011), si $f(\mathbf{c})$ es la densidad de las condiciones ambientales en el territorio (estimada con los puntos de fondo) y $f_1(\mathbf{c})$ la densidad en los sitios de presencia, MaxEnt estima el cociente $f_1(\mathbf{c})/f(\mathbf{c})$ buscando la f_1 más cercana a f en entropía relativa, sujeta a que los promedios de las covariables bajo f_1 coincidan con los observados en las presencias. La solución tiene forma exponencial en una combinación lineal de *features* $h(\mathbf{c})$ de las covariables (lineales, cuadráticas, de umbral, etc.) (Phillips et al., 2006):

$$\frac{f_1(\mathbf{c})}{f(\mathbf{c})} = \exp\big(\eta(\mathbf{c})\big), \qquad \eta(\mathbf{c}) = \beta_0 + \boldsymbol{\beta}^{\mathrm{T}} h(\mathbf{c}), \tag{3.18}$$

ajustada maximizando una verosimilitud penalizada, porque sin regularización el modelo sobreajusta (Guisan et al., 2017, p. 219). Esta forma es la de un modelo lineal generalizado: en el límite de un fondo grande, contrastar presencias con el fondo mediante una regresión logística penalizada estima las mismas pendientes $\boldsymbol{\beta}$ (el intercepto difiere y depende del número de puntos de fondo) (Fithian y Hastie, 2013). Por eso el *baseline* MaxEnt de esta tesis se implementa como una regresión logística con *features* lineales y cuadráticas y penalización L2 (la implementación original de MaxEnt usa L1):

$$P(y = 1 \mid \mathbf{c}) = \sigma\big(\mathbf{w}^{\mathrm{T}} h(\mathbf{c}) + b\big), \qquad \sigma(a) = \frac{1}{1 + e^{-a}}, \tag{3.19}$$

donde σ es la función logística, que convierte el predictor lineal (no acotado) en una probabilidad (Guisan et al., 2017, pp. 165–167). Los términos cuadráticos producen las respuestas unimodales típicas de las especies, que rinden mejor cerca de un óptimo ambiental y peor a ambos lados. La ventaja de este modelo es su interpretabilidad: cada coeficiente dice cómo cambia la probabilidad de presencia con una covariable.

3.10.4 Árboles de decisión, Random Forest y gradient boosting

Un *árbol de clasificación* divide los datos repetidamente en dos grupos según una regla sobre una sola covariable ("NDVI $< 0{,}4$", "elevación $> 1200\,\mathrm{m}$"), eligiendo en cada nodo la división que mejor separa presencias de ausencias. Cada hoja guarda la proporción

de presencias que llegan a ella, que es su probabilidad predicha (Guisan et al., 2017, p. 190). En la implementación usada, la impureza de un nodo se mide con el índice de Gini, $G = 1 - p_{\text{pres}}^2 - p_{\text{aus}}^2$, con p_{pres} y p_{aus} las proporciones de presencias y ausencias en el nodo, y cada división minimiza la impureza ponderada de los dos hijos. El árbol no asume ninguna forma de respuesta y captura interacciones, pero ajustar un solo árbol es una operación de alta varianza: pequeños cambios en los datos producen árboles muy distintos (Guisan et al., 2017, pp. 194, 203). Los *ensambles* corrigen eso combinando muchos árboles (Figura 3.8).

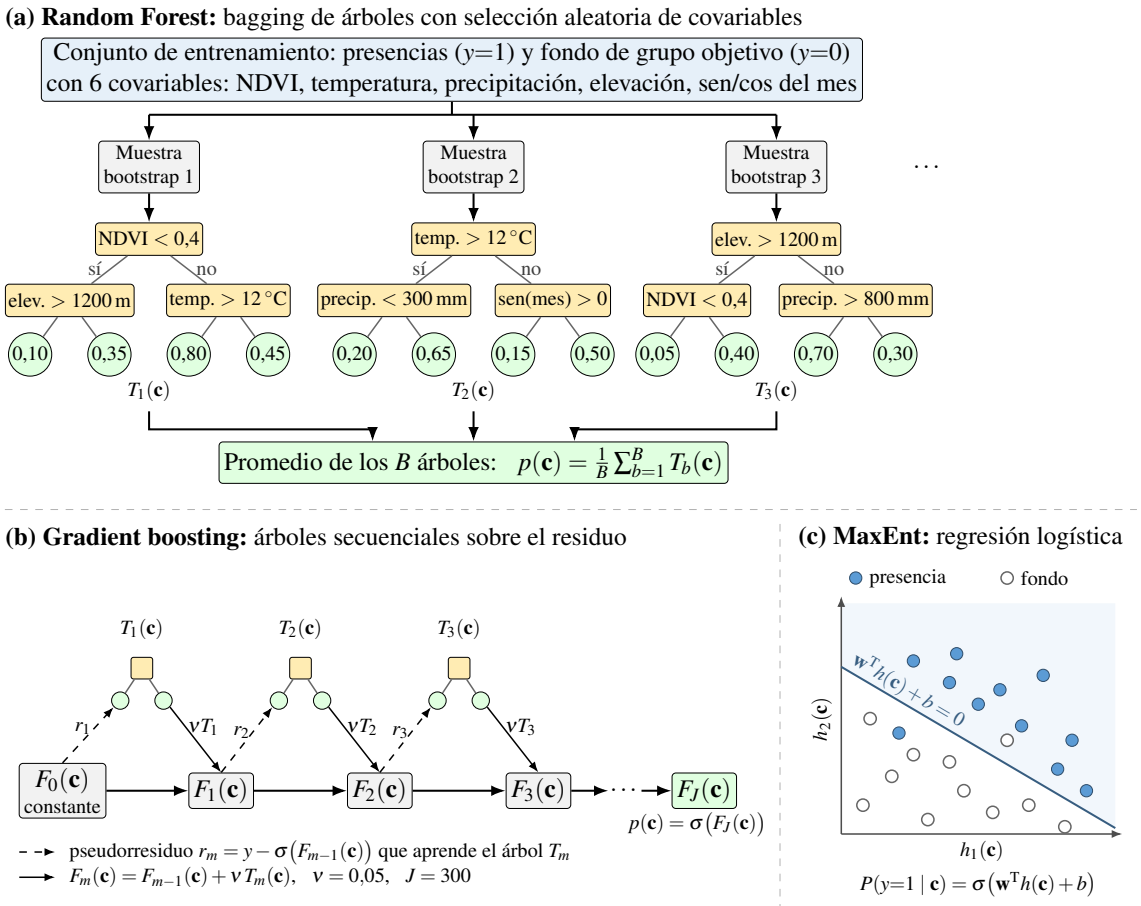


Figura 3.8: Modelos de distribución basados en árboles y modelo lineal: (a) Random Forest promedia B árboles entrenados sobre muestras *bootstrap* (Ecuación 3.20); (b) gradient boosting suma árboles ajustados secuencialmente al pseudorresiduo (Ecuación 3.21); (c) MaxEnt como regresión logística penalizada sobre las *features* $h(\mathbf{c})$ (Ecuación 3.19). Esquemas propios a partir de Breiman (2001), Friedman (2001) y Elith et al. (2011).

- **Random Forest** (Breiman, 2001). Entrena B árboles, cada uno sobre una muestra

bootstrap de los datos y eligiendo en cada nodo la mejor división entre un subconjunto aleatorio de $\sqrt{d}$ covariables, sin poda, y promedia sus probabilidades:

$$\hat{p}(\mathbf{c}) = \frac{1}{B}\sum_{b=1}^{B} T_b(\mathbf{c}). \tag{3.20}$$

El azar en los datos y en las variables descorrelaciona los árboles, y el promedio reduce drásticamente la varianza (Bishop y Bishop, 2024, p. 278). Aquí $B = 300$.

- **Gradient boosting** (Friedman, 2001). Construye el modelo de forma secuencial: cada árbol pequeño T_m se ajusta al gradiente negativo de la pérdida del conjunto anterior, es decir, a lo que todavía está mal modelado, y se suma con una tasa de aprendizaje ν que regula el peso de los árboles sucesivos:

$$F_m(\mathbf{c}) = F_{m-1}(\mathbf{c}) + \nu\, T_m(\mathbf{c}), \qquad m = 1,\dots,J, \qquad \hat{p}(\mathbf{c}) = \sigma\big(F_J(\mathbf{c})\big), \tag{3.21}$$

con F_0 el logit de la proporción inicial de presencias. Los *boosted regression trees* están entre los métodos de mejor desempeño en modelado de distribución (Elith et al., 2008; Valavi et al., 2022). Aquí $J = 300$ y $\nu = 0{,}05$.

3.10.5 Red neuronal conjunta multiespecie

Los SDM neuronales reemplazan las curvas de respuesta fijas de la regresión por una red que aprende interacciones no lineales entre covariables (Botella et al., 2018; Deneu et al., 2021). El modelo de esta tesis es un perceptrón multicapa *conjunto*: una única red para las 54 especies, que recibe las seis covariables concatenadas con un vector aprendido de 8 dimensiones que identifica a la especie k (su *embedding* $\mathbf{e}_k$),

$$P(y_k = 1 \mid \mathbf{c}) = \sigma\Big(g_\theta\big([\mathbf{c};\, \mathbf{e}_k]\big)\Big), \tag{3.22}$$

con g_θ una red de parámetros θ con dos capas ocultas de 64 unidades ReLU y *dropout*, entrenada con la entropía cruzada binaria ponderada por clase, de modo que presencias y fondo pesen lo mismo (Figura 3.9). Compartir la red entre especies transfiere información estadística de las especies con muchos registros a las de pocos, como hacen los modelos de Cole et al. (2023). Sin capas ocultas, el modelo se reduce a una regresión logística con pendientes compartidas entre especies y un intercepto por especie; el *baseline* MaxEnt de la Ecuación 3.19 es el extremo opuesto, con un modelo independiente por especie y *features*

cuadráticas.

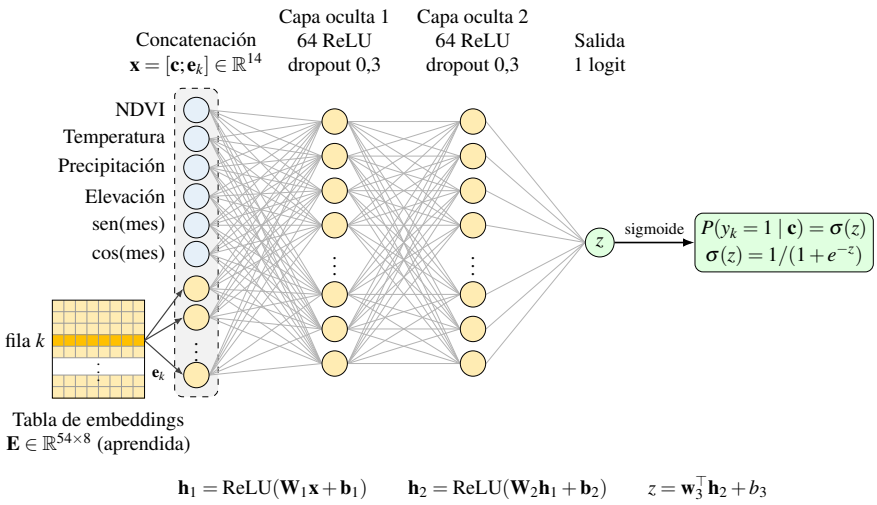


Figura 3.9: Red neuronal conjunta multiespecie del modelo de distribución. Las seis covariables (azul) se concatenan con el *embedding* aprendido de la especie (amarillo) y atraviesan dos capas ocultas de 64 unidades hasta un logit cuya sigmoide es la probabilidad de presencia (Ecuación 3.22); todas las especies comparten las capas ocultas.

3.11 Métricas de evaluación

3.11.1 Matriz de confusión, *accuracy* y F1

Toda métrica de clasificación parte de contar, para cada clase k, cuatro resultados al comparar la predicción con la verdad: verdaderos positivos TP_k (muestras de la especie k predichas como k), falsos positivos FP_k (muestras de otra especie predichas como k), falsos negativos FN_k (muestras de k predichas como otra especie) y verdaderos negativos TN_k. La *matriz de confusión* de $K \times K$ tabula cuántas muestras de cada especie verdadera (filas) se predijeron como cada especie (columnas). Su diagonal son los aciertos y fuera de ella se ve qué especies se confunden con cuáles (Bishop y Bishop, 2024, pp. 147–148). Con N

muestras de prueba:

$$\text{Accuracy} = \frac{1}{N}\sum_{i=1}^{N} \mathbb{I}[\hat{y}_i = y_i], \tag{3.23}$$

$$\text{F1}_{\text{macro}} = \frac{1}{K}\sum_{k=1}^{K} \frac{2\,\text{TP}_k}{2\,\text{TP}_k + \text{FP}_k + \text{FN}_k}, \tag{3.24}$$

donde $\mathbb{I}[\cdot]$ vale uno si la condición se cumple y cero si no. La *accuracy* es la fracción de aciertos y pesa cada muestra por igual, por lo que la dominan las clases frecuentes. Con clases raras puede ser alta aunque el sistema no acierte ninguna de ellas. El F1 de una clase es la media armónica de su precisión ($\text{TP}/(\text{TP}+\text{FP})$, qué fracción de lo predicho como k era realmente k) y su *recall* ($\text{TP}/(\text{TP}+\text{FN})$, qué fracción de las muestras de k se recuperó), y el F1 *macro* promedia el F1 de todas las clases por igual, de modo que una especie amenazada con tres grabaciones de prueba pesa tanto como una común con ocho (Virtanen et al., 2018, pp. 170–171). Por eso es la métrica de selección de modelos de esta tesis y la que mejor refleja el foco en las especies raras. También se reporta la *accuracy* top-5, que acepta la predicción si la especie correcta está entre las cinco más probables, útil para un asistente que propone candidatas.

3.11.2 Curva ROC y AUC

Las métricas anteriores dependen de una decisión (el argmax). Para evaluar la calidad de las probabilidades sin fijar un umbral se usa la curva ROC: para cada posible umbral sobre la probabilidad de la clase k se calcula la tasa de verdaderos positivos, $\text{TPR} = \text{TP}/(\text{TP}+\text{FN})$ (la *sensibilidad*), y la de falsos positivos, $\text{FPR} = \text{FP}/(\text{FP}+\text{TN})$ (uno menos la *especificidad*), y se grafica una contra otra (Virtanen et al., 2018, p. 172). Un clasificador perfecto pasa por la esquina superior izquierda y uno aleatorio sigue la diagonal (Figura 3.10). El *área bajo la curva* (AUC) resume toda la curva en un número entre 0,5 (azar) y 1 (perfecto), y tiene una interpretación probabilística: es la probabilidad de que el modelo asigne mayor puntaje a un positivo elegido al azar que a un negativo elegido al azar (Hanley y McNeil, 1982):

$$\text{AUC}_k = \frac{1}{n_k^{+}\, n_k^{-}} \sum_{i \in \text{pos}} \sum_{j \in \text{neg}} \Big(\mathbb{I}\big[p_k(\mathbf{x}_i) > p_k(\mathbf{x}_j)\big] + \tfrac{1}{2}\,\mathbb{I}\big[p_k(\mathbf{x}_i) = p_k(\mathbf{x}_j)\big] \Big), \tag{3.25}$$

donde n_k^+ y n_k^- son el número de muestras positivas y negativas de la clase k y los empates cuentan medio. La ROC está definida para problemas binarios. En clasificación multiclase se trata cada especie como un problema binario (“esta especie frente a todas las demás”) y se promedian las K áreas, el AUC macro, $\frac{1}{K}\sum_k \mathrm{AUC}_k$. A diferencia de la precisión, el AUC no cambia al agregar más negativos (Virtanen et al., 2018, pp. 173, 176).

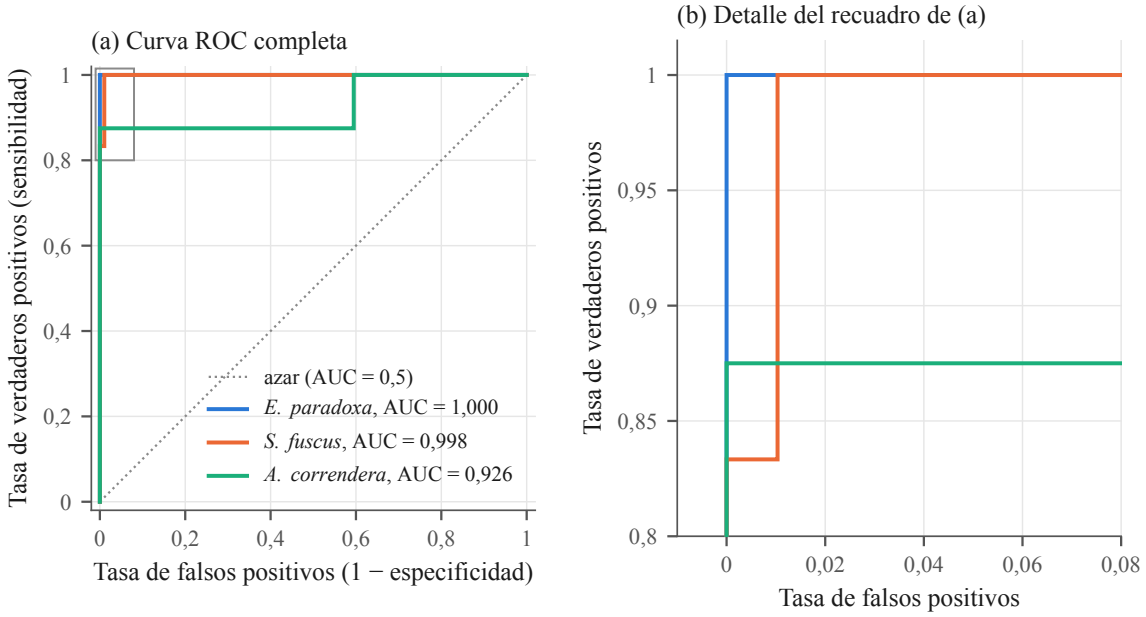


Figura 3.10: Curvas ROC de la CNN de audio (prueba, protocolo agregado) para tres especies con al menos seis grabaciones de prueba: una con AUC igual a uno (*Eugralla paradoxa*), la mediana (*Scytalopus fuscus*, 0,998) y la de menor AUC (*Anthus correndera*, 0,926). La diagonal es el clasificador al azar; el panel (b) amplía el recuadro de (a).

En el modelo de distribución el AUC es la métrica estándar (Valavi et al., 2022): para cada especie compara las probabilidades asignadas a las presencias de prueba con las de los puntos de fondo. Hay dos salvedades. Como los puntos de fondo no son ausencias reales, el AUC mide la capacidad de distinguir presencias del ambiente disponible, no de ausencias verdaderas, y sus valores son relativos: solo permiten comparar modelos de una misma especie en una misma área (Guisan et al., 2017, p. 265). Además, es poco sensible al tamaño muestral y a la prevalencia, lo que lo vuelve optimista (Guisan et al., 2017, p. 120), y depende de la extensión del área de estudio (Lobo et al., 2008). Por eso la tesis lo usa para comparar métodos sobre los mismos datos, no como valor absoluto.

3.11.3 Incertidumbre de las métricas

Con conjuntos de prueba pequeños las métricas son ruidosas: una grabación más o menos acertada cambia el F1 de una especie con tres muestras de 1,00 a 0,80, y dos errores lo bajan a 0,50. Esta tesis estima la incertidumbre con el *bootstrap* (Efron y Tibshirani, 1993): se remuestrea el conjunto de prueba con reemplazo R veces, se recalcula la métrica en cada remuestra y los percentiles 2,5 y 97,5 de esos valores forman el intervalo de confianza al 95 %. Para comparar dos modelos de distribución, que se evalúan sobre las mismas especies, se usa el test de Wilcoxon de rangos con signo, que contrasta si las diferencias de AUC por especie se distribuyen simétricamente alrededor de cero sin suponer normalidad.

3.12 Autocorrelación espacial y validación por bloques

La Figura 3.11 muestra la partición espacial que usa esta tesis; esta sección explica por qué hace falta. Los datos ecológicos violan un supuesto básico de la evaluación: las observaciones cercanas no son independientes, porque comparten ambiente, historia y, en ciencia ciudadana, observador. Esta *autocorrelación espacial* se mide con el semivariograma, que promedia las diferencias al cuadrado entre pares de puntos separados por una distancia d:

$$\gamma(d) = \frac{1}{2\,|N(d)|} \sum_{(i,j)\in N(d)} \left(z_i - z_j\right)^2, \tag{3.26}$$

donde $N(d)$ son los pares a distancia aproximadamente d y z una covariable. La Figura 3.12 muestra su forma típica: la semivarianza crece con la distancia hasta estabilizarse en la *meseta*, el valor que corresponde a dos puntos sin relación entre sí; el *rango* es la distancia a la que se alcanza esa meseta, a partir de la cual dos puntos ya no se parecen más que dos puntos cualesquiera; y el *efecto pepita* es la semivarianza en el origen, que recoge el ruido de medición y la variación a escalas menores que la distancia mínima entre puntos.

Si entrenamiento y prueba se reparten al azar, cada punto de prueba tiene vecinos casi idénticos en entrenamiento y las métricas resultan infladas (Guisan et al., 2017, pp. 276, 297). En audio el consejo es el mismo: nunca repartir grabaciones de un mismo lugar o archivo entre entrenamiento y prueba (Virtanen et al., 2018, pp. 161, 166). La validación cruzada por bloques (Roberts et al., 2017; Valavi et al., 2019) divide el territorio en bloques contiguos de tamaño comparable al rango de autocorrelación, asigna los bloques al azar a cinco *folds* y evalúa cada modelo en bloques que nunca vio. Mide, por tanto, la capacidad

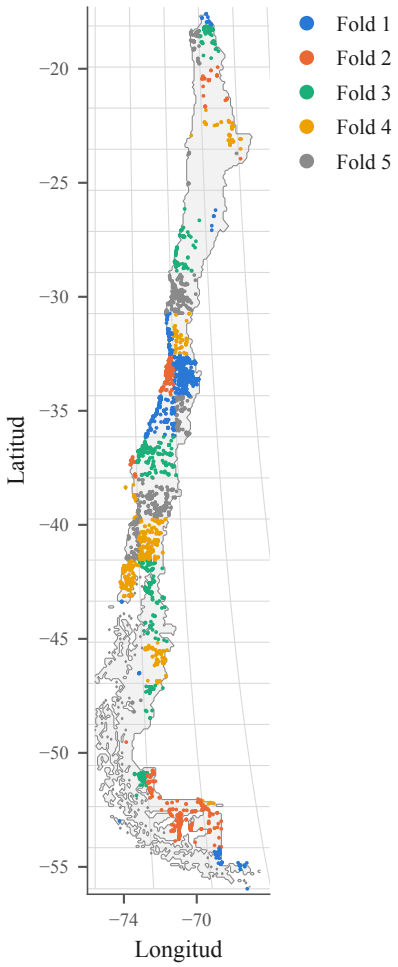


Figura 3.11: Partición espacial por bloques de 200 km usada para validar los modelos de distribución: muestra de 8 000 de los 34 926 puntos del conjunto del SDM, coloreados según el *fold* de su bloque (46 bloques repartidos al azar en cinco *folds* de tamaño equilibrado). Cada *fold* de prueba contiene bloques completos ausentes del entrenamiento.

de *extrapolar* a zonas sin registros, que es más exigente que la de interpolar entre registros vecinos (Figura 3.11). Ambos protocolos se reportan en el Capítulo 5.

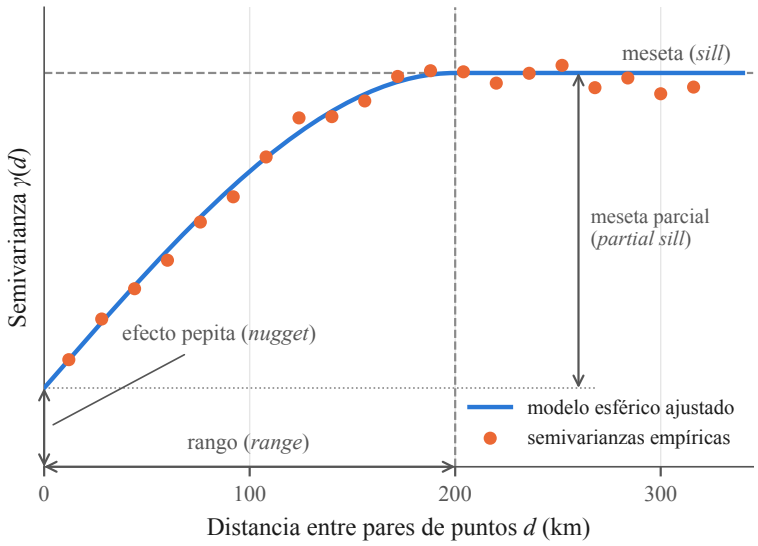


Figura 3.12: Semivariograma esquemático: semivarianzas empíricas por clase de distancia y modelo esférico ajustado, con sus tres parámetros: efecto pepita (valor en el origen), meseta (valor estable) y rango (distancia a la que se alcanza la meseta), que aquí fija el tamaño de los bloques de validación.

3.13 Metodología de trabajo, fuentes de datos y *baselines*

3.13.1 Metodología de trabajo

El proyecto se organiza según la metodología CRISP-DM: comprensión del problema, comprensión y preparación de los datos (Capítulo 4), modelado, evaluación y despliegue (Capítulo 5), fases recorridas de forma iterativa. Todo el desarrollo se realiza en Python con PyTorch (Paszke et al., 2019), sobre un repositorio versionado cuyas dependencias se gestionan con `uv` para garantizar la reproducibilidad de los experimentos.

3.13.2 Fuentes de datos

La Tabla 3.1 resume las fuentes públicas integradas, su modalidad, cobertura y uso en el proyecto. MODIS es el sensor de los satélites Terra y Aqua de la NASA del que proviene el NDVI. Google Earth Engine (GEE) no es una fuente de datos, sino la plataforma en la nube desde la que se consultan MODIS, WorldClim y SRTM sin descargar las imágenes completas (Sección 4.5.3).

Tabla 3.1: Fuentes de datos integradas en el proyecto. El plan original contemplaba ERA5 (Hersbach et al., 2020) y Sentinel-2 (Drusch et al., 2012); su reemplazo se explica en el Capítulo 4.

Fuente	Modalidad	Cobertura	Licencia	Uso en el proyecto
Xeno-canto (Vellinga y Planqué, 2015)	Audio	Global	CC (varias)	Grabaciones etiquetadas por especie focal
iNaturalist / GBIF (Van Horn et al., 2018)	Imagen	Global	CC (varias)	Fotografías geolocalizadas con grado de investigación
eBird e iNaturalist vía GBIF (Sullivan et al., 2014)	Tabular	Global	Abierta (CC)	Registros de presencia georreferenciados con fecha
MODIS vía GEE (Didan, 2021; Gorelick et al., 2017)	Satelital	Global, 1 km	Abierta	NDVI por punto y año
WorldClim y SRTM vía GEE (Hijmans et al., 2005; Farr et al., 2007)	Climática, topográfica	Global, 1 km	Abierta	Temperatura, precipitación y elevación
RCE – MMA (Ministerio del Medio Ambiente, 2026)	Documental	Chile	Pública	Categoría de conservación; selección de especies

3.13.3 Selección de *baselines*

Los *baselines* se eligieron pensando en dos dimensiones: cómo se abordaría cada problema *hoy, sin este proyecto*, y cómo se abordaría *con un método más antiguo o más simple*. La Tabla 3.2 los organiza por tarea y resume la configuración de cada uno. Los hiperparámetros completos están en el Apéndice B.

Tabla 3.2: *Baselines* del proyecto, por tarea y por dimensión de comparación.

Tarea	Práctica actual (sin este proyecto)	Método más simple o más antiguo
Identificación de especies	(i) Clasificadores unimodales (solo audio o solo imagen), la forma habitual de identificación automática: los mismos modelos de esta tesis evaluados sin fusión. (ii) Un modelo de IA generativa multimodal (Claude Opus 5.5) consultado con la fotografía y la lista de especies candidatas, en *zero-shot* y *few-shot* (una fotografía de referencia por especie); temperatura por defecto (1,0), esfuerzo de razonamiento bajo, salida estructurada restringida a la lista.	Regresión logística sobre los *frozen embeddings* de los mismos modelos preentrenados sin ajustar (EfficientNet-B0 y B3 de ImageNet, AST de AudioSet), siguiendo a Ghani et al. (2023): mide cuánto aporta el ajuste completo.
Distribución de especies	MaxEnt, el método de referencia en ecología, implementado como regresión logística penalizada (L2, $C = 1$) con *features* lineales y cuadráticas (Ecuación 3.19).	El propio MaxEnt es también el método clásico; frente a él se comparan Random Forest ($B = 300$), gradient boosting ($J = 300$, $\nu = 0{,}05$) y la red neuronal conjunta (Ecuación 3.22).

3.14 Justificación técnica de la metodología

Transfer learning. El conjunto de datos chileno es pequeño (2508 grabaciones de 55 especies y 7060 fotografías de 53), lo que hace inviable entrenar redes profundas desde cero. Los modelos preentrenados en ImageNet y AudioSet reutilizan representaciones aprendidas sobre millones de ejemplos y solo necesitan ajustarse a la nueva tarea (Sección 3.6). Que los *embeddings* de clasificadores de aves transfieran incluso con pocos ejemplos por clase (Ghani et al., 2023) es valioso para las especies amenazadas, que son las que menos datos tienen.

Late fusion. Aporta robustez frente a registros ambiguos o incompletos: un canto grabado con ruido puede complementarse con una fotografía y viceversa. Permite entrenar cada rama con datos no emparejados, que es la situación de Xeno-canto e iNaturalist, donde audio e imagen de un mismo individuo raramente coexisten, y opera cuando solo hay una modalidad (Sección 3.9). Los resultados de SSW60 muestran que esta combinación mejora el desempeño sobre cada modalidad por separado (Van Horn et al., 2022).

Balanceo y aumentación. La pérdida ponderada por clase, SpecAugment y *mixup* (Sección 3.3) abordan el desbalance y la escasez propios de los datos de ciencia ciudadana. Sin ellas, el clasificador se sesgaría hacia las especies comunes en desmedro de las amenazadas

y memorizaría un corpus de pocas decenas de grabaciones por especie.

Covariables ambientales. Google Earth Engine muestrea las covariables en la nube sobre todo el territorio continental y evita descargar y almacenar volúmenes masivos de imágenes satelitales (Gorelick et al., 2017). Las climatologías grilladas de WorldClim son el conjunto de datos climáticos más usado en ecología y ofrecen cobertura nacional homogénea, más práctica a escala que las estaciones meteorológicas, cuya distribución en Chile es irregular (Guisan et al., 2017, p. 63).

Modelado de distribución. La red conjunta multiespecie comparte información estadística entre especies con distribuciones similares, lo que beneficia a las de pocos registros. Los ensambles de árboles aportan una referencia fuerte y robusta en datos tabulares (Valavi et al., 2022), y MaxEnt, como regresión logística, aporta interpretabilidad. La validación espacial por bloques (Sección 3.12) permite comprobar que la comparación no esté inflada por autocorrelación.

Baselines exigentes. Elegir MaxEnt, un modelo de IA generativa y los *frozen embeddings* como referencias asegura que las mejoras reportadas sean significativas en la práctica y no artefactos de una comparación débil.

3.15 Efectos positivos esperados

Se espera que el sistema identifique al menos 50 especies de aves chilenas con una *accuracy* superior al 85 %, que la fusión multimodal supere a los clasificadores unimodales en *accuracy* y F1 macro y que el SDM basado en aprendizaje automático supere a MaxEnt en AUC-ROC. Más allá de las métricas, los efectos positivos esperados de la aplicación de estos elementos son:

(i) Una herramienta de apoyo al monitoreo automatizado de biodiversidad para organismos de conservación (MMA, CONAF, SAG) y ONG (ROC, CODEFF), alineada con las líneas de acción de investigación y monitoreo de la Estrategia Nacional de Conservación de Aves (Ministerio del Medio Ambiente, 2022).

(ii) Un insumo para la ciencia ciudadana y la identificación asistida de aves, que puede retroalimentar la calidad de los registros en plataformas como eBird e iNaturalist.

(iii) Mapas de probabilidad de presencia que permitan priorizar zonas de monitoreo y

evaluar el efecto de variables climáticas y de vegetación sobre la distribución de especies amenazadas.

(iv) Un repositorio reproducible que reduzca el costo de entrada para futuros trabajos sobre otras especies o regiones.

(v) Evidencia metodológica cuantitativa sobre la escasez de datos en especies amenazadas y sobre la efectividad de las estrategias de mitigación, útil para orientar esfuerzos de recolección de datos.

4 Levantamiento de datos

Este capítulo documenta las fases de comprensión y preparación de los datos: cómo se definió el conjunto de especies, cómo se construyeron los tres corpus del sistema (audio, imagen y avistamientos con covariables ambientales), qué decisiones se tomaron durante el levantamiento y en qué se apartó la implementación del plan original.

4.1 Repositorio reproducible y acceso a las fuentes

El levantamiento se implementó como una secuencia de *scripts* numerados sobre un paquete Python (`biomonitor`) con módulos de datos, audio, visión, fusión multimodal y distribución de especies. Las dependencias se fijan con `uv` y Python 3.12, los hiperparámetros viven en un único archivo de configuración y las credenciales se cargan desde variables de entorno. Las descargas y los entrenamientos se ejecutaron en un Mac con procesador Apple M4 Pro, con aceleración por GPU mediante Metal/MPS. El código, la configuración y los *scripts* están publicados en https://github.com/sebastianvidal92/biomonitor-aviar.

Las fuentes se consultan mediante sus interfaces programáticas: la API v3 de Xeno-canto, la API pública de GBIF para fotografías y registros de ocurrencia, y Google Earth Engine (GEE) para las covariables ambientales. El listado del RCE se descarga directamente del sitio del Ministerio del Medio Ambiente. Los modelos preentrenados provienen de los repositorios abiertos `timm` y Hugging Face.

4.2 Conjunto de especies objetivo

El conjunto objetivo se construyó a partir del listado oficial del Reglamento de Clasificación de Especies (RCE), que asigna a cada especie evaluada una categoría de conservación. La Tabla 4.1 resume las categorías que aparecen en este trabajo y la Figura 4.1 muestra el proceso de selección completo.

El punto de partida son las 147 aves clasificadas por el RCE. Primero se filtraron las de distribución continental (133) y, entre ellas, las de interés de conservación (CR, EN o VU, o endémicas de Chile), lo que dejó 59 candidatas. Para cada una se realizó un censo de

Tabla 4.1: Categorías de conservación del RCE que aparecen en este trabajo y número de especies del conjunto objetivo en cada una.

Sigla	Categoría	Significado	Especies
CR	En Peligro Crítico	riesgo extremadamente alto de extinción	1
EN	En Peligro	riesgo muy alto de extinción	5
VU	Vulnerable	riesgo alto de extinción	7
NT	Casi Amenazada	cerca de calificar como amenazada	1
LC	Preocupación Menor	evaluada y sin riesgo actual	3
NE	No Evaluada	sin evaluación formal en el RCE	38

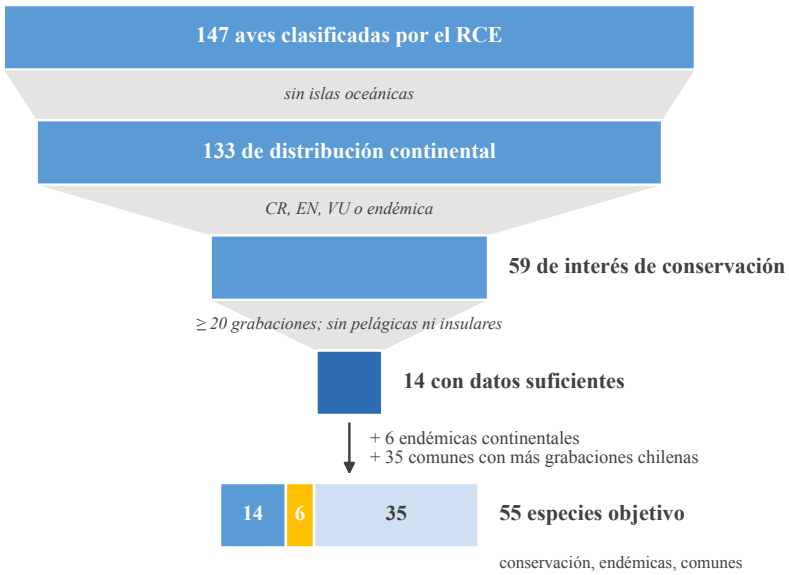


Figura 4.1: Construcción del conjunto de 55 especies objetivo: de las 147 aves clasificadas por el RCE se conservan las de distribución continental, luego las de interés de conservación y por último las que tienen datos suficientes; a esas 14 se suman 6 endémicas y 35 comunes.

datos: grabaciones en Xeno-canto (globales y con localidad en Chile) y fotografías con grado de investigación en GBIF. Se descartaron las especies pelágicas (aves marinas que viven en mar abierto, como albatros, petreles y pingüinos) e insulares (restringidas a las islas oceánicas), cuyo monitoreo responde a otra lógica, y las que no alcanzaban un mínimo de 20 grabaciones a nivel global. Quedaron 14 especies de interés de conservación: una CR (*Podiceps gallardoi*), cinco EN, siete VU y el choroy (*Enicognathus leptorhynchus*), endémico en Preocupación Menor. Segundo, se agregaron las seis especies endémicas continentales restantes con grabaciones suficientes (tenca, chiricoca, turca, hued-hued

castaño, tapaculo y churrín del norte). Tercero, se completó el conjunto con las 35 especies comunes con mayor número de grabaciones chilenas en Xeno-canto, que aportan masa de entrenamiento y representan los principales ecosistemas del país. En el resto del documento las especies se agrupan en tres categorías: *amenazadas* (13 especies CR, EN o VU), *endémicas* no amenazadas (7, incluido el choroy) y *comunes* (35). El listado completo se presenta en el Apéndice A.

La exclusión de las pelágicas no es solo una decisión de datos. Cerca de 25 de las 59 candidatas lo son, apenas vocalizan en tierra y su distribución es oceánica, incompatible con un modelo de distribución terrestre basado en vegetación y clima. La consecuencia es que no es posible reunir 50 especies únicamente con aves amenazadas, lo que obligó a completar el conjunto con especies comunes. La propuesta original pedía "foco" en las amenazadas, no exclusividad, y esa composición preserva el foco con una base de entrenamiento suficiente.

4.3 Corpus de audio

4.3.1 Censo y disponibilidad

El censo identificó 2587 grabaciones de Xeno-canto con localidad en Chile para las 55 especies. La Tabla 4.2 resume la disponibilidad por grupo y la Figura 4.2 la detalla por especie. La asimetría es fuerte. Las 13 especies amenazadas reúnen 129 grabaciones chilenas, el 5 % del total, con una mediana de 6 por especie, y cuatro de ellas no tienen ninguna. Las 35 comunes concentran el 81 %. La especie más grabada (*Turdus falcklandii*, 186) tiene por sí sola más audio que las 13 amenazadas juntas.

Tabla 4.2: Grabaciones de Xeno-canto con localidad en Chile por grupo de especies del conjunto objetivo.

Grupo	Especies	Grabaciones	% del total	Mínimo	Mediana	Máximo
Amenazadas (CR, EN, VU)	13	129	5,0	0	6	34
Endémicas (incl. choroy)	7	355	13,7	34	46	86
Comunes	35	2103	81,3	32	51	186
Total	55	2587	100	0	44	186

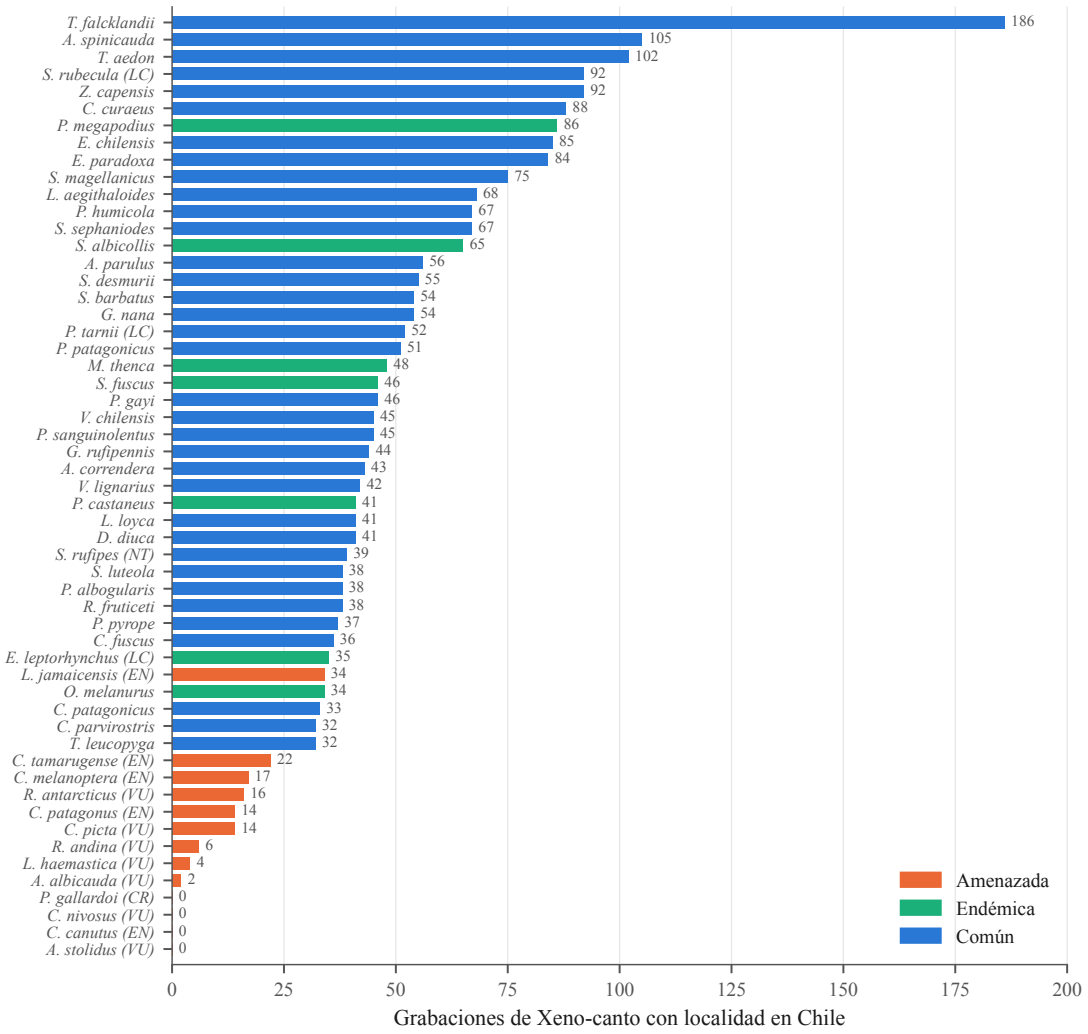


Figura 4.2: Grabaciones de Xeno-canto con localidad en Chile por especie del conjunto objetivo, coloreadas por grupo. Entre paréntesis, la categoría del RCE cuando la especie ha sido evaluada.

4.3.2 Descarga y composición del corpus

Dado el censo anterior, el corpus de entrenamiento no se limitó a Chile. Para cada especie se descargaron hasta 50 grabaciones de calidad A, B o C y de menos de cuatro minutos, priorizando las de localidad chilena y completando con grabaciones de otros países cuando faltaban. La calidad es la que asignan los propios usuarios de Xeno-canto en una escala de A (grabación nítida, con el ave en primer plano y casi sin ruido) a E (apenas audible). Se conservaron las tres mejores. Dos razones justifican el uso de audio extranjero. La primera es acústica: la firma vocal es específica de la especie y, para aves de distribución amplia,

las poblaciones vecinas comparten el repertorio. La segunda es práctica: sin grabaciones externas, las cuatro especies amenazadas sin audio chileno quedarían fuera del clasificador. El tope de 50 por especie acota el desbalance, pues las comunes tendrían hasta 186. La Tabla 4.3 resume el corpus resultante y la Figura 4.3 muestra su composición por especie y origen.

Tabla 4.3: Corpus de audio descargado y preprocesado.

Característica	Valor
Grabaciones	2509 seleccionadas; 2508 decodificadas correctamente (una corrupta)
Duración total	25,6 h (mediana 24 s por grabación; 7 % dura 5 s o menos)
Grabaciones por especie	mínimo 22 (*Agriornis albicauda*, *Rallus antarcticus*), tope 50; 39 especies alcanzan el tope
Origen	64 % Chile (1609); 36 % de otros 36 países (Argentina 434, Brasil 77, Ecuador 56, Perú 45, Estados Unidos 44)
Especies con menos de la mitad de audio chileno	17; cuatro sin ninguna grabación chilena (*P. gallardoi*, *C. canutus*, *C. nivosus*, *A. stolidus*)
Calidad de la grabación (escala de Xeno-canto)	A 69 %, B 26 %, C 4 %
Tipo de vocalización	canto en el 47 % de las grabaciones, llamado en el 56 % (categorías no excluyentes)
Particiones (grabaciones)	entrenamiento 1721 (69 %), validación 394 (16 %), prueba 393 (16 %)

4.3.3 Preprocesamiento y particiones

Cada archivo se decodificó, se convirtió a mono, se remuestreó a 32 kHz y se almacenó en una caché comprimida sin pérdida junto a un manifiesto con sus metadatos (especie, identificador de Xeno-canto, duración, país, calidad y tipo de vocalización). Las particiones de entrenamiento, validación y prueba (70/15/15) se construyeron a nivel de *grabación*, estratificadas por especie y con semilla fija, de modo que todas las ventanas extraídas de un mismo archivo pertenecen a una única partición. Las 55 especies están presentes en las tres particiones. El conjunto de prueba tiene entre 3 (*A. albicauda*) y 8 grabaciones por especie, lo que, como se verá en el Capítulo 5, hace ruidosas las métricas de las especies raras.

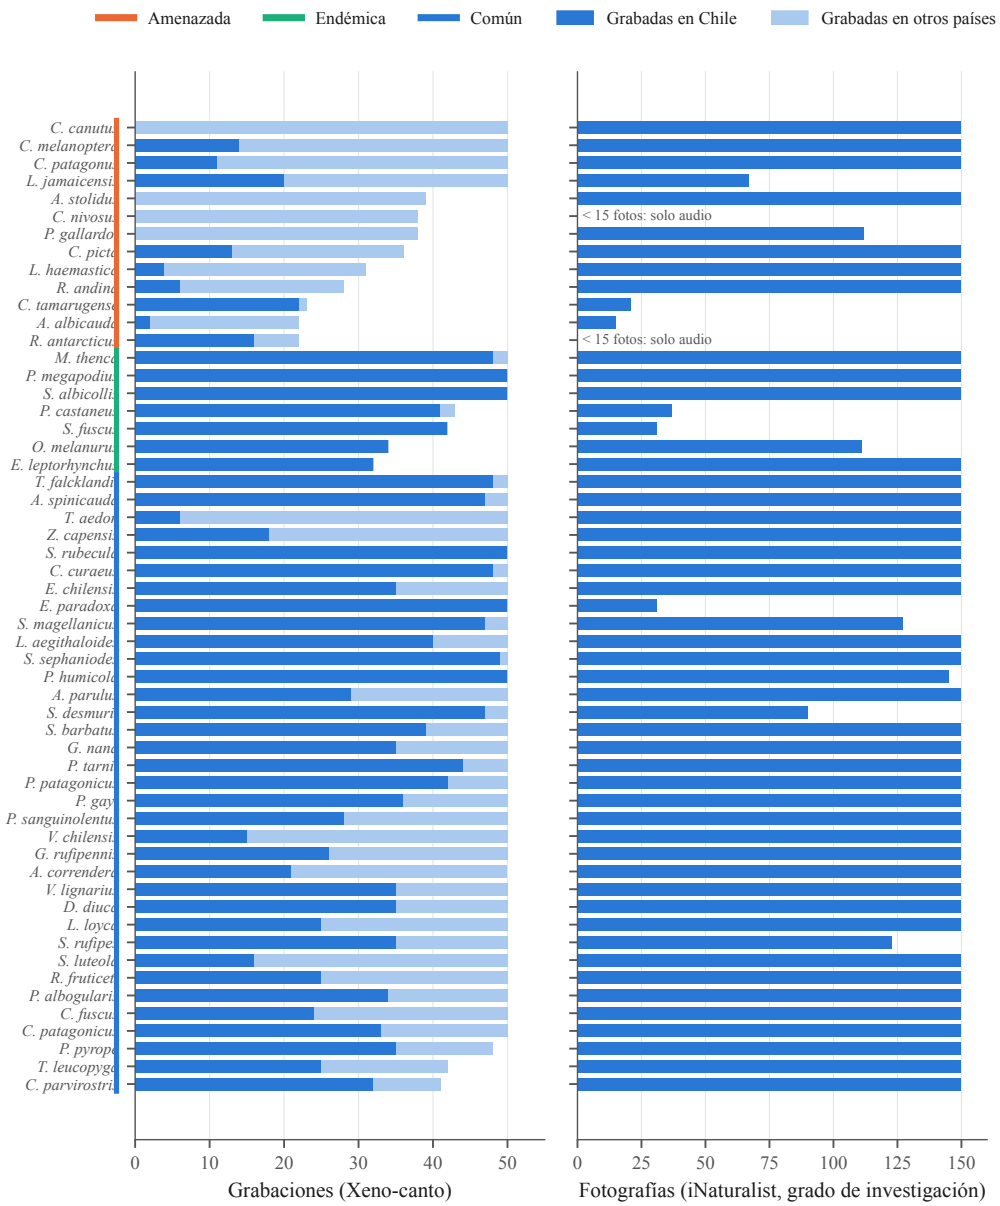


Figura 4.3: Composición de los corpus por especie; las especies se ordenan por grupo de conservación (franja de color) y número de grabaciones. Izquierda: grabaciones de audio del corpus de entrenamiento según su origen. Derecha: fotografías con grado de investigación de iNaturalist. Las dos especies con menos de 15 fotografías no participan del clasificador de imagen.

4.4 Corpus de imagen

Las fotografías provienen de observaciones de iNaturalist con grado de investigación, es decir, geolocalizadas y con la identificación validada por la comunidad. Se descargaron a través de la API de GBIF (iNaturalist contributors, 2026) con un tope de 150 por especie. La descarga exigió dos ajustes. Primero, un mapa de sinónimos taxonómicos: iNaturalist clasifica al fío-fío como *Elaenia albiceps* y escribe *Sylviorthorhynchus desmursii* para el colilarga, por lo que las consultas con los nombres del RCE devolvían cero resultados. Segundo, un respaldo filtrado para las especies con pocas fotografías: al ampliar la búsqueda a todo GBIF aparecían espectrogramas de Xeno-canto y fotografías de especímenes de museo, de modo que se restringió a observaciones humanas de aves vivas.

Se obtuvieron 7068 fotografías para las 55 especies. Dos especies amenazadas no alcanzaron el mínimo de 15 fotografías de aves vivas (*Charadrius nivosus*, con 2, y *Rallus antarcticus*, con 6) y quedaron fuera del clasificador de imagen como especies *solo audio*, que la fusión multimodal sigue cubriendo. El corpus del clasificador tiene, por tanto, 7060 fotografías de 53 especies, entre 15 (*A. albicauda*) y 150 por especie, con solo dos especies bajo 30. El 52 % de las fotografías fue tomado en Chile y el 33 % en Argentina. Como cada fotografía es una observación independiente, la partición se hizo a nivel de fotografía, estratificada por especie y con la misma semilla: 4980 para entrenamiento, 1040 para validación y 1040 para prueba. El mismo patrón de escasez del audio reaparece aquí: las especies de mayor interés de conservación son las que tienen menos ejemplos y conjuntos de prueba de 2 a 5 fotografías.

4.5 Avistamientos y covariables ambientales

4.5.1 Registros de presencia

Los registros de presencia para el modelo de distribución se obtuvieron de la búsqueda pública de ocurrencias de GBIF, que agrega las observaciones de eBird (Levatich y Ligocki, 2026) e iNaturalist, con un tope de 2000 registros por especie dentro de Chile continental (coordenadas válidas y dentro del rectángulo de latitud -56° a $-17{,}5^\circ$ y longitud $-75{,}7^\circ$ a $-66{,}4^\circ$, que excluye las islas oceánicas). El plan original contemplaba la base histórica de eBird (EBD), que entrega listas completas con el esfuerzo de observación. La solicitud de acceso se envió en julio de 2026 y, al momento de escribir este informe (octubre de 2026),

no ha sido aprobada, de modo que se optó por GBIF, que es inmediato y reproducible. El costo de esta decisión es la pérdida del esfuerzo de observación, que se compensa en la generación de pseudoausencias (Sección 4.5.2).

Se reunieron 100.270 registros de las 55 especies. Cuarenta y nueve especies alcanzan el tope y cinco quedan por debajo de 500 (*Anous stolidus* tiene solo 5 y no se modela). La Figura 4.4 muestra su distribución. Espacialmente, siguen la geografía del esfuerzo de observación, concentrados en la zona central y en torno a las ciudades y rutas, y el patrón apenas cambia entre verano e invierno. Temporalmente, el 87 % corresponde a 2024–2026, por el crecimiento reciente de la ciencia ciudadana y porque el tope por especie favorece los registros más recientes. Estacionalmente, la mitad (51 %) se concentra en enero y febrero, el verano austral. Esta estacionalidad mezcla la fenología de las aves con el esfuerzo de los observadores y es una de las limitaciones que se discuten en el Capítulo 6.

4.5.2 Pseudoausencias y conjunto de datos del SDM

Un modelo de distribución necesita contrastar los lugares donde la especie está con lugares donde no está. Los registros de ciencia ciudadana solo dicen dónde se la vio, nunca dónde se la buscó sin éxito, así que las "ausencias" deben construirse artificialmente: son las *pseudoausencias* o puntos de fondo (Sección 3.10). La forma más simple, repartirlas al azar por todo el territorio, tiene un problema: los avistamientos se concentran donde hay observadores, de modo que el modelo aprendería a distinguir "lugares con gente" de "lugares sin gente" en vez de hábitat bueno y malo. Para evitarlo se usó el método del *grupo objetivo* (Phillips et al., 2009): se tomó una única muestra aleatoria de 10.000 avistamientos de todas las especies del conjunto, compartida entre todas las especies modeladas, que por construcción reproduce los lugares y meses en que la gente observa aves; cada modelo usa 1500 de esos puntos como fondo (Apéndice B). Así, el contraste que aprende el modelo es entre los sitios donde se vio a la especie y los sitios comparables donde se observan aves en general. Las presencias se limitaron a 500 registros por especie para reducir el peso de las zonas sobremuestreadas. Tras muestrear las covariables, el conjunto de datos quedó en 34.926 puntos: 25.171 presencias de 55 especies (54 con al menos 20, el mínimo para modelar) y 9755 puntos de fondo (los 245 restantes cayeron sobre agua o sin datos).

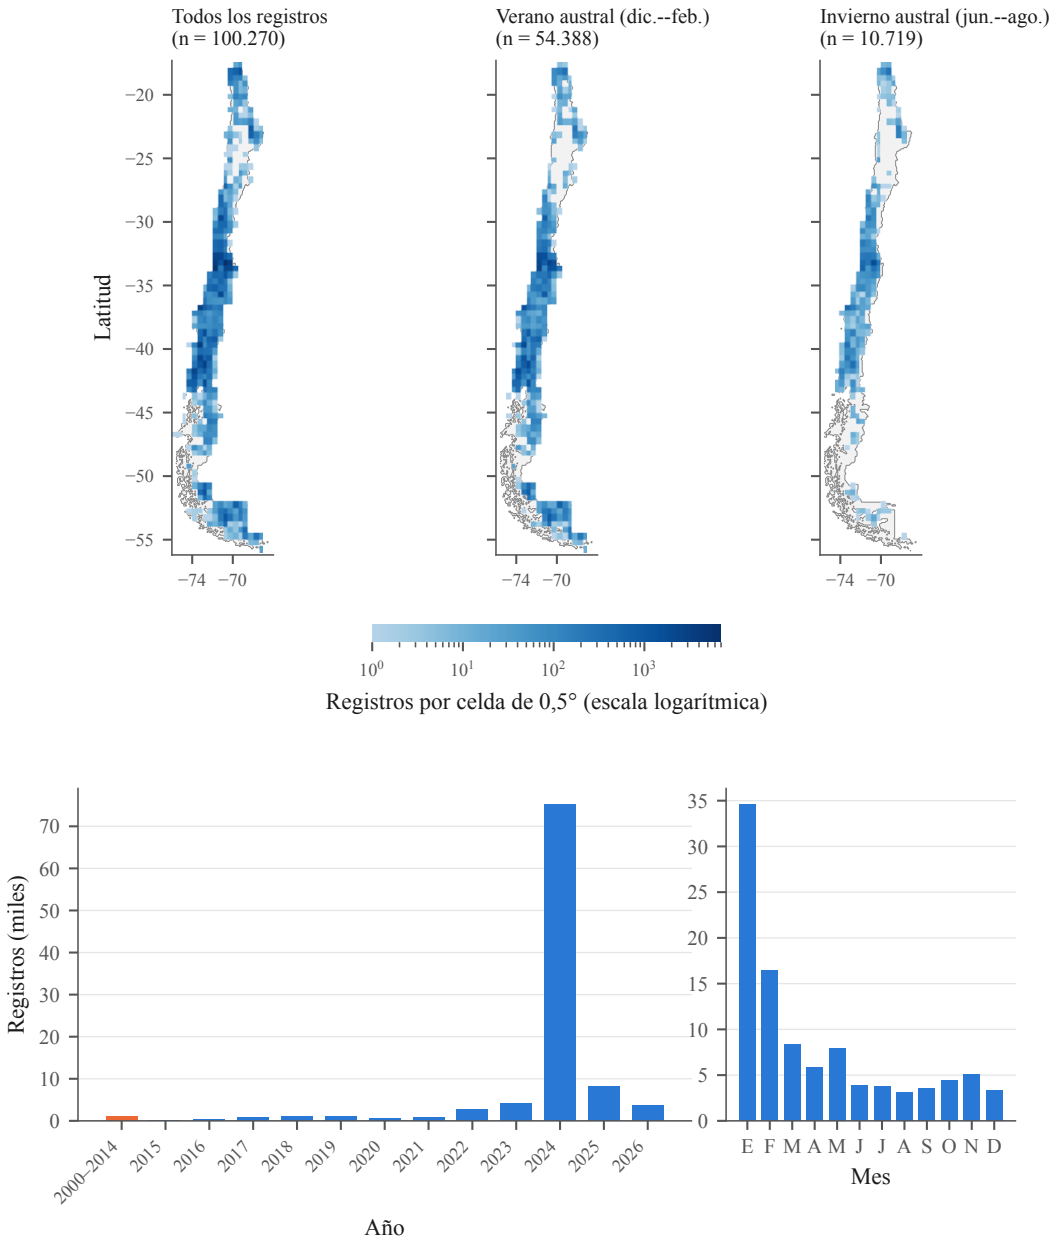


Figura 4.4: Registros de presencia obtenidos de GBIF (eBird e iNaturalist) para las 55 especies. Arriba: densidad espacial en celdas de 0,5° para todos los registros, para el verano y para el invierno austral. Abajo: distribución por año y por mes.

4.5.3 Covariables ambientales

Cada punto (presencia o pseudoausencia) se describe con cuatro variables ambientales y el mes del registro (Tabla 4.4, Figura 4.5). Las variables ambientales se obtuvieron de

Google Earth Engine, una plataforma de Google que almacena en la nube catálogos de imágenes satelitales y capas climáticas y permite consultarlos sin descargarlos (Gorelick et al., 2017). Para cada punto se pidió, en una sola consulta, el valor de las cuatro capas a 1 km de resolución. El NDVI (índice de vegetación de diferencia normalizada) mide la cantidad de vegetación verde a partir de la luz que refleja la superficie y proviene de MODIS, un sensor de los satélites Terra y Aqua de la NASA que observa toda la Tierra cada uno o dos días. La temperatura media anual y la precipitación anual provienen de WorldClim, una climatología global interpolada a partir de estaciones meteorológicas. La elevación proviene del modelo digital de terreno SRTM. El mes del avistamiento se codifica de forma cíclica (seno y coseno), lo que aporta el eje temporal al modelo.

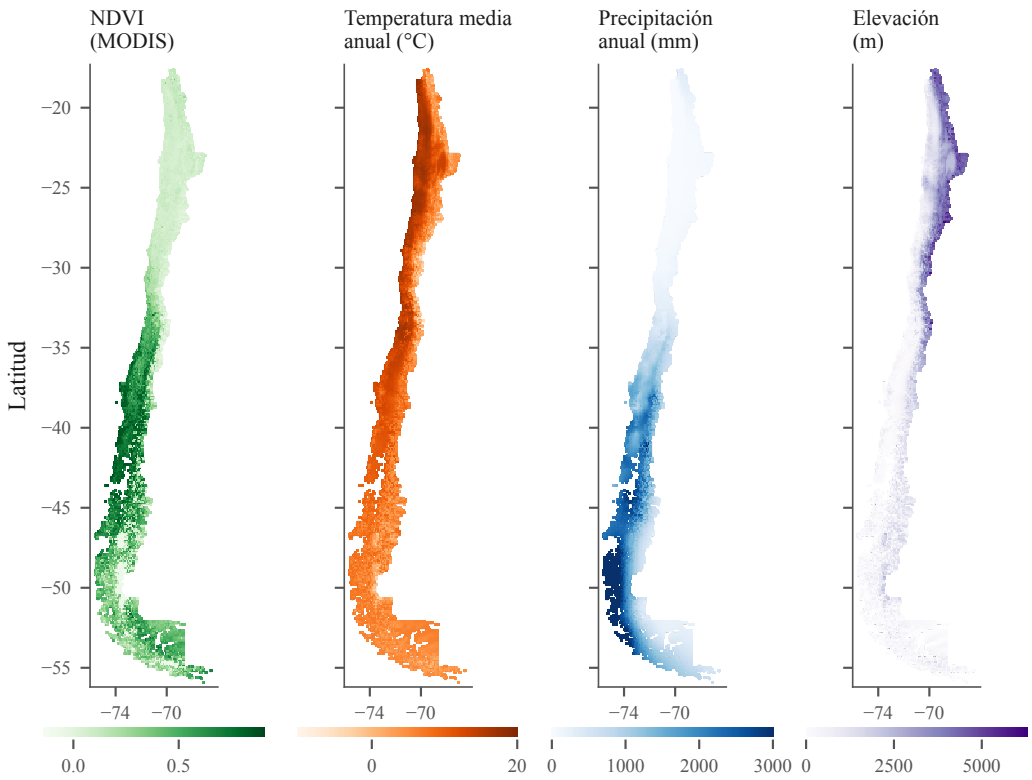


Figura 4.5: Covariables ambientales sobre la grilla de 0,1° de Chile continental: NDVI, temperatura media anual, precipitación anual (escala truncada en 3000 mm) y elevación.

El plan original usaba el reanálisis climático ERA5 y el NDVI mensual de Sentinel-2. Ambos se descartaron por una restricción de cómputo de la plataforma: calcular la mediana de miles de imágenes de Sentinel-2 o el promedio de 120 meses de ERA5 en decenas de miles de puntos excede el tiempo máximo que Google Earth Engine permite

por consulta. Se reemplazaron por capas precalculadas, que son además el estándar en modelado de distribución (Hijmans et al., 2005). Para los experimentos con información satelital se extrajeron también parches de cobertura de suelo de ESA WorldCover (Zanaga et al., 2021) y el *embedding* satelital anual de 64 dimensiones de Google (AlphaEarth Foundations, Brown et al., 2025). Este *embedding* es una representación numérica de cada píxel, aprendida por un modelo de fundación a partir de múltiples satélites, y se usó en su versión fija (2023) y pareada al año de cada observación (2017–2025). Para dibujar mapas de distribución se muestrearon las mismas covariables en una grilla regular de 0,1° (7910 celdas dentro de Chile continental).

Tabla 4.4: Covariables del modelo de distribución.

Covariable	Fuente	Resolución	Rango en el conjunto de datos
NDVI (media anual 2022)	MODIS MOD13A2 (Didan, 2021)	1 km	−0,15 a 0,89
Temperatura media anual	WorldClim v1 (bio01)	1 km	−1,4 a 19,9 °C
Precipitación anual	WorldClim v1 (bio12)	1 km	0 a 3866 mm
Elevación	SRTM (Farr et al., 2007)	30 m	−1 a 5104 m
Mes (seno, coseno)	fecha del registro	–	ciclo anual

4.6 Hallazgos del levantamiento y desviaciones del plan

4.6.1 Escasez de datos en las especies amenazadas

El hallazgo transversal del levantamiento es la asimetría de datos entre categorías de conservación. En audio, las 13 especies amenazadas reúnen el 5 % de las grabaciones chilenas (Tabla 4.2). En imagen, las dos únicas especies excluidas del clasificador por falta de fotografías son amenazadas, y las de menor conjunto de prueba también lo son. En avistamientos, las cinco especies con menos de 500 registros son amenazadas. Este patrón refleja un sesgo estructural de la ciencia ciudadana: se registra más lo que es más fácil de encontrar. Su implicancia es que un sistema de monitoreo orientado a conservación no puede diseñarse asumiendo abundancia de datos para las especies que más importa detectar. El censo aporta también la vía de mitigación: varias amenazadas de distribución amplia tienen mucho más audio fuera del país (*Calidris canutus* tiene 311 grabaciones globales y *Laterallus jamaicensis*, 181), lo que permitió entrenar con grabaciones de otras poblaciones y medir después el efecto del origen de la grabación (Sección 5.2).

4.6.2 Desviaciones respecto del plan

La Tabla 4.5 resume las diferencias entre la propuesta (Capítulos 1 a 3) y lo implementado, con su motivo. Corresponden a los riesgos del proyecto que se materializaron, todos detectados durante el levantamiento: acceso a datos restringidos, cómputo insuficiente y datos de menor calidad que la prevista. Ninguna altera las preguntas de investigación, y sus consecuencias se discuten en el Capítulo 6.

Tabla 4.5: Desviaciones entre lo planificado y lo implementado.

Planificado	Implementado	Motivo y consecuencia
Avistamientos de eBird (EBD) con esfuerzo y listas completas	Ocurrencias de GBIF (eBird + iNaturalist), sin esfuerzo	La EBD, solicitada en julio, no fue aprobada a tiempo. Sin esfuerzo, el sesgo de muestreo se corrige con fondo de grupo objetivo.
Clima ERA5 (Copernicus)	WorldClim v1 (bio01, bio12)	El muestreo de ERA5 en 35.000 puntos excede el cómputo de GEE. WorldClim es el estándar en SDM.
NDVI mensual de Sentinel-2 (10 m)	NDVI anual de MODIS (1 km) y *embeddings* satelitales anuales	Idéntica restricción de cómputo. La dimensión temporal se evaluó con el pareo anual del satélite.
EfficientNet y ViT a resolución completa (ConvNeXt o ViT-B preentrenados en ImageNet-21k, 384 px)	EfficientNet-B3 a 384 px (ImageNet y NoisyStudent) y ViT-S/16 a 224 px	Un ConvNeXt preentrenado en ImageNet-21k tardaba unas 8 horas por época en el equipo disponible y se descartó; ViT-B a 384 px resultó inviable por el mismo motivo. La variante pequeña ViT-S/16 sí se entrenó y quedó entre seis y ocho puntos por debajo de B3 según el protocolo (Sección 5.3).
Pérdida balanceada por número efectivo de muestras	Pesos inversos a la frecuencia ($\beta \to 1$) con suavizado de etiquetas y *mixup*	Caso límite de la misma familia. El desbalance del corpus es moderado (22 a 50 grabaciones).
Evaluación de audio solo sobre grabaciones chilenas	Conjunto de prueba mixto, con análisis por origen	Cuatro especies no tienen audio chileno. Se reporta el desempeño por origen de la grabación.
Validación espacial por bloques desde el inicio	Partición aleatoria en la comparación principal y validación por bloques como segundo protocolo	Se reportan ambos protocolos (Sección 5.6).

5 Resultados

Este capítulo reporta los resultados de las fases de modelado y evaluación. Sigue el orden de los objetivos específicos: los clasificadores de audio e imagen por separado (OE2), su fusión multimodal (OE2), los *baselines* de referencia (OE4), el modelo de distribución frente a MaxEnt (OE3) y el prototipo que integra los modelos. Cierra con una síntesis frente a los objetivos y las métricas de costo computacional (OE5). Los hiperparámetros completos están en el Apéndice B y las métricas por especie en el Apéndice C.

5.1 Protocolo experimental

Todos los experimentos usan PyTorch (Paszke et al., 2019), los modelos preentrenados de `timm` y Hugging Face, y los modelos clásicos de `scikit-learn`, con semilla fija en particiones y entrenamientos. Las métricas son las definidas en la Sección 3.11: *accuracy*, F1 macro y AUC-ROC para la identificación, y AUC-ROC por especie para la distribución. Se usan tres protocolos de evaluación, que la Sección 3.8 describe en detalle:

- **Audio: ventana única y agregado por grabación.** Los modelos de audio no clasifican la grabación entera sino ventanas cortas (5 s en la CNN, 10 s en el AST). En el protocolo de *ventana única* se clasifica solo la ventana central de cada grabación. En el protocolo *agregado* se clasifican hasta 12 ventanas de 5 s en la CNN (hasta 8 de 10 s en el AST) repartidas a lo largo de la grabación y se promedian sus probabilidades antes de decidir. El agregado es la métrica operacional, pues en uso real se clasifica la grabación entera. Los valores de ventana única de las tablas de este capítulo son los que entrega el *script* de entrenamiento sobre la ventana central de cada grabación.
- **Imagen: recorte central y TTA.** En el protocolo base la fotografía se reduce y se recorta un cuadrado central de 384 px, que es lo que ve el modelo. En la aumentación en tiempo de prueba (TTA) el modelo ve diez versiones de la misma fotografía (recortes de las cuatro esquinas y del centro, y sus reflejos horizontales) y se promedian las diez probabilidades, lo que suaviza errores debidos al encuadre.
- **Fusión: pareo por especie.** Como las grabaciones y las fotografías no corresponden a

los mismos individuos, cada grabación del conjunto de prueba de audio se empareja al azar con una fotografía del conjunto de prueba de imagen de la misma especie, 30 pares por especie, y las tres alternativas (solo audio, solo imagen, fusión) se evalúan sobre exactamente los mismos pares. El pareo se repite 20 veces con semillas distintas para medir su variabilidad.

Las métricas de los modelos del sistema y de los *baselines* se acompañan de intervalos de confianza al 95 % calculados por *bootstrap* sobre las muestras de prueba (Tabla 5.10, al final del capítulo), y las comparaciones entre modelos de distribución, de un test pareado por especie (Tabla 5.9).

5.2 Identificación por audio

5.2.1 Modelos entrenados

Se entrenaron dos modelos sobre las mismas particiones. El *baseline* es una CNN EfficientNet-B0 preentrenada en ImageNet, adaptada a un canal, que recibe el espectrograma log-mel de 128 bandas de una ventana de 5 s y se ajusta completa durante 100 épocas con AdamW. El modelo avanzado es el *Audio Spectrogram Transformer* preentrenado en AudioSet, ajustado durante 20 épocas sobre ventanas de 10 s remuestreadas a 16 kHz, que es la entrada que el modelo espera. Ambos usan entropía cruzada con pesos inversos a la frecuencia de cada clase y suavizado de etiquetas de 0,1. La CNN agrega las técnicas de regularización descritas en la Sección 3.3: *mixup*, SpecAugment con dos máscaras de tiempo y dos de frecuencia, ganancia aleatoria, ruido gaussiano, *dropout* de 0,3 y profundidad estocástica de 0,2 (omitir al azar bloques completos de la red durante el entrenamiento).

La regularización no fue un refinamiento menor. Para medir su efecto se entrenó una corrida de control con la misma arquitectura, datos, épocas y optimizador, pero sin aumentación, sin *mixup*, sin suavizado de etiquetas, sin *dropout* y sin profundidad estocástica. Sobreajustó con rapidez: la pérdida de entrenamiento cayó a 0,003 mientras la de validación tocó su mínimo (1,41) en la época 45 y luego subió hasta 1,6 y 1,7, y el conjunto de prueba dio 0,735 de *accuracy* por ventana y 0,789 agregado. Con la receta completa la pérdida de entrenamiento baja de forma gradual, de 4,0 a 1,2–1,4 en las últimas cuarenta épocas, y nunca se separa de la de validación, que sigue bajando hasta 1,47 (Figura 5.2); la prueba

sube a 0,812 por ventana y 0,858 agregado: siete puntos de *accuracy* agregada que se deben solo a la regularización. La Tabla 5.1 resume las dos corridas y la Figura 5.1 compara sus curvas de pérdida: sin regularización explícita la pérdida de entrenamiento se desploma mientras la de validación se estanca en torno a 1,5–1,7 desde la décima época (su mínimo de 1,41 en la época 45 queda dentro de esa oscilación), la firma clásica del sobreajuste. El AST converge en pocas épocas, como corresponde a un modelo preentrenado en audio: alcanza su mejor validación en la época 11 y después oscila.

Tabla 5.1: Efecto de la regularización en la CNN de audio: misma arquitectura, datos, épocas y optimizador, con y sin aumentación, *mixup*, suavizado de etiquetas, *dropout* y profundidad estocástica; ambas corridas conservan el decaimiento de pesos y la selección del mejor *checkpoint* en validación. Pérdidas al final de las 100 épocas; *accuracy* en prueba.

Corrida	Pérdida entren.	Pérdida valid.	*Accuracy* (ventana)	*Accuracy* (agregado)
Control (sin regularización explícita)	0,003	1,65	0,735	0,789
Receta completa	1,24	1,47	0,812	0,858

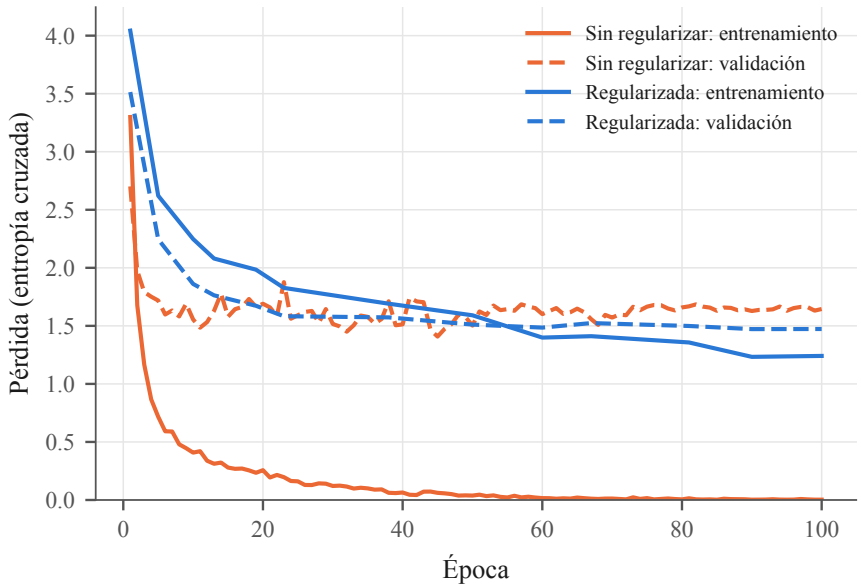


Figura 5.1: Pérdida de entrenamiento y de validación de la CNN de audio sin regularización y con la regularización completa. Sin regularización la red memoriza el conjunto de entrenamiento y la pérdida de validación deja de bajar; con regularización ambas curvas se mantienen cercanas.

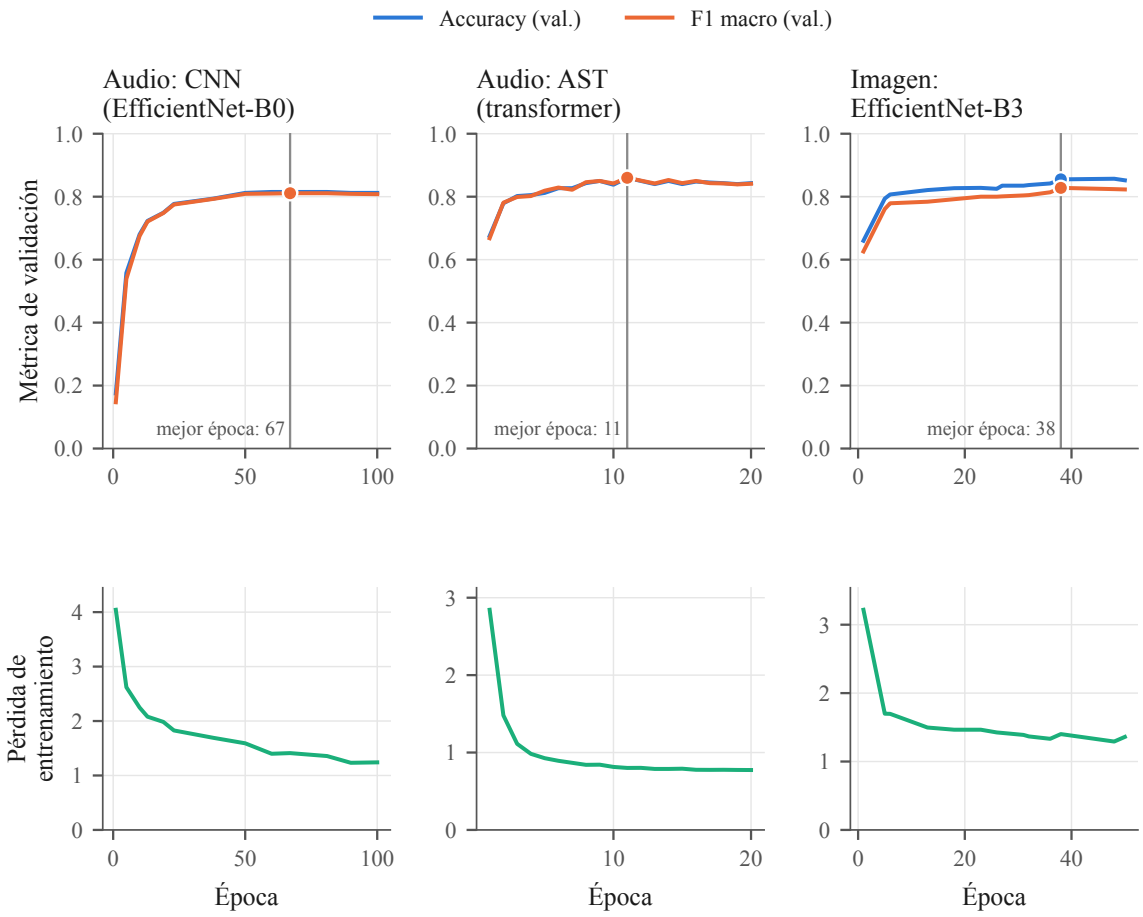


Figura 5.2: Curvas de entrenamiento de los tres clasificadores unimodales del sistema (CNN y AST de audio, EfficientNet-B3 de imagen): *accuracy* y F1 macro en validación (arriba) y pérdida de entrenamiento (abajo). La línea vertical marca la época del mejor *checkpoint*, que es el evaluado en prueba.

5.2.2 Desempeño global

La Tabla 5.2 y la Figura 5.3 resumen el desempeño en el conjunto de prueba (393 grabaciones, 55 especies). Ambos modelos superan la meta de 85 % de *accuracy* con el protocolo agregado y el AST supera a la CNN en los dos protocolos, con una diferencia de dos puntos por ventana que se reduce a uno al agregar. La agregación por grabación aporta entre 3,8 y 5,4 puntos sin reentrenar nada, porque promedia ventanas sin vocalización o con ruido con las que sí contienen al ave focal. Es la mitigación más barata del ruido de etiqueta de Xeno-canto descrito en el Capítulo 2. El costo del AST es alto: 86 millones de parámetros frente a 4 millones, y 480 segundos por época frente a 22, es decir, unas 20 veces más

cómputo para un punto adicional de *accuracy*.

Tabla 5.2: Clasificadores de audio en el conjunto de prueba (393 grabaciones, 55 especies). El protocolo agregado promedia las probabilidades de hasta 12 ventanas (CNN) u 8 (AST) de la grabación.

	Ventana única		Agregado			
Modelo	*Accuracy*	F1 macro	*Accuracy*	F1 macro	Parámetros	Tiempo/época
EfficientNet-B0 sin regularizar	0,735	0,736	0,789	0,784	4,1 M	22 s
EfficientNet-B0 regularizada	0,812	0,811	**0,858**	**0,858**	4,1 M	22 s
AST (AudioSet)	0,832	0,828	**0,870**	**0,864**	86,2 M	480 s

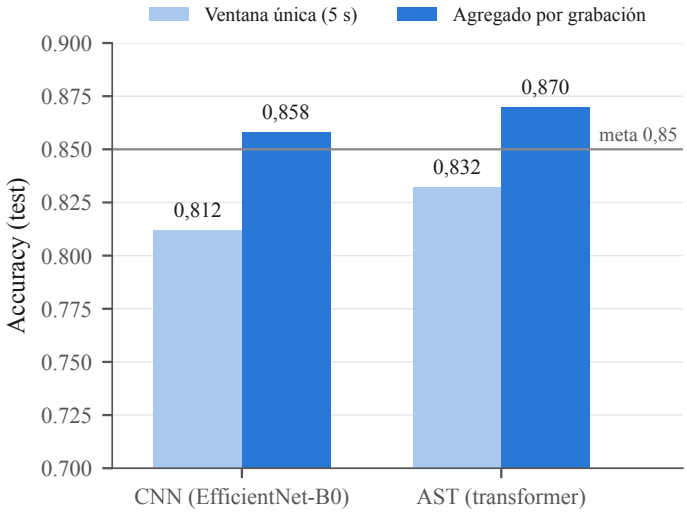


Figura 5.3: *Accuracy* en prueba de los clasificadores de audio con ventana única y con agregación por grabación.

La Tabla 5.3 completa la caracterización con las métricas que no dependen de un umbral de decisión. El AUC-ROC macro supera 0,99 en los tres clasificadores del sistema y la especie correcta está entre las cinco más probables en el 97 % de las grabaciones (CNN) y el 95 % de las fotografías, lo que importa para un uso asistido en que el sistema propone candidatas a un observador. La latencia mediana por grabación, incluido el cálculo del espectrograma, es de 18 ms para la CNN y 177 ms para el AST en la GPU del equipo. Una fotografía con TTA tarda 66 ms (11 ms con un solo recorte).

Origen de la grabación. Como el 36 % del corpus proviene de otros países, se evaluó por separado el desempeño sobre las 255 grabaciones chilenas y las 138 extranjeras del conjunto de prueba. La CNN obtiene 0,847 de *accuracy* en las chilenas y 0,877 en las

Tabla 5.3: Métricas extendidas de los clasificadores unimodales (solo audio o solo imagen) en el conjunto de prueba (protocolo operacional). AUC-ROC macro (cada especie frente a las demás); top-5: la especie correcta está entre las cinco más probables; latencia mediana por muestra en Apple M4 Pro (MPS), incluido el cálculo de características.

Modelo	*Accuracy*	F1 macro	AUC macro	Top-5	Parámetros	Latencia (ms)
Audio: CNN (agregado)	0,858	0,858	0,991	0,969	4,1 M	18
Audio: AST (agregado)	0,870	0,864	0,993	0,949	86,2 M	177
Imagen: B3 (TTA)	0,848	0,808	0,990	0,948	10,8 M	66

extranjeras (F1 macro 0,847 y 0,797). El AST obtiene 0,871 y 0,870. No hay, por tanto, una penalización sobre las grabaciones chilenas: el desplazamiento de dominio que se anticipó en el Capítulo 4 no se manifiesta en el conjunto de prueba, en parte porque las grabaciones extranjeras pertenecen a las mismas especies y a poblaciones vecinas (Argentina aporta la mitad de ellas) y en parte porque el modelo aprende rasgos del canto más que del ambiente de grabación.

5.2.3 Desempeño por especie y por grupo de conservación

La Figura 5.5 (panel izquierdo) muestra el F1 de la CNN por especie. Veintiséis especies superan 0,9 y solo ocho quedan bajo 0,7. La Figura 5.4 muestra en qué se equivoca el modelo y revela un patrón distinto del esperado: los errores de audio *no* se concentran en pares de congéneres. De los 56 errores de la CNN en las 393 grabaciones, solo tres ocurren entre especies del mismo género (*Phrygilus gayi* clasificado como *P. patagonicus*) y el resto se reparte en más de cuarenta pares distintos, casi todos con un único caso. Las especies de peor F1 (*Cinclodes patagonicus* con 0,46, y *Leptasthenura aegithaloides*, *Sylviorthorhynchus desmurii* y *P. gayi* con 0,62) fallan hacia una especie diferente en cada grabación, un patrón más compatible con el ruido de etiqueta de Xeno-canto (especies de fondo, tramos sin vocalización, llamados poco característicos) que con una similitud acústica sistemática. El AST comete 51 errores con la misma dispersión. El segundo factor es el *tamaño del conjunto de prueba*: *Agriornis albicauda* (0,50) tiene tres grabaciones de prueba, de modo que un solo error cuesta 33 puntos de *recall*. La variabilidad de BirdNET entre especies y contextos (Pérez-Granados, 2023) tiene aquí su contraparte: el desempeño por especie depende tanto de la calidad de las grabaciones disponibles como de la especie misma.

Contra lo que la escasez de datos haría esperar, las especies amenazadas obtienen en audio

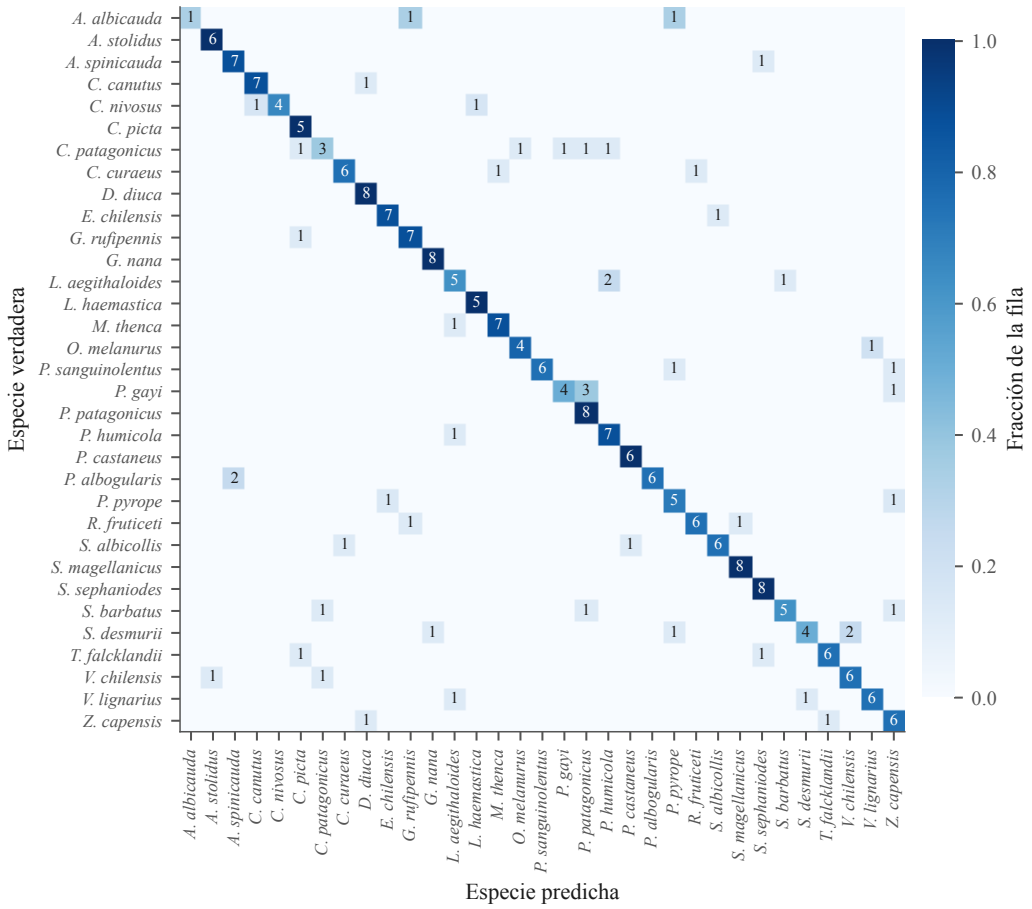


Figura 5.4: Matriz de confusión de la CNN de audio (conjunto de prueba, agregado por grabación) restringida a las especies con *recall* inferior a 0,8 y a las especies con que se confunden; el color indica la fracción de la fila y el número, las grabaciones. Los errores están dispersos: ningún par de especies acumula más de tres casos.

un F1 medio *mayor* que las comunes, 0,906 frente a 0,838 (Tabla 5.4). Dos factores lo explican. Las amenazadas del conjunto son en su mayoría aves acuáticas, playeros y loros, con vocalizaciones muy distintas de las de los paseriformes (el orden de las aves cantoras, al que pertenece la mayoría de las especies pequeñas del corpus), de modo que el problema *fine-grained* es más fácil para ellas. Además, sus conjuntos de prueba son pequeños, lo que hace sus métricas más altas pero también más inciertas. Las comunes, en cambio, concentran las especies de canto más variable y las grabaciones más heterogéneas. El AST reparte el desempeño de forma más pareja (F1 0,866, 0,896 y 0,857 en amenazadas, endémicas y comunes) y es el mejor modelo en las endémicas. El desafío de la escasez de datos se manifiesta, por tanto, menos en la métrica de prueba de las amenazadas que en su

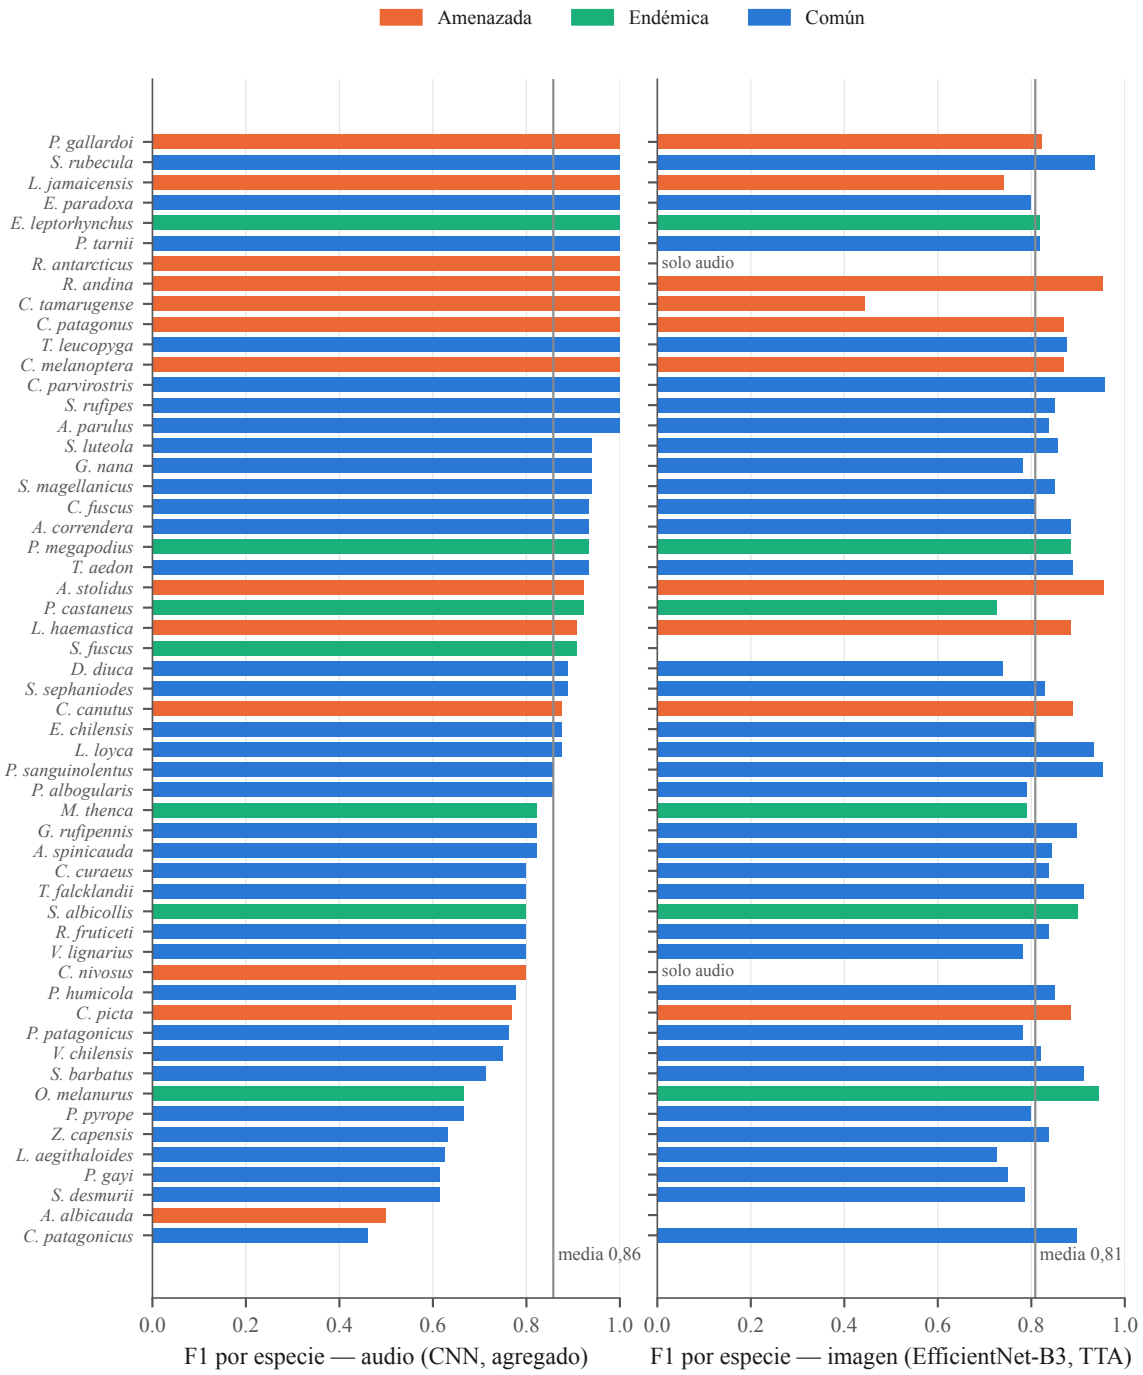


Figura 5.5: F1 por especie en el conjunto de prueba del clasificador de audio (CNN, agregado por grabación) y del clasificador de imagen (EfficientNet-B3 con TTA), coloreado por grupo de conservación y ordenado por el F1 de audio. Las dos especies sin fotografías suficientes no participan del clasificador de imagen.

variabilidad y en la dependencia de grabaciones extranjeras.

Tabla 5.4: Desempeño por grupo de conservación. F1 medio por especie en el conjunto de prueba (audio: CNN, agregado por grabación; imagen: EfficientNet-B3 con TTA; fusión: pareo por especie) y AUC-ROC medio del SDM.

Grupo	Especies	F1 audio	Especies	F1 imagen	F1 fusión	AUC MaxEnt	AUC RF
Amenazada	13	0,906	11	0,756	0,945	0,948	0,967
Endémica	7	0,865	7	0,723	0,940	0,899	0,917
Común	35	0,838	35	0,842	0,942	0,827	0,849
Todas	55	0,858	53	0,808	0,942	0,863	0,884

5.3 Identificación por imagen

Se ajustó EfficientNet-B3 preentrenada en ImageNet, con entrada de 384 px, durante 50 épocas con la misma receta de regularización (*mixup*, suavizado de etiquetas, *dropout*, profundidad estocástica) y aumentación geométrica y de color. Una variante con pesos NoisyStudent no mejoró la *accuracy* (0,845 frente a 0,848), aunque sí el F1 macro (0,820 frente a 0,808); se mantuvo la de ImageNet como rama del sistema por su mejor *accuracy* y porque la diferencia queda dentro del intervalo de confianza. Una arquitectura mayor (ConvNeXt preentrenada en ImageNet-21k) se descartó porque cada época tardaba unas ocho horas en el equipo disponible, y ViT-B a 384 px, comparable a ConvNeXt, era inviable por el mismo motivo. Sí se entrenó la variante pequeña de la familia, ViT-S/16 (21,7 M de parámetros, un cuarto de ViT-B; preentrenado en ImageNet-21k y ajustado en ImageNet-1k), a 224 px durante 30 épocas (unos 100 s por época) con la misma receta de regularización. Alcanzó 0,797 de *accuracy* en validación, todavía subiendo levemente al final, y 0,779 en prueba con recorte central (F1 macro 0,750), seis puntos por debajo de EfficientNet-B3 con el mismo protocolo (0,839) y ocho con TTA, que al ViT lo empeora (0,767), posiblemente porque sin la equivariancia de la convolución es más sensible al desplazamiento de los recortes de esquina. El resultado es compatible con lo esperado para un modelo con menos sesgos inductivos ajustado con unos pocos miles de fotografías (Sección 3.5), pero la comparación está confundida por la resolución (224 frente a 384 px) y el número de épocas, de modo que no permite concluir que la atención global no ayude (Sección 6.3). A esta escala y con este cómputo, B3 sigue siendo la rama de imagen del sistema. La Tabla 5.5 resume los resultados en las 1040 fotografías de prueba (53 especies).

Tabla 5.5: Clasificadores de imagen en el conjunto de prueba (1040 fotografías, 53 especies).

	Recorte central		TTA (10 vistas)		
Modelo	*Accuracy*	F1 macro	*Accuracy*	F1 macro	Parámetros
EfficientNet-B3 (ImageNet)	0,839	0,802	**0,848**	0,808	10,8 M
EfficientNet-B3 (NoisyStudent)	–	–	0,845	0,820	10,8 M
ViT-S/16 (ImageNet-21k, 224 px)	0,779	0,750	0,767	0,727	21,7 M

El clasificador de imagen queda dos milésimas bajo la meta de 0,85 cuando se evalúa solo. La curva de validación (Figura 5.2) muestra un *plateau* desde la época 36, de modo que más épocas no ayudan, y el techo está en las especies difíciles: en el panel derecho de la Figura 5.5, *Scytalopus fuscus* (F1 0,00, cinco fotografías de prueba) es visualmente casi idéntico a su congénere *S. magellanicus*, y *Agriornis albicauda* (0,00, dos fotografías) y *Conirostrum tamarugense* (0,44, tres) son las especies con menos ejemplos. Diez especies superan 0,9. A diferencia del audio, en imagen los errores sí se concentran en congéneres: el 13 % de los 158 errores ocurre dentro de un género, y los pares más frecuentes son *Phrygilus gayi* y *P. patagonicus* (nueve casos en ambos sentidos), los dos *Scytalopus*, *Pteroptochos castaneus* y *P. tarnii*, y los dos *Chloephaga*. También a diferencia del audio, aquí las amenazadas y endémicas rinden peor que las comunes, con F1 medio de 0,756 y 0,723 frente a 0,842 (Tabla 5.4): en imagen la escasez de ejemplos pesa más que la distintividad, porque un plumaje se parece a otro más de lo que un canto se parece a otro. Dado que la meta de 85 % se definió para el sistema multimodal, se aceptó este resultado como la rama visual del sistema. La sección siguiente muestra que la fusión la supera con amplitud.

5.4 Fusión multimodal

5.4.1 *Late fusion* frente a cada modalidad

La *late fusion* combina las probabilidades de la CNN de audio (55 clases, agregadas por grabación) y de EfficientNet-B3 (53 clases, proyectadas al espacio de 55 con probabilidad cero para las dos especies que solo tienen audio) con peso $\alpha = 0{,}5$ (Ecuación 3.16). Siguiendo el protocolo del Capítulo 3, el pareo por especie se repitió 20 veces con semillas distintas (30 pares por especie, 1590 pares por repetición, 53 especies) y se reportan la media y la desviación estándar (Tabla 5.6, Figura 5.6). Con la CNN como rama de audio, la

fusión alcanza **0,945** $\pm$ **0,004** de *accuracy* y 0,942 $\pm$ 0,004 de F1 macro, frente a 0,865 $\pm$ 0,008 del audio solo y 0,816 $\pm$ 0,009 de la imagen sola sobre los mismos pares: 8,0 puntos sobre la mejor modalidad y 12,9 sobre la imagen, con una variabilidad entre repeticiones diez veces menor que la ganancia (el pareo único usado durante el desarrollo había dado 0,950, dentro del rango). La meta del 85 % se supera con holgura y se confirma la hipótesis central del Módulo 1.

Tabla 5.6: *Late fusion* evaluada con pareo por especie repetido: media y desviación estándar sobre 20 repeticiones de 1590 pares (53 especies), para las dos ramas de audio disponibles.

Rama de audio	Modalidad	*Accuracy*	F1 macro
CNN (EfficientNet-B0)	Audio solo	0,865 $\pm$ 0,008	0,861 $\pm$ 0,009
CNN (EfficientNet-B0)	Imagen sola	0,816 $\pm$ 0,009	0,803 $\pm$ 0,009
CNN (EfficientNet-B0)	*Late fusion* ($\alpha = 0{,}5$)	0,945 $\pm$ 0,004	0,942 $\pm$ 0,004
CNN (EfficientNet-B0)	Mejor fusión ($\alpha = 0{,}5$, geométrica)	0,956 $\pm$ 0,004	0,954 $\pm$ 0,004
AST	Audio solo	0,877 $\pm$ 0,010	0,872 $\pm$ 0,010
AST	Imagen sola	0,816 $\pm$ 0,009	0,803 $\pm$ 0,009
AST	*Late fusion* ($\alpha = 0{,}5$)	0,946 $\pm$ 0,006	0,941 $\pm$ 0,006
AST	Mejor fusión ($\alpha = 0{,}5$, geométrica)	0,953 $\pm$ 0,005	0,948 $\pm$ 0,005

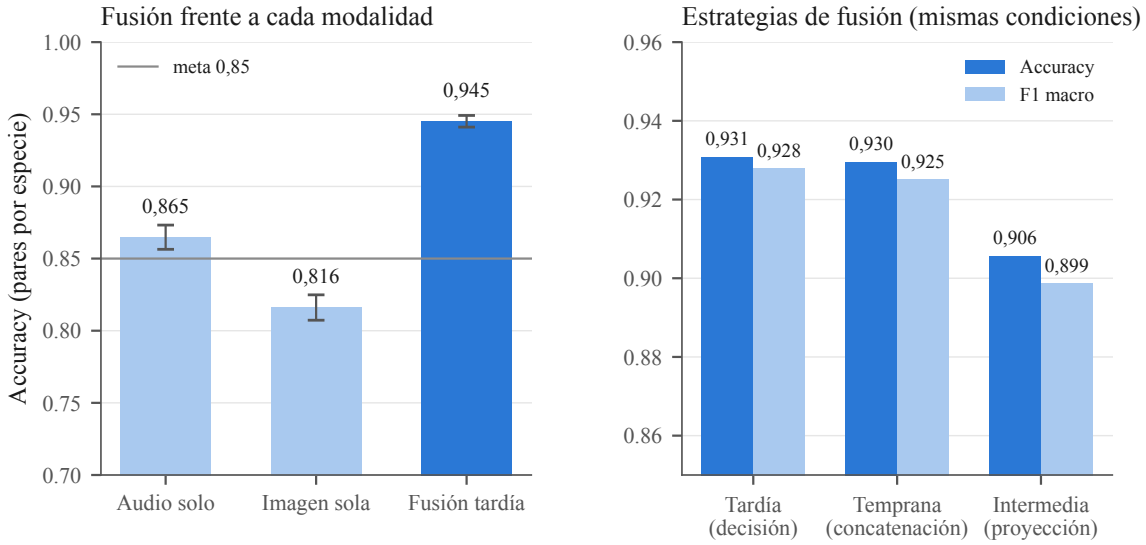


Figura 5.6: Fusión multimodal evaluada con pareo por especie (1590 pares, 53 especies). Izquierda: la *late fusion* frente a cada modalidad sobre los mismos pares (media de 20 repeticiones; las barras de error, apenas visibles, son la desviación estándar). Derecha: comparación controlada de tres estrategias de fusión con cabezas entrenadas sobre los *frozen embeddings* de ambos modelos.

El análisis de complementariedad explica la ganancia. En el 71,6 % de los pares ambas modalidades aciertan, en el 14,9 % solo el audio, en el 10,0 % solo la imagen y en el 3,5 %

ninguna. La fusión resuelve correctamente el 91,6 % de los pares en que las modalidades discrepan y no estropea ninguno en que ambas aciertan: su techo, si resolviera todas las discrepancias, sería 0,965, y alcanza 0,945. Cuando el audio confunde dos *Phrygilus*, la fotografía los separa. Cuando la imagen no distingue dos *Scytalopus*, el canto sí lo hace. El efecto es más visible por grupo de conservación (Tabla 5.4): la fusión lleva a las especies endémicas, las peores en imagen (F1 0,723) y medianas en audio (0,865), a 0,940, y deja a los tres grupos entre 0,94 y 0,95. Con ello borra la desventaja de las especies con menos datos.

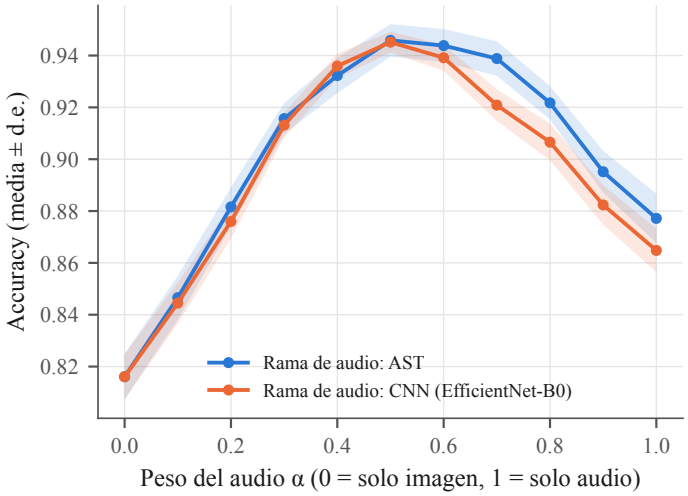


Figura 5.7: Sensibilidad de la *late fusion* al peso del audio α (media aritmética de probabilidades), con la CNN o el AST como rama de audio; banda: desviación estándar sobre 20 repeticiones del pareo.

La Figura 5.7 muestra la sensibilidad al peso α. La curva es unimodal con máximo en $\alpha = 0{,}5$ y una meseta entre 0,4 y 0,6, y es asimétrica a favor del audio: con $\alpha = 0{,}7$ la fusión todavía supera 0,92, mientras que con $\alpha = 0{,}3$ cae a 0,91. La media geométrica de probabilidades (producto de expertos) mejora un punto sobre la aritmética (0,956 $\pm$ 0,004) porque penaliza las clases que una modalidad descarta con seguridad. Reemplazar la CNN por el AST en la rama de audio, pese a sus 1,2 puntos adicionales en solitario (0,877 $\pm$ 0,010), no cambia la fusión (0,946 $\pm$ 0,006): la ganancia proviene de la complementariedad, no de la fuerza de cada rama. En síntesis, el sistema final usa la CNN como rama de audio y *late fusion* con $\alpha = 0{,}5$, que alcanza 0,945 $\pm$ 0,004 de *accuracy* (intervalo de confianza al 95 % de 0,924 a 0,959). La variante con media geométrica es la de mayor precisión observada (0,956 $\pm$ 0,004, con intervalo de 0,937 a 0,972). El sistema conserva la media

aritmética por dos razones: los intervalos de confianza de ambas variantes se solapan, y la media geométrica anula cualquier especie a la que una rama asigne probabilidad cero, lo que ocurre con las dos especies que solo tienen audio cuando la rama de imagen se proyecta de 53 a 55 clases. La diferencia entre usar la CNN o el AST como rama de audio (0,001) es menor que una desviación estándar, de modo que no justifica un modelo veinte veces más costoso.

5.4.2 Comparación de estrategias de fusión

Para aislar el efecto de la arquitectura de fusión se compararon las tres estrategias de la taxonomía de Baltrušaitis et al. (2019) en condiciones idénticas: los mismos *backbones* ya entrenados, congelados como extractores de características (1 280 dimensiones de audio y 1 536 de imagen), los mismos pares por especie (150 de entrenamiento y 30 de prueba por especie) y cabezas con la misma configuración (40 épocas, tasa de aprendizaje 10^{-3}, lotes de 64). La *late fusion* entrena una cabeza lineal por modalidad y promedia sus probabilidades. La *early fusion* concatena los dos *embeddings* a la entrada de una única cabeza, y la *intermediate fusion* proyecta cada modalidad a un espacio común de 256 dimensiones antes de concatenar. El panel derecho de la Figura 5.6 muestra el resultado: la *late fusion* (0,931) y la *early fusion* (0,930) empatan y la *intermediate fusion* queda por debajo (0,906). Las proyecciones por modalidad agregan parámetros que sobreajustan con los pares disponibles, y como los *embeddings* ya son representaciones de alto nivel, la transformación adicional no aporta. El resultado respalda la elección de la *late fusion* para el sistema final, que además es robusta a modalidades faltantes. (El 0,945 de la subsección anterior promedia los *softmax* de los modelos completos, sin cabeza adicional, por lo que es algo superior a las cabezas entrenadas sobre *frozen embeddings*.)

5.5 *Baselines* de referencia

Dos referencias sitúan el aporte de los modelos ajustados. La primera es la de “bajo costo”: un clasificador lineal sobre los *frozen embeddings* de un modelo preentrenado, siguiendo el protocolo de Ghani et al. (2023), con regresión logística multinomial y el parámetro de regularización elegido en validación. Se usaron tres extractores sin ajustar: EfficientNet-B0 de ImageNet sobre el espectrograma log-mel, el AST de AudioSet (salida de 768 dimensiones) y EfficientNet-B3 de ImageNet sobre la fotografía. La segunda referencia es

un *modelo de IA generativa multimodal* (Claude, Anthropic; Anthropic, 2026) consultado mediante la API con cada fotografía del conjunto de prueba y la lista cerrada de las 53 especies candidatas, en modo *zero-shot* (solo la lista) y *few-shot* (una fotografía de referencia por especie, tomada del conjunto de entrenamiento). La respuesta se restringe a un nombre de la lista mediante salida estructurada, de modo que el protocolo de métricas es el mismo del clasificador propio.

Tabla 5.7: *Baselines* de referencia frente a los modelos ajustados (conjuntos de prueba). *Frozen embeddings*: regresión logística sobre las representaciones de un modelo preentrenado sin ajustar. IA generativa: modelo de IA generativa multimodal consultado con la fotografía y la lista cerrada de especies.

Modalidad	Método	*Accuracy*	F1 macro	AUC macro
Audio	*Frozen embeddings* de EfficientNet-B0 (ImageNet) + regresión logística	0,547	0,545	0,901
Audio	*Frozen embeddings* de AST (AudioSet) + regresión logística	0,784	0,769	0,980
Imagen	*Frozen embeddings* de EfficientNet-B3 (ImageNet) + regresión logística	0,775	0,760	0,985
Imagen	IA generativa (claude-opus-5-5, *zero-shot*, esfuerzo *low*)	0,803	0,765	–
Imagen	IA generativa (claude-opus-5-5, *few-shot*, esfuerzo *low*)	0,817	0,779	–
Audio	**CNN EfficientNet-B0 ajustada (este trabajo)**	0,858	0,858	0,991
Audio	**AST ajustado (este trabajo)**	0,870	0,864	0,993
Imagen	**EfficientNet-B3 ajustada + TTA (este trabajo)**	0,848	0,808	0,990

***Frozen embeddings*.** Sobre el espectrograma, las características de EfficientNet-B0 preentrenada en ImageNet, sin ajuste, llegan solo a 0,547 de *accuracy* (Tabla 5.7): las representaciones de imágenes naturales describen mal un espectrograma, y el ajuste completo aporta 31 puntos. El AST preentrenado en AudioSet, un modelo de audio general, transfiere mucho mejor (0,784 con una regresión logística) y el ajuste agrega 8,6 puntos. El orden entre ambos extractores reproduce el hallazgo de Ghani et al. (2023) de que el preentrenamiento en el dominio correcto importa más que la arquitectura. En imagen, EfficientNet-B3 congelada da 0,775 y el ajuste suma 7,3 puntos. En las tres ramas el AUC-ROC de la referencia congelada es alto (0,90 a 0,99): el ordenamiento de candidatas es razonable sin ajustar, pero la decisión final no lo es.

IA generativa. Claude Opus 5.5 identifica correctamente el 80,3 % de las 1040 fotografías de prueba en *zero-shot* (F1 macro 0,765), 4,5 puntos por debajo de EfficientNet-B3 ajustada

(0,848 de *accuracy* y 0,808 de F1) y 14 por debajo de la fusión multimodal. Cuatro fotografías fueron rechazadas por un error de formato (archivos PNG con extensión JPEG, corregido en las corridas posteriores) y cuentan como errores. La brecha entre su *accuracy* y su F1 macro se explica por cómo promedia cada métrica: la *accuracy* cuenta aciertos sobre las 1040 fotografías, donde pesan las especies comunes con 22 fotografías de prueba, mientras que el F1 macro promedia el F1 de cada especie por igual, de modo que las endémicas y las especies con dos o tres fotografías, donde el modelo falla, pesan tanto como las comunes bien resueltas. El perfil por grupo es revelador: el modelo generativo es excelente en las especies amenazadas (F1 0,839 y 93 % de acierto), que son aves acuáticas, playeros y loros abundantemente fotografiados en todo el mundo, y competente en las comunes (0,795), pero falla en las endémicas (F1 0,498 y 56 % de acierto): confunde sistemáticamente los tapaculos chilenos (turca 0,42, tapaculo 0,31, hued-hued castaño 0,36, churrín del norte 0,25) y la chiricoca (0,40), especies que el clasificador propio resuelve con F1 de 0,73 a 0,94. El modelo de IA generativa conoce las aves que el mundo fotografía y no las que solo Chile tiene, que son justamente el foco de este trabajo. Supera al clasificador especializado en 23 especies y pierde en 28. Su confianza declarada es informativa (0,79 en los aciertos frente a 0,48 en los errores), lo que permitiría abstenerse en los casos dudosos. El costo fue de US$2,19 por el conjunto completo (0,2 centavos por fotografía), con una latencia mediana de 2,4 s por consulta frente a 66 ms del clasificador propio en un equipo portátil.

En modo *few-shot*, con una fotografía de referencia por especie servida desde la caché de *prompts*, el modelo sube a 0,817 de *accuracy* y 0,779 de F1 macro, sin respuestas inválidas. La mejora se concentra donde faltaba conocimiento: las endémicas pasan de 0,498 a 0,567 de F1 (de 56 % a 71 % de acierto), con ganancias de 14 a 27 puntos en la chiricoca, la turca y el tapaculo, mientras que las amenazadas no cambian (0,837) y las comunes apenas (0,804). Una sola fotografía de referencia cierra alrededor de un quinto de la brecha de las endémicas respecto del clasificador propio, que sigue ganando en 29 especies frente a 23, y el costo sube a US$4,27 por el conjunto (0,4 centavos por fotografía) con 2,7 s de latencia. La Figura 5.8 resume el antes y el después por grupo. Ni en *zero-shot* ni en *few-shot* el modelo generativo alcanza a la rama de imagen ajustada con 4980 fotografías, y ambos quedan 13 puntos por debajo de la fusión multimodal. La comparación responde el OE4 y, de paso, justifica entrenar modelos propios para las especies que importan a la conservación local.

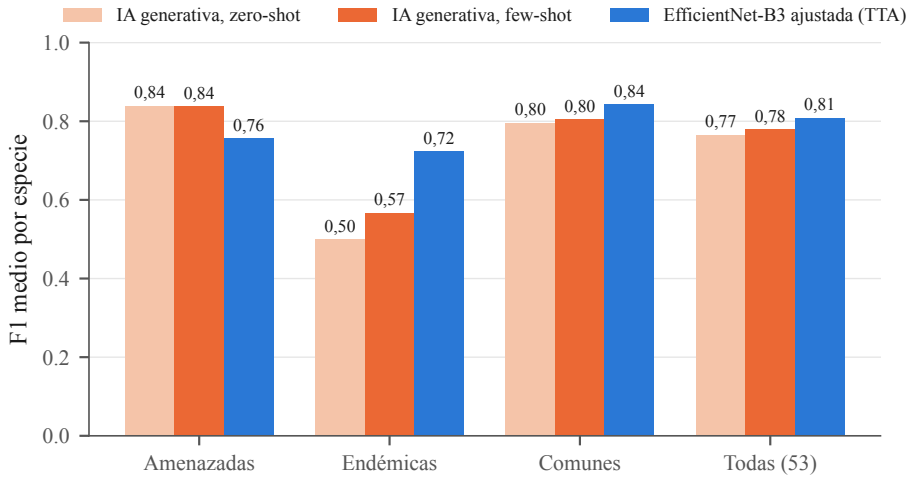


Figura 5.8: F1 medio por grupo de conservación del modelo generativo en *zero-shot* y *few-shot*, frente al clasificador de imagen ajustado. La fotografía de referencia mejora sobre todo a las endémicas, sin cerrar la brecha con el modelo propio.

5.6 Modelo de distribución espaciotemporal

5.6.1 Modelos comparados

Sobre el conjunto de datos de la Sección 4.5 (presencias de cada especie frente a 1500 puntos de fondo de grupo objetivo, muestreados con la misma semilla para todos los modelos) se compararon cuatro alternativas, cuyas bases se presentan en la Sección 3.10:

- **MaxEnt** (*baseline*): regresión logística penalizada con características lineales y cuadráticas y clases balanceadas, aprovechando la equivalencia entre MaxEnt y los modelos de regresión para datos de solo presencia (Fithian y Hastie, 2013).
- **Red neuronal conjunta**: el perceptrón multicapa multiespecie con dos capas ocultas de 64 unidades, *dropout* de 0,3 y un *embedding* de especie de 8 dimensiones, entrenado con entropía cruzada binaria ponderada durante 40 épocas sobre todas las especies a la vez.
- **Random Forest**: 300 árboles con clases balanceadas.
- **Gradient boosting**: 300 iteraciones con tasa de aprendizaje 0,05 y clases balanceadas.

Todos usan las seis covariables (NDVI, temperatura, precipitación, elevación y el mes cíclico) y se evalúan por especie con AUC-ROC sobre una partición estratificada 70/30.

Tabla 5.8: Modelos de distribución comparados: AUC-ROC medio sobre las 54 especies con al menos 20 presencias y número de especies en que cada modelo supera a MaxEnt. Partición aleatoria estratificada 70/30 y validación cruzada espacial por bloques de 200 km (5 *folds*).

Modelo	AUC (aleatoria)	Gana a MaxEnt	AUC (espacial)	Gana a MaxEnt
MaxEnt (regresión logística penalizada)	0,863	–	0,816	–
Red neuronal conjunta	0,856	15/54	0,810	21/54
Gradient boosting	0,883	44/54	0,803	16/54
Random Forest	0,884	46/54	0,812	17/54

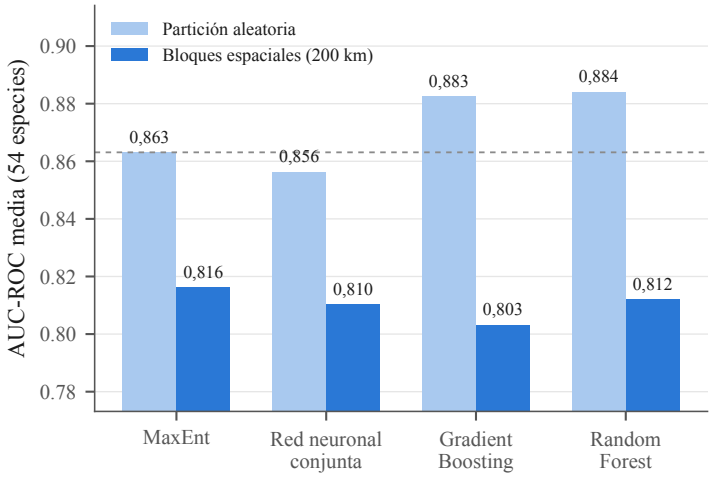


Figura 5.9: AUC-ROC medio de los modelos de distribución sobre las 54 especies modeladas. La línea punteada marca el *baseline* MaxEnt.

El resultado (Tabla 5.8, Figura 5.9) contradice la hipótesis original en su forma literal y la confirma en su espíritu. La red neuronal *no* supera a MaxEnt: obtiene 0,856 de AUC medio frente a 0,863 y solo gana en 15 de las 54 especies. Los ensambles de árboles, en cambio, superan a MaxEnt con claridad: Random Forest alcanza 0,884 y gana en 46 de 54 especies, y gradient boosting 0,883 con 44 victorias. La mejora media de Random Forest sobre MaxEnt es de 0,021 (intervalo de confianza al 95 % de 0,015 a 0,027 y $p < 0{,}001$ en un test de Wilcoxon pareado por especie), con casos de hasta siete puntos (*Vanellus chilensis* pasa de 0,725 a 0,795 y *Limosa haemastica* de 0,871 a 0,943) y ocho especies en que MaxEnt conserva una ventaja pequeña (Figura 5.10). La desventaja de la red neuronal también es sistemática aunque pequeña (0,007 con $p = 0{,}001$). El patrón es coherente con la evidencia de que, en datos tabulares de tamaño moderado, los modelos de árboles siguen superando a las redes neuronales (Grinsztajn et al., 2022) y con los *benchmarks* de SDM, donde los árboles potenciados y los ensambles figuran entre los mejores métodos.

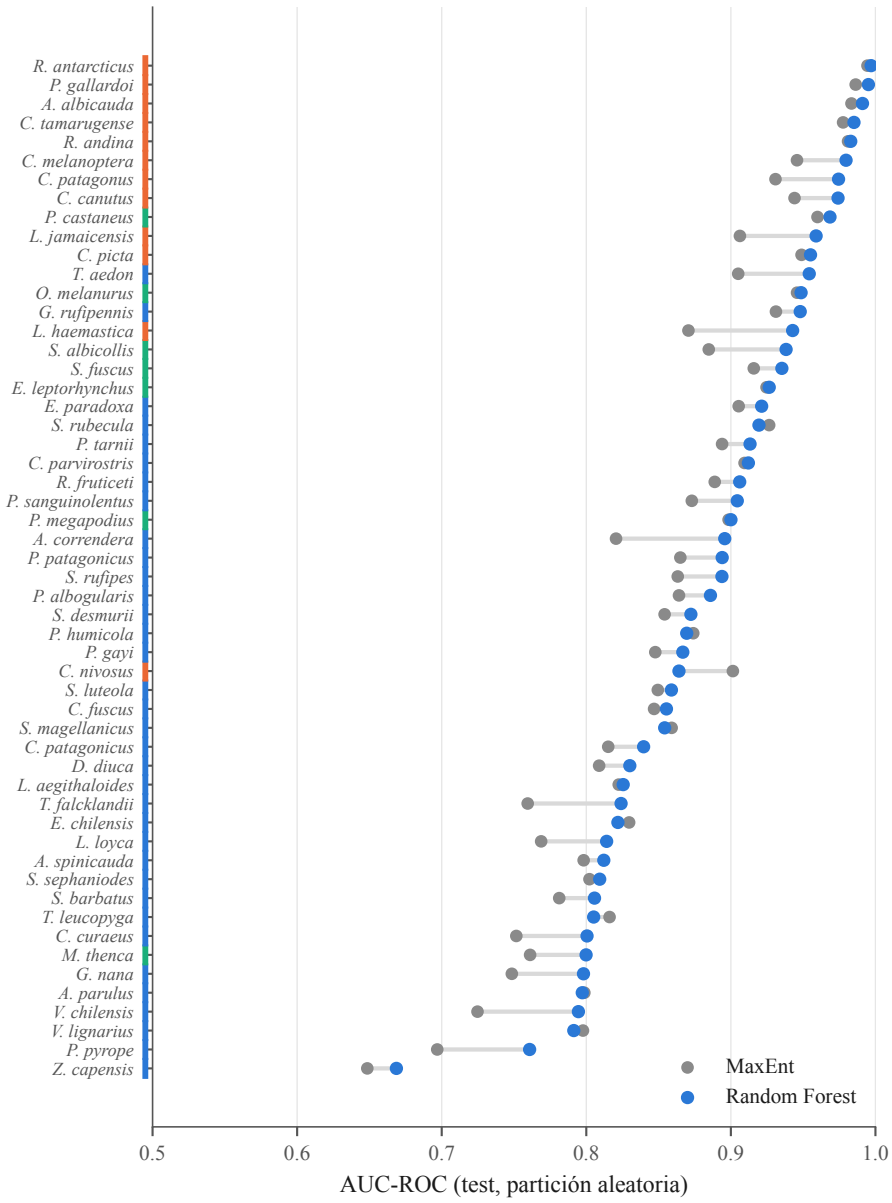


Figura 5.10: AUC-ROC por especie de MaxEnt y Random Forest (partición aleatoria), ordenadas por el valor de Random Forest; la franja de color indica el grupo de conservación.

El desempeño por especie depende sobre todo de la amplitud de su distribución. Las especies de rango restringido se modelan casi perfectamente (*Rallus antarcticus* 0,997, *Podiceps gallardoi* 0,995, *Agriornis albicauda* 0,991), mientras que los generalistas ubicuos son los más difíciles (*Zonotrichia capensis* 0,669, *Pyrope pyrope* 0,761): cuando una especie está en todas partes, el fondo de grupo objetivo se parece a sus presencias y las covariables no pueden separarlos. Por eso, al contrario del clasificador de imagen, aquí las especies

amenazadas obtienen el AUC más alto, 0,967 con Random Forest frente a 0,849 de las comunes (Tabla 5.4): la escasez de registros no impide modelarlas, porque sus pocos registros son ambientalmente muy informativos.

5.6.2 ¿Aportan los datos satelitales no estructurados?

Para dar al aprendizaje profundo una ventaja que MaxEnt no puede aprovechar, se probaron dos fuentes de información satelital no estructurada (Figura 5.11, panel izquierdo). Con parches de cobertura de suelo de 3 km procesados por una CNN junto a las covariables, la red cayó a 0,613 de AUC, y con el *embedding* satelital de 64 dimensiones de AlphaEarth, a 0,767. Se verificó que los parches estaban correctamente alineados, de modo que la degradación no es un error de datos sino sobreajuste: la cobertura de suelo es redundante con el NDVI y la elevación (bosque donde el NDVI es alto, suelo desnudo donde es bajo o la altitud es alta) y la capacidad adicional de la red solo agrega varianza. La prueba definitiva es que el *embedding* también perjudica a los árboles, que son robustos a características irrelevantes: Random Forest baja de 0,884 a 0,878 (una caída pequeña pero consistente en 44 de 54 especies, $p < 0{,}001$) y gradient boosting de 0,883 a 0,881.

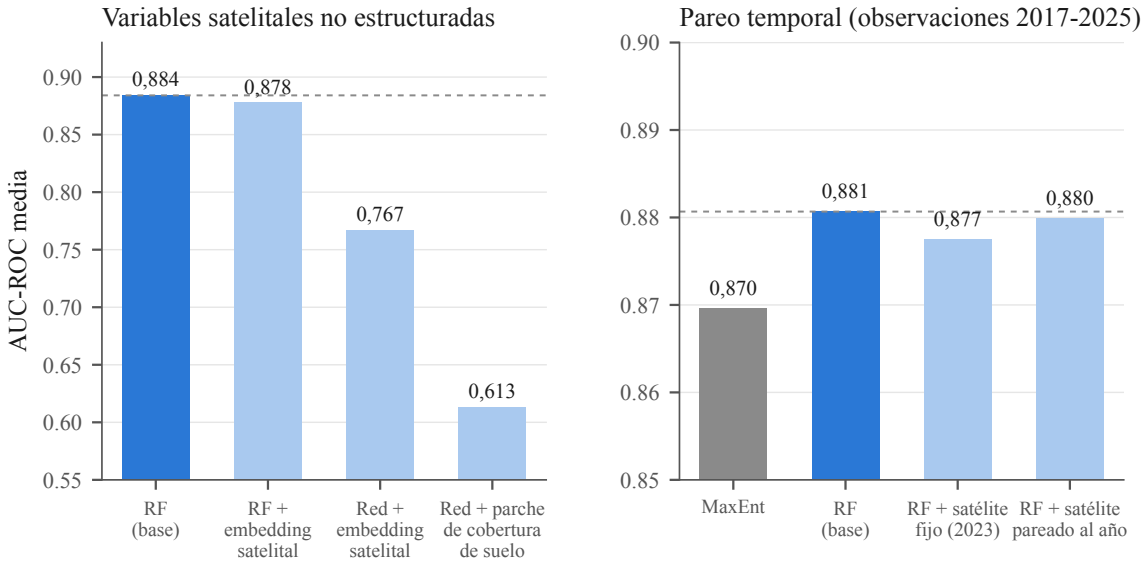


Figura 5.11: Experimentos con información satelital. Izquierda: AUC-ROC medio al agregar el *embedding* satelital o parches de cobertura de suelo a las covariables base. Derecha: pareo temporal del *embedding* satelital al año de cada observación, sobre el subconjunto 2017–2025 (53 especies).

Quedaba una explicación alternativa: el desajuste temporal entre la imagen satelital (un

compuesto fijo de 2023) y observaciones de cualquier año. Para descartarla se repitió el experimento sobre las observaciones de 2017 a 2025, pareando a cada punto el NDVI y el *embedding* del año en que fue observado (panel derecho de la Figura 5.11). El pareo ayuda marginalmente respecto del compuesto fijo (0,880 frente a 0,877 y mejor en 32 de 53 especies, $p = 0{,}010$), lo que confirma que el desajuste existía, pero ninguna versión supera a las covariables base sin satélite (0,881): la diferencia entre el satélite pareado y la base es $-0{,}001$ con un intervalo de confianza de $-0{,}005$ a $+0{,}003$ ($p = 0{,}89$), es decir, indistinguible de cero (Tabla 5.9; el test se hace sobre Random Forest, el mejor modelo del bloque). El desajuste temporal era un factor menor. La causa es la redundancia.

5.6.3 Validación espacial por bloques

Para comprobar que la comparación anterior no está inflada por la autocorrelación espacial, se repitió con validación cruzada por bloques, siguiendo el protocolo de `blockCV` (Valavi et al., 2019). Los semivariogramas empíricos de las covariables dan rangos de autocorrelación de 650 km (NDVI, precipitación) a 1200 km (temperatura, elevación), consecuencia del gradiente latitudinal de Chile. Bloques de ese tamaño dejarían entre cuatro y seis en todo el país, de modo que se usaron bloques de 200 km (46 bloques), asignados al azar a cinco *folds* equilibrados en número de registros: de 10 700 a 17 400 filas por *fold* del conjunto apilado por especie (presencias más los 1 500 puntos de fondo de cada especie, que se repiten entre especies), equivalentes a entre unos 5 800 y 8 900 de los 34 926 puntos distintos. Cada modelo se entrena en cuatro *folds* y se evalúa en el quinto, con los mismos puntos y el mismo fondo que la partición aleatoria. En 13 especies de rango restringido, cuyas presencias caen en pocos bloques, solo dos a cuatro *folds* tienen presencias suficientes para calcular el AUC.

El resultado (Tabla 5.8, Figura 5.9) cambia la lectura. Todos los modelos caen entre cinco y ocho puntos al extrapolar a bloques no vistos (MaxEnt de 0,863 a 0,816, Random Forest de 0,884 a 0,812, gradient boosting a 0,803 y la red a 0,810) y las diferencias entre ellos quedan dentro de la variabilidad entre *folds* (desviación estándar media de 0,06). Random Forest supera a MaxEnt en solo 17 de las 54 especies, la diferencia media es de $-0{,}004$ con un intervalo de confianza que incluye el cero (de $-0{,}013$ a $+0{,}004$, con $p = 0{,}06$) y en 21 especies es menor que 0,01. Por grupo, los árboles conservan ventaja en las especies amenazadas (0,901 frente a 0,883) y la pierden en las comunes (0,779 frente a 0,788) y endémicas (0,823 frente a 0,845). La ventaja de los ensambles de árboles es, por tanto,

una ventaja de *interpolación*: con registros en todo el territorio aprovechan interacciones locales entre covariables que MaxEnt no modela, pero al predecir en zonas sin registros las funciones de respuesta suaves de MaxEnt generalizan igual o mejor. Para la pregunta de investigación esto significa que el aprendizaje automático supera a MaxEnt en el uso habitual de un SDM (describir la distribución donde hay datos), pero no al extrapolar a regiones sin muestreo, que es el escenario que la validación por bloques simula y el más exigente. La Tabla 5.9 reúne todas las comparaciones pareadas de este capítulo.

Tabla 5.9: Comparaciones pareadas por especie entre modelos de distribución: diferencia media de AUC-ROC con intervalo *bootstrap* al 95 %, número de especies en que el primer modelo supera al segundo y valor *p* del test de Wilcoxon de rangos con signo (bilateral).

Protocolo	Comparación	*n*	ΔAUC [IC 95 %]	Gana	*p*
aleatoria	Random Forest vs. MaxEnt	54	0,021 [0,015; 0,027]	46/54	<0,001
aleatoria	Gradient boosting vs. MaxEnt	54	0,019 [0,012; 0,026]	44/54	<0,001
aleatoria	Red neuronal vs. MaxEnt	54	-0,007 [-0,011; -0,003]	15/54	0,001
aleatoria	RF + *embedding* satelital vs. RF	54	-0,006 [-0,009; -0,004]	10/54	<0,001
espacial	Random Forest vs. MaxEnt	54	-0,004 [-0,012; 0,004]	17/54	0,060
espacial	Gradient boosting vs. MaxEnt	54	-0,013 [-0,022; -0,004]	16/54	0,003
espacial	Red neuronal vs. MaxEnt	54	-0,006 [-0,012; 0,000]	21/54	0,044
temporal 2017-2025	RF vs. MaxEnt	53	0,011 [0,005; 0,017]	38/53	<0,001
temporal 2017-2025	RF + satélite fijo vs. RF	53	-0,003 [-0,007; 0,000]	21/53	0,069
temporal 2017-2025	RF + satélite pareado vs. RF	53	-0,001 [-0,005; 0,003]	28/53	0,891
temporal 2017-2025	RF + satélite pareado vs. fijo	53	0,002 [0,001; 0,004]	32/53	0,010

5.6.4 Mapas de distribución estimada

La Figura 5.12 muestra la probabilidad de presencia estimada por Random Forest sobre la grilla de 0,1° para tres especies de distribución contrastante: el chucao, propio del bosque templado lluvioso del sur; el tricahue (EN), confinado a los valles del centro-norte; y el comesebo de los tamarugales (EN), restringido a la Pampa del Tamarugal. En los tres casos el mapa reproduce el rango conocido y los avistamientos caen en las zonas de alta probabilidad, sin que el modelo haya recibido las coordenadas como covariable: la distribución emerge del clima, la vegetación y la elevación. La Figura 5.13 ilustra el eje temporal con el zarapito de pico recto (VU), un playero migratorio que pasa el verano austral en Chile: el modelo asigna alta probabilidad a los humedales del sur en enero y la reduce en julio, cuando la especie está en el hemisferio norte, aunque con la salvedad de que la mitad de los registros se concentra en verano por el propio esfuerzo de observación.

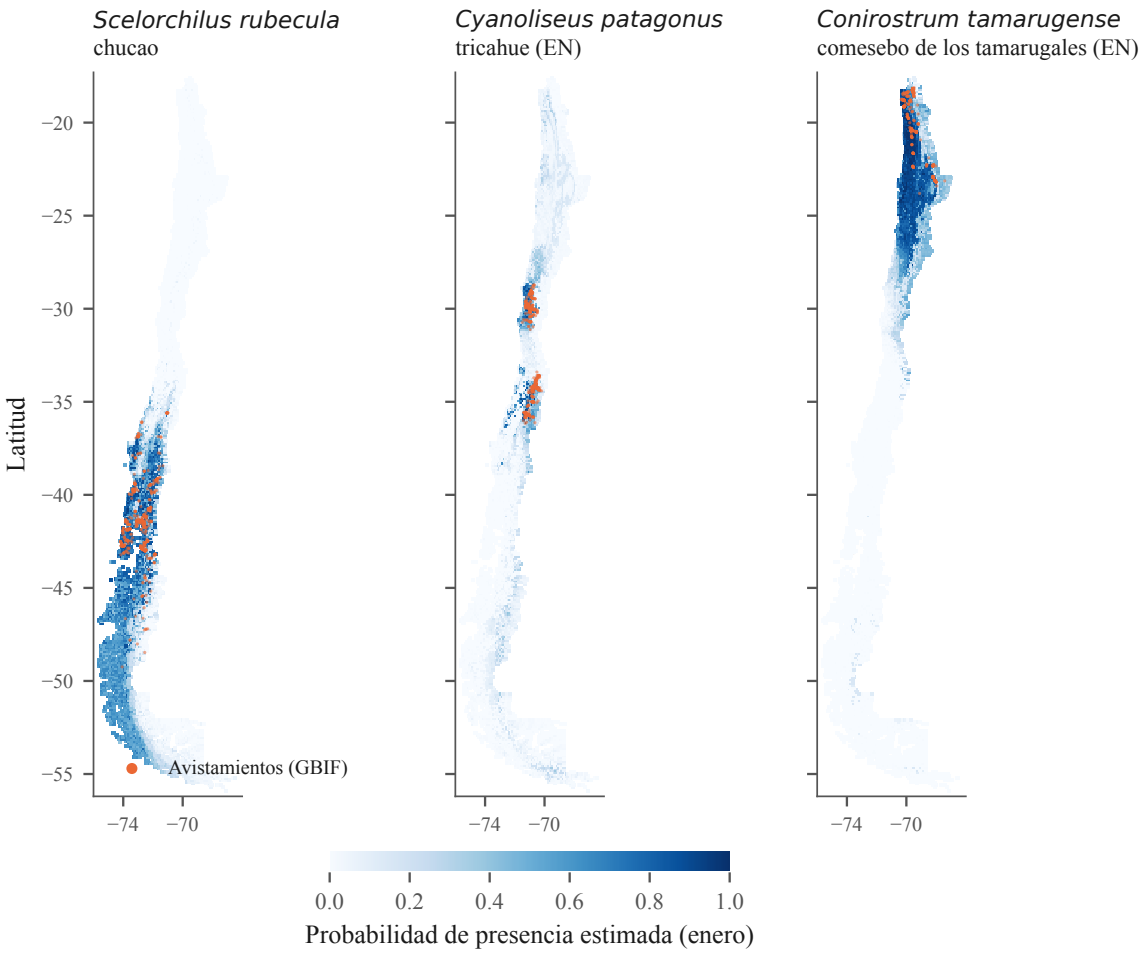


Figura 5.12: Probabilidad de presencia en enero estimada por Random Forest para tres especies de distribución contrastante, con una muestra de sus avistamientos superpuesta.

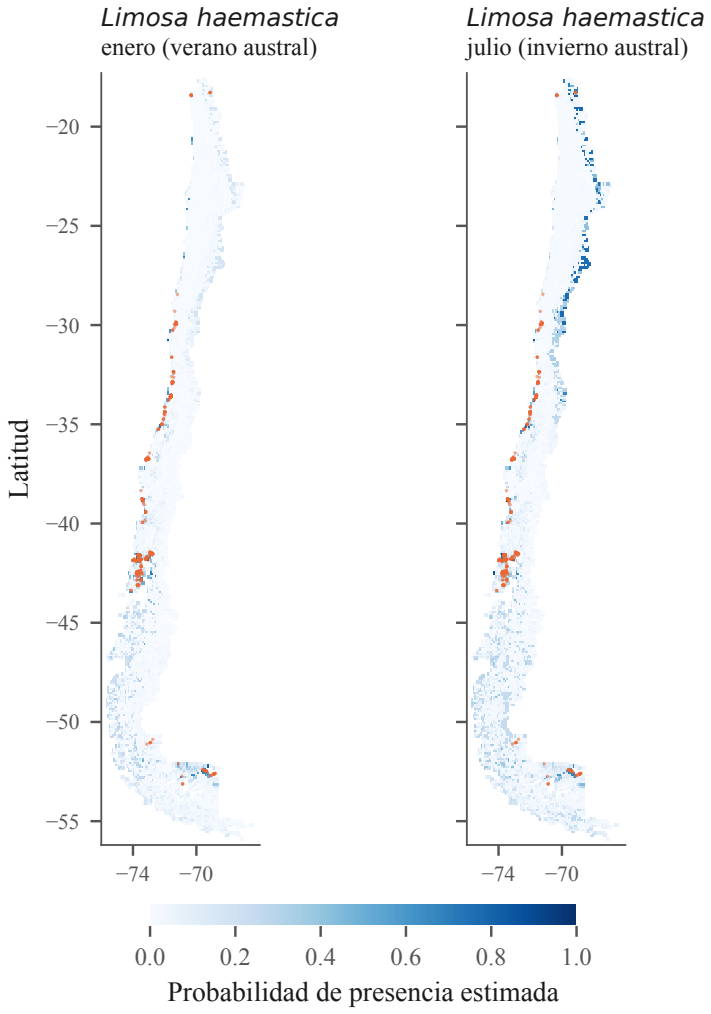


Figura 5.13: Eje temporal del modelo: probabilidad de presencia estimada para *Limosa haemastica* en enero y en julio.

5.7 Prototipo integrado

Los tres modelos se integraron en un prototipo web construido con Streamlit. El usuario sube una grabación y/o una fotografía. El sistema calcula las probabilidades de cada rama disponible, las fusiona si hay ambas, muestra las cinco especies más probables con su confianza y su categoría de conservación, y dibuja sobre un mapa interactivo la distribución estimada de la especie identificada para el mes elegido, usando los Random Forest por especie entrenados con todos los datos y la grilla de covariables precalculada. La inferencia completa tarda unos segundos en CPU. El prototipo cumple el papel de "despliegue" de CRISP-DM en su forma mínima: demuestra que los módulos funcionan juntos de extremo a extremo con entradas reales, aunque no es un servicio productivo (Capítulo 6).

5.8 Síntesis frente a los objetivos

La Tabla 5.11 resume el estado de cada objetivo específico, la Tabla 5.10 reúne los intervalos de confianza de las métricas principales y la Tabla 5.12 el costo computacional de los modelos, que completa la documentación que pide el OE5.

Tabla 5.10: Intervalos de confianza al 95 % de las métricas principales de identificación. *Bootstrap* percentil con 2000 remuestreos de las muestras de prueba (fusión: 300 remuestreos estratificados por especie de grabaciones y fotografías, con el pareo recalculado); los *baselines* de *frozen embeddings* usan el intervalo normal de una proporción.

Modelo	n	*Accuracy* [IC 95 %]	F1 macro [IC 95 %]
Audio: CNN EfficientNet-B0 (agregado)	393	0,858 [0,822; 0,891]	0,858 [0,804; 0,880]
Audio: AST (agregado)	393	0,870 [0,837; 0,903]	0,864 [0,811; 0,889]
Imagen: EfficientNet-B3 (TTA)	1040	0,848 [0,826; 0,869]	0,808 [0,779; 0,827]
IA generativa *zero-shot*	1040	0,803 [0,779; 0,828]	0,765 [0,733; 0,787]
IA generativa *few-shot*	1040	0,817 [0,793; 0,840]	0,779 [0,748; 0,801]
Frozen embeddings: EfficientNet-B0 (ImageNet)	393	0,547 [0,498; 0,596]	0,545
Frozen embeddings: AST (AudioSet)	393	0,784 [0,743; 0,824]	0,769
Frozen embeddings: EfficientNet-B3 (ImageNet)	1040	0,775 [0,750; 0,800]	0,760
Pareo: audio solo	1590	0,861 [0,827; 0,893]	–
Pareo: imagen sola	1590	0,819 [0,792; 0,847]	–
Pareo: *late fusion* ($\alpha = 0{,}5$)	1590	0,942 [0,924; 0,959]	–
Pareo: *late fusion* geométrica	1590	0,955 [0,937; 0,972]	–

Tabla 5.11: Cumplimiento de los objetivos específicos.

Objetivo	Resultado	Estado
OE1 Conjunto de datos reproducible	Tres corpus (2508 grabaciones, 7060 fotografías, 100.270 registros) con particiones sin fuga y *scripts* reanudables	Cumplido
OE2 Clasificadores y fusión, *accuracy* $>$ 85 % en $\geq$ 50 especies	Audio 0,858 (CNN) y 0,870 (AST) sobre 55 especies; imagen 0,848; fusión 0,945 $\pm$ 0,004 sobre 53 especies	Cumplido
OE3 SDM frente a MaxEnt	Random Forest 0,884 $>$ MaxEnt 0,863 (46/54 especies) con partición aleatoria; bajo validación espacial todos los modelos empatan (0,80–0,82); la red neuronal no supera a MaxEnt en ningún protocolo	Cumplido (hallazgo matizado)
OE4 Comparación con IA generativa	*Zero-shot* 0,803 y *few-shot* 0,817, frente a 0,848 del clasificador propio y 0,945 de la fusión; falla en las endémicas	Cumplido
OE5 Documentación de desempeño y limitaciones	Métricas, costo computacional, análisis por especie, grupo y origen; limitaciones en el Capítulo 6	Cumplido

Tabla 5.12: Costo computacional de los modelos en Apple M4 Pro (MPS). El ViT-S/16 se entrenó solo como comparación.

Modelo	Parámetros	Entrenamiento (total)	Épocas	Inferencia (mediana)
Audio: EfficientNet-B0	4,1 M	22 s/época (37 min)	100	18 ms por grabación
Audio: AST	86,2 M	480 s/época (2,7 h)	20	177 ms por grabación
Imagen: EfficientNet-B3	10,8 M	250–500 s/época (3,5–7 h)	50	66 ms por foto (TTA)
Imagen: ViT-S/16 (224 px)	21,7 M	101 s/época (50 min)	30	–
SDM: Random Forest	300 árboles/especie	segundos por especie	–	$<$1 s por mapa
SDM: red conjunta	$\approx$ 5600	$\approx$ 1 min	40	–

6 Conclusiones, desafíos y trabajo futuro

6.1 Respuesta a las preguntas de investigación

PI1. ¿Puede un sistema multimodal identificar aves chilenas mejor que los clasificadores unimodales (solo audio o solo imagen) y que un modelo de IA generativa multimodal? Sí, en ambas comparaciones. La *late fusion* de audio e imagen alcanza 0,945 $\pm$ 0,004 de *accuracy* sobre 53 especies (intervalo de confianza al 95 % de 0,924 a 0,959), 8,0 puntos más que el mejor clasificador unimodal sobre los mismos pares y casi 10 sobre la meta comprometida, y lo hace con datos no emparejados de ciencia ciudadana, un escenario que la literatura previa no había explorado. Cada modalidad por separado también cumple o roza la meta: audio 0,858 (CNN) y 0,870 (AST) sobre 55 especies, imagen 0,848 sobre 53. Frente al modelo de IA generativa multimodal, el sistema especializado gana con claridad: Claude Opus 5.5 alcanza 0,803 en *zero-shot* y 0,817 en *few-shot* sobre las mismas fotografías, 3 a 4,5 puntos menos que la rama de imagen y 13 menos que la fusión, y falla precisamente en las especies endémicas chilenas (F1 0,498 y 0,567 frente a 0,940 de la fusión).

PI2. ¿Puede un SDM basado en aprendizaje automático superar a MaxEnt? Sí, pero no con redes neuronales. Random Forest y gradient boosting superan a MaxEnt en AUC-ROC (0,884 y 0,883 frente a 0,863) en 46 y 44 de las 54 especies, mientras que la red neuronal conjunta queda por debajo (0,856) y la incorporación de parches de cobertura de suelo y *embeddings* de imágenes satelitales de un modelo fundacional degrada a todos los modelos. La hipótesis "aprendizaje profundo $>$ MaxEnt" se refuta con evidencia. La hipótesis "aprendizaje automático $>$ MaxEnt" se confirma con un método más simple, pero con una condición importante: bajo validación espacial por bloques, que mide la extrapolación a zonas sin registros, todos los modelos caen a 0,80–0,82 y ninguno supera a MaxEnt. El aprendizaje automático gana al interpolar, no al extrapolar.

PI3. ¿Cómo afecta la escasez de datos de las especies amenazadas y qué estrategias la mitigan? De forma distinta en cada módulo. En imagen, donde los plumajes de congéneres se parecen, las especies con menos fotografías son las que fallan (F1 medio 0,756 en amenazadas frente a 0,842 en comunes) y dos quedaron fuera del clasificador. En audio, la

escasez se mitigó con grabaciones de otras poblaciones, aumentación en el espectrograma y pesos por clase, y las amenazadas rinden incluso mejor que las comunes (0,906 frente a 0,838) porque sus vocalizaciones son distintivas. El precio es la dependencia de audio extranjero y conjuntos de prueba de tres a ocho grabaciones. En distribución, los pocos registros de las especies de rango restringido bastan para modelarlas casi perfectamente (AUC 0,967). La fusión multimodal es, en sí misma, la mitigación más efectiva: cubre las especies que una modalidad no puede clasificar y corrige los errores de la otra.

6.2 Discusión

Por qué funciona la fusión. La complementariedad no es casual. El audio separa especies por estructura temporal y espectral del canto, que en aves es un carácter de reconocimiento de especie. La imagen separa por forma y plumaje. Los pares que confunde una modalidad (*Cinclodes* y *Phrygilus* en audio, *Scytalopus* en imagen) son distintos de los que confunde la otra, y la *late fusion* solo necesita que una de las dos esté segura. Que la *late fusion* y la *early fusion* empaten y la *intermediate fusion* pierda indica que, con *backbones* fuertes y pocos pares, lo simple gana: la forma más barata de combinar evidencia es también la mejor, y la *late fusion* tiene la ventaja de operar con una sola modalidad.

Por qué los árboles ganan al aprendizaje profundo en el SDM. El problema de distribución, tal como se formuló, es tabular: seis covariables y unos cientos de presencias por especie. En ese régimen los ensambles de árboles tienen sesgos inductivos adecuados (invariancia a la escala de las variables, fronteras de decisión irregulares, robustez a variables irrelevantes) y las redes necesitan más datos o regularización (Grinsztajn et al., 2022). La red conjunta comparte información entre especies, pero esa ventaja no compensa la pérdida frente a 300 árboles por especie. Los experimentos satelitales muestran además que la señal ambiental relevante ya está en las covariables clásicas: el NDVI, el clima y la elevación resumen lo que la cobertura de suelo y el *embedding* satelital repiten con más ruido. Y la validación espacial agrega un matiz: la ventaja de los árboles es de interpolación. Al extrapolar a zonas sin registros, la respuesta suave y regularizada de MaxEnt generaliza igual de bien. Este resultado es informativo para la práctica: con buenas covariables, un Random Forest es la elección razonable para describir la distribución donde hay datos, MaxEnt sigue siendo tan bueno como cualquiera para proyectarla a zonas sin muestreo, y la complejidad adicional debe justificarse con una ganancia medida, no supuesta.

El valor de la agregación y de los protocolos operacionales. La métrica por ventana única subestima el desempeño real en cuatro puntos. Evaluar como se usará el sistema (la grabación completa, la fotografía con TTA, el par audio-imagen) no solo da números más altos sino más honestos respecto del caso de uso. Lo mismo vale para la comparación de costo: el AST mejora un punto a la CNN con veinte veces el cómputo, una diferencia que decide qué modelo conviene desplegar en un dispositivo de campo.

Relación con la literatura. La ganancia de la fusión coincide con lo observado en SSW60, donde combinar audio e imagen supera a cada modalidad (Van Horn et al., 2022), y la extiende a datos no emparejados de ciencia ciudadana. En distribución, el resultado es coherente con el *benchmark* de Valavi et al. (2022), donde MaxEnt y los ensambles de árboles quedan entre los mejores métodos con diferencias pequeñas, y con la advertencia de Roberts et al. (2017): la partición aleatoria sobreestima el desempeño cuando los datos tienen estructura espacial, aquí entre cinco y ocho puntos de AUC. Por último, el desempeño de la rama de audio sobre especies chilenas, frente a la cobertura moderada de BirdNET en Sudamérica (Funosas et al., 2026), respalda la estrategia de entrenar clasificadores regionales con datos locales, aunque las dos evaluaciones no son directamente comparables.

6.3 Desafíos y limitaciones

1. **Evaluación de la fusión con pares sintéticos.** Los pares audio-imagen se construyen entre individuos distintos de la misma especie. El protocolo mide la ganancia de combinar evidencia, que es el caso de uso previsto, pero no captura correlaciones entre el canto y la apariencia de un mismo individuo ni condiciones de campo donde ambas señales se degradan a la vez (un ave lejana, grabada y fotografiada con ruido).

2. **Conjuntos de prueba pequeños para las especies raras.** Con tres grabaciones o dos fotografías de prueba, el F1 de una especie amenazada puede oscilar entre 0 y 1 por un solo ejemplo. Las métricas globales son robustas (la repetición del pareo da una desviación estándar de 0,004 en la fusión), pero las de especies individuales con pocos datos deben leerse como indicativas: el F1 mínimo dentro del grupo de amenazadas baja a 0,48 por una sola especie con dos fotografías.

3. **Origen de las grabaciones.** El 36 % del audio proviene de otros países y cuatro especies no tienen audio chileno. El conjunto de prueba es mixto. El análisis por origen no muestra penalización (la CNN obtiene 0,847 en las grabaciones chilenas y 0,877 en

las extranjeras, mientras que el AST obtiene 0,871 y 0,870), pero la limitación persiste en otro sentido: cuatro especies solo pueden evaluarse con audio extranjero, y nada garantiza ese desempeño sobre paisajes sonoros grabados en terreno en Chile.

4. **Sesgos de los registros de presencia.** Los avistamientos de GBIF carecen de esfuerzo de observación, se concentran en 2024–2026 y en el verano austral, y siguen la geografía de los observadores. El fondo de grupo objetivo corrige el sesgo espacial, pero la estacionalidad aprendida por el modelo mezcla fenología con esfuerzo, y el tope de 2000 registros por especie descarta historia útil.

5. **Validación espacial.** La comparación principal del SDM usa una partición aleatoria, optimista ante la autocorrelación espacial. La validación por bloques cuantifica esa diferencia: entre cinco y ocho puntos de AUC, y borra la ventaja de los árboles. Por eso ambos protocolos se reportan juntos y la conclusión sobre el SDM se formula con esa salvedad.

6. **Covariables estáticas.** WorldClim y el NDVI medio anual describen el clima y la vegetación promedio, no el año ni el mes de cada observación. El pareo anual del *embedding* satelital mostró que ese desajuste pesa poco, pero una serie temporal de NDVI a mayor resolución sigue siendo la vía natural para un modelo verdaderamente espaciotemporal.

7. **Anotación débil de Xeno-canto.** Cada grabación lleva una especie focal, pero puede contener otras de fondo y tramos sin vocalización. La agregación por grabación mitiga el efecto, pero no lo elimina, y las ventanas de entrenamiento siguen siendo ruidosas.

8. **Cómputo local.** Las arquitecturas de imagen más fuertes (ConvNeXt y ViT-B con preentrenamiento en ImageNet-21k a 384 px) quedaron fuera porque su tiempo de entrenamiento era inviable en el equipo; el ViT-S/16 que sí se entrenó, a 224 px, quedó entre seis y ocho puntos por debajo de EfficientNet-B3 según el protocolo, de modo que sigue abierta la pregunta de si la atención global ayuda con mayor resolución y más cómputo; con GPU dedicada es probable que la rama de imagen mejore. El AST, por su parte, se entrenó con lotes de 8 por la misma restricción.

9. **Comparación con el modelo generativo.** El resultado depende del modelo y la versión consultados, del *prompt* y de que las fotografías de iNaturalist puedan haber formado parte de su entrenamiento. Se reporta como referencia, no como *benchmark* estable.

6.4 Aspectos éticos

El proyecto no involucra personas ni datos personales, por lo que no requirió la aprobación de un comité de ética. Aun así, el uso de datos de ciencia ciudadana y la publicación de modelos sobre especies amenazadas plantean cuatro consideraciones.

Origen y licencias de los datos. Todas las fuentes son públicas y se usaron según sus condiciones. Las grabaciones de Xeno-canto y las fotografías de iNaturalist llevan licencias Creative Commons elegidas por sus autores y se emplearon solo para entrenar y evaluar modelos, sin redistribuirlas. Los registros de eBird e iNaturalist se obtuvieron de GBIF y se citan con el identificador de cada conjunto (Levatich y Ligocki, 2026; iNaturalist contributors, 2026). Las capas ambientales (WorldClim, MODIS, SRTM, WorldCover) son de acceso abierto. De cada registro se usan solo la especie, las coordenadas y la fecha; no se procesa la identidad de los observadores, y las plataformas ya ofuscan las localidades de las especies que consideran sensibles antes de publicarlas.

Riesgo de mal uso. Un mapa de probabilidad de presencia de una especie amenazada puede orientar su captura o su tráfico; los loros, como el tricahue, son el caso más conocido en Chile. Tres decisiones acotan ese riesgo. Los mapas se calculan sobre una grilla de $0{,}1^\circ$ (unos 10 km) y describen la idoneidad del hábitat, no la ubicación de individuos ni de nidos. El prototipo no muestra ni entrega los registros individuales que alimentan los modelos. Y en un despliegue público los mapas de las especies más sensibles deberían publicarse a menor resolución o restringirse a instituciones de conservación, como hacen eBird e iNaturalist con sus datos sensibles.

Decisiones automatizadas. El clasificador se equivoca más en las especies con pocos datos y confunde congéneres de plumaje o canto parecidos (Secciones 5.2 y 5.3). Si sus predicciones alimentaran una base de datos sin revisión, introducirían registros falsos justamente en las especies que más importan. Por eso el sistema se plantea como apoyo a la identificación experta: el prototipo muestra las especies candidatas con su probabilidad en lugar de una etiqueta única, y cualquier uso para registros oficiales debe pasar por validación humana.

Sesgos de los datos. Los registros ciudadanos siguen a los observadores: se concentran en la zona central, en verano y en los últimos años (Sección 6.3). Un modelo entrenado con ellos describe mejor las zonas visitadas que las remotas, y las prioridades de monitoreo que se deriven de sus mapas podrían reforzar ese sesgo. El fondo de grupo objetivo y la validación

por bloques lo acotan y lo cuantifican, pero no lo eliminan, y así debe leerse cualquier mapa del sistema. Por último, las fotografías enviadas al modelo generativo comercial son públicas y con licencia abierta, y no se envió información sobre los observadores.

6.5 Lecciones aprendidas y recomendaciones

Más allá de los resultados, el proyecto deja lecciones que pueden servir a otros estudiantes del programa.

- **Pedir los datos restringidos el primer día.** La base histórica de eBird se solicitó en julio y no llegó a tiempo, lo que obligó a reemplazar las no detecciones reales por pseudoausencias. Un acceso que depende de terceros debe gestionarse al inicio y con un plan alternativo.
- **Fijar los *baselines* y el protocolo de evaluación antes de entrenar.** Decidir de antemano contra qué se compara el sistema (MaxEnt, *frozen embeddings*, un modelo generativo) y cómo se mide (ventana única o agregado, recorte central o TTA, pareo por especie) evitó ajustar la vara después de ver los resultados.
- **Evaluar como se usará el sistema.** La métrica por ventana única subestimaba el desempeño en cuatro puntos; la grabación completa, la fotografía con TTA y el par audio-imagen son los escenarios reales de uso.
- **Validar espacialmente desde el inicio.** La partición aleatoria daba a los árboles una ventaja de dos puntos sobre MaxEnt que la validación por bloques borró. Con datos georreferenciados, la validación espacial debe ser el protocolo por defecto y no una comprobación final.
- **No presuponer que el aprendizaje profundo gana.** En datos tabulares la red neuronal perdió frente a Random Forest y frente a MaxEnt. La complejidad de un modelo se justifica con una ganancia medida.
- **Medir el costo junto con la métrica.** El AST gana un punto a la CNN con veinte veces el cómputo; sin ese dato la decisión de despliegue sería otra.
- **Automatizar el levantamiento.** Un *pipeline* de *scripts* reanudables permitió rehacer corpus y experimentos muchas veces sin perder trabajo, y es lo que hace reproducible este informe.

Qué haría distinto: solicitar la base de eBird en marzo, entrenar la rama de imagen en la nube desde el inicio para probar arquitecturas mayores, y organizar al menos una campaña de grabación en terreno para las especies amenazadas con poco audio chileno.

6.6 Trabajo futuro

- **Datos para las especies amenazadas.** Solicitar la base histórica de eBird (EBD) con esfuerzo y listas completas, que permite no detecciones reales en lugar de pseudoausencias. Organizar campañas de grabación dirigidas a las trece amenazadas. Explorar *embeddings* bioacústicos de modelos entrenados en aves (BirdNET, Perch) con clasificadores de pocos ejemplos (Ghani et al., 2023) para las especies bajo el umbral de inclusión.
- **Transformers de visión y rama de imagen en la nube.** Entrenar en la nube ConvNeXt o ViT-B con preentrenamiento en ImageNet-21k y mayor resolución (el ViT-S/16 a 224 px entrenado aquí quedó por debajo de la CNN), para comprobar si la imagen sola supera el 85 % y si la atención global ayuda en las especies de plumaje casi idéntico. Incorporar TTA en la rama visual de la fusión.
- **SDM verdaderamente temporal.** Series de NDVI mensuales de Sentinel-2 o MODIS exportadas de forma asíncrona desde GEE, variables climáticas del año de observación y validación por bloques espaciales y temporales como protocolo por defecto. También cuantificar la incertidumbre de los mapas (por ejemplo, con la varianza entre árboles).
- **Monitoreo acústico pasivo.** Evaluar los clasificadores sobre paisajes sonoros continuos grabados en terreno, con solapamiento de especies y relación señal-ruido baja, que es el escenario de BirdCLEF (Kahl et al., 2023), y adaptar el umbral de decisión por especie.
- **Despliegue.** Llevar el prototipo a un servicio estable con modelos cuantizados (la CNN de 4 millones de parámetros es candidata a correr en dispositivos de campo), registro de las predicciones y retroalimentación de expertos para reentrenar.

6.7 Conclusión general

Este trabajo construyó y evaluó un sistema de monitoreo de biodiversidad aviar para Chile continental que integra la identificación multimodal de especies con el modelado de su distribución, a partir exclusivamente de fuentes públicas de ciencia ciudadana y

teledetección. Sus resultados principales son cuatro. Primero, la fusión de audio e imagen identifica 53 especies con 0,95 de *accuracy*, superando con amplitud la meta del 85 %, a cada modalidad por separado y a un modelo de IA generativa multimodal, lo que valida la hipótesis multimodal con datos no emparejados. Segundo, Random Forest y gradient boosting superan a MaxEnt en la estimación de distribución con partición aleatoria, pero no al extrapolar a zonas sin registros, donde todos los modelos empatan. Ni las redes neuronales ni los parches de cobertura de suelo ni los *embeddings* de imágenes satelitales aportan, un resultado negativo bien fundamentado que orienta la práctica. Tercero, el levantamiento cuantificó la escasez estructural de datos de las especies amenazadas chilenas y mostró qué estrategias la mitigan en cada modalidad. Cuarto, todo el proceso quedó en un repositorio reproducible y público (https://github.com/sebastianvidal92/biomonitor-aviar), con *scripts* reanudables y un prototipo que integra los modelos, que puede extenderse a otras especies y regiones. Una última lección cruza los dos módulos. El aprendizaje profundo fue imprescindible donde los datos no tienen estructura tabular: el canto y la fotografía solo pueden clasificarse aprendiendo representaciones a partir de la señal cruda, y ahí las redes preentrenadas y su ajuste fino hicieron la diferencia (31 puntos sobre una regresión logística con rasgos congelados en audio). Pero cuando los datos ya vienen como una tabla de covariables ambientales, la estadística clásica sigue siendo muy valiosa. MaxEnt, que en el fondo es una regresión logística regularizada, obtiene un AUC competitivo (0,863 frente a 0,884 de Random Forest), empata o gana al extrapolar a zonas sin registros y entrega algo que los ensambles y las redes no dan con la misma claridad: coeficientes interpretables que dicen cómo responde cada especie a la temperatura, la precipitación o la vegetación, y supuestos explícitos que pueden discutirse con un ecólogo. La elección del método debe seguir a la naturaleza de los datos y al uso que se dará al modelo, no a la moda. El sistema no reemplaza al ornitólogo en terreno, pero ofrece una herramienta concreta para procesar el volumen creciente de registros ciudadanos y para priorizar dónde y cuándo mirar.

Referencias

Anthropic (2026). Claude Opus 5.5: modelo de lenguaje multimodal. API de Anthropic, https://www.anthropic.com. Consultado en octubre de 2026.

Baltrušaitis, T., Ahuja, C., y Morency, L.-P. (2019). Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2):423–443. https://doi.org/10.1109/TPAMI.2018.2798607

Barros, R., Jaramillo, Á., y Schmitt, F. (2015). Lista de las aves de Chile 2014. *La Chiricoca*, 20:79–100.

Bishop, C. M. y Bishop, H. (2024). *Deep Learning: Foundations and Concepts*. Springer, Cham. https://doi.org/10.1007/978-3-031-45468-4

Botella, C., Joly, A., Bonnet, P., Monestiez, P., y Munoz, F. (2018). A deep learning approach to species distribution modelling. En Joly, A., Vrochidis, S., Karatzas, K., Karppinen, A., y Bonnet, P., eds., *Multimedia Tools and Applications for Environmental & Biodiversity Informatics*, pp. 169–199. Springer, Cham. https://doi.org/10.1007/978-3-319-76445-0_10

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32. https://doi.org/10.1023/A:1010933404324

Brown, C. F., Kazmierski, M. R., Pasquarella, V. J., Rucklidge, W. J., Samsikova, M., Zhang, C., Shelhamer, E., Lahera, E., Wiles, O., Ilyushchenko, S., Gorelick, N., Zhang, L. L., Alj, S., Schechter, E., Askay, S., Guinan, O., Moore, R., Boukouvalas, A., y Kohli, P. (2025). AlphaEarth Foundations: An embedding field model for accurate and efficient global mapping from sparse label data. arXiv:2507.22291. https://doi.org/10.48550/arXiv.2507.22291

Cole, E., Van Horn, G., Lange, C., Shepard, A., Leary, P., Perona, P., Loarie, S., y Mac Aodha, O. (2023). Spatial implicit neural representations for global-scale species mapping. En *Proceedings of the 40th International Conference on Machine Learning (ICML)*, vol. 202 de *Proceedings of Machine Learning Research*, pp. 6320–6342. https://proceedings.mlr.press/v202/cole23a.html

Cornell Lab of Ornithology (2025). eBird passes 2 billion bird observations. https://ebird.org/news/ebird-passes-2-billion-bird-observations. Consultado en septiembre de 2026.

Cui, Y., Jia, M., Lin, T.-Y., Song, Y., y Belongie, S. (2019). Class-balanced loss based on effective number of samples. En *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 9268–9277. https://doi.org/10.1109/CVPR.2019.00949

Deneu, B., Servajean, M., Bonnet, P., Botella, C., Munoz, F., y Joly, A. (2021). Convolutional neural networks improve species distribution modelling by capturing the spatial structure of the environment. *PLOS Computational Biology*, 17(4):e1008856. https://doi.org/10.1371/journal.pcbi.1008856

Didan, K. (2021). MODIS/Terra Vegetation Indices 16-Day L3 Global 1km SIN Grid V061 (MOD13A2). NASA EOSDIS Land Processes Distributed Active Archive Center. https://doi.org/10.5067/MODIS/MOD13A2.061

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., y Houlsby, N. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. En *International Conference on Learning Representations (ICLR)*. https://openreview.net/forum?id=YicbFdNTTy

Drusch, M., Del Bello, U., Carlier, S., Colin, O., Fernandez, V., Gascon, F., Hoersch, B., Isola, C., Laberinti, P., Martimort, P., et al. (2012). Sentinel-2: ESA's optical high-resolution mission for GMES operational services. *Remote Sensing of Environment*, 120:25–36. https://doi.org/10.1016/j.rse.2011.11.026

Efron, B. y Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall, New York.

Elith, J. y Leathwick, J. R. (2009). Species distribution models: Ecological explanation and prediction across space and time. *Annual Review of Ecology, Evolution, and Systematics*, 40:677–697. https://doi.org/10.1146/annurev.ecolsys.110308.120159

Elith, J., Leathwick, J. R., y Hastie, T. (2008). A working guide to boosted regression trees. *Journal of Animal Ecology*, 77(4):802–813. https://doi.org/10.1111/j.1365-2656.2008.01390.x

Elith, J., Phillips, S. J., Hastie, T., Dudík, M., Chee, Y. E., y Yates, C. J. (2011). A

statistical explanation of MaxEnt for ecologists. *Diversity and Distributions*, 17(1):43–57. https://doi.org/10.1111/j.1472-4642.2010.00725.x

Estopinan, J., Servajean, M., Bonnet, P., Munoz, F., y Joly, A. (2022). Deep species distribution modeling from Sentinel-2 image time-series: A global scale analysis on the orchid family. *Frontiers in Plant Science*, 13:839327. https://doi.org/10.3389/fpls.2022.839327

Farr, T. G., Rosen, P. A., Caro, E., Crippen, R., Duren, R., Hensley, S., Kobrick, M., Paller, M., Rodriguez, E., Roth, L., Seal, D., Shaffer, S., Shimada, J., Umland, J., Werner, M., Oskin, M., Burbank, D., y Alsdorf, D. (2007). The Shuttle Radar Topography Mission. *Reviews of Geophysics*, 45(2):RG2004. https://doi.org/10.1029/2005RG000183

Fithian, W. y Hastie, T. (2013). Finite-sample equivalence in statistical models for presence-only data. *The Annals of Applied Statistics*, 7(4):1917–1939. https://doi.org/10.1214/13-AOAS667

Fraixedas, S., Lindén, A., Piha, M., Cabeza, M., Gregory, R., y Lehikoinen, A. (2020). A state-of-the-art review on birds as indicators of biodiversity: Advances, challenges, and future directions. *Ecological Indicators*, 118:106728. https://doi.org/10.1016/j.ecolind.2020.106728

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232. https://doi.org/10.1214/aos/1013203451

Funosas, D., Sebastián-González, E., Morant, J., Marín Gómez, O. H., Mendoza, I., Mohedano-Muñoz, M. A., et al. (2026). A global assessment of BirdNET performance: Differences among continents, biomes, and species. *Ecological Indicators*, 182:114550. https://doi.org/10.1016/j.ecolind.2025.114550

Gemmeke, J. F., Ellis, D. P. W., Freedman, D., Jansen, A., Lawrence, W., Moore, R. C., Plakal, M., y Ritter, M. (2017). Audio Set: An ontology and human-labeled dataset for audio events. En *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 776–780. https://doi.org/10.1109/ICASSP.2017.7952261

Ghani, B., Denton, T., Kahl, S., y Klinck, H. (2023). Global birdsong embeddings enable superior transfer learning for bioacoustic classification. *Scientific Reports*, 13:22876. https://doi.org/10.1038/s41598-023-49989-z

Gong, Y., Chung, Y.-A., y Glass, J. (2021). AST: Audio Spectrogram Transformer. En

Proceedings of Interspeech 2021, pp. 571–575. https://doi.org/10.21437/Interspeech.2021-698

Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., y Moore, R. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, 202:18–27. https://doi.org/10.1016/j.rse.2017.06.031

Grinsztajn, L., Oyallon, E., y Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? En *Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track*. https://arxiv.org/abs/2207.08815

Guisan, A., Thuiller, W., y Zimmermann, N. E. (2017). *Habitat Suitability and Distribution Models: With Applications in R*. Cambridge University Press, Cambridge. https://doi.org/10.1017/9781139028271

Hamer, J., Triantafillou, E., van Merriënboer, B., Kahl, S., Klinck, H., Denton, T., y Dumoulin, V. (2023). BIRB: A generalization benchmark for information retrieval in bioacoustics. arXiv:2312.07439. https://doi.org/10.48550/arXiv.2312.07439

Hanley, J. A. y McNeil, B. J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1):29–36. https://doi.org/10.1148/radiology.143.1.7063747

He, K., Zhang, X., Ren, S., y Sun, J. (2016). Deep residual learning for image recognition. En *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778. https://doi.org/10.1109/CVPR.2016.90

Hersbach, H., Bell, B., Berrisford, P., Hirahara, S., Horányi, A., Muñoz-Sabater, J., Nicolas, J., Peubey, C., Radu, R., Schepers, D., et al. (2020). The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 146(730):1999–2049. https://doi.org/10.1002/qj.3803

Hijmans, R. J., Cameron, S. E., Parra, J. L., Jones, P. G., y Jarvis, A. (2005). Very high resolution interpolated climate surfaces for global land areas. *International Journal of Climatology*, 25(15):1965–1978. https://doi.org/10.1002/joc.1276

Huang, G., Sun, Y., Liu, Z., Sedra, D., y Weinberger, K. Q. (2016). Deep networks with stochastic depth. En *Computer Vision – ECCV 2016*, pp. 646–661. https://doi.org/10.1007/978-3-319-46493-0_39

Huang, S.-C., Pareek, A., Seyyedi, S., Banerjee, I., y Lungren, M. P. (2020). Fusion of medical imaging and electronic health records using deep learning: A systematic review and implementation guidelines. *npj Digital Medicine*, 3:136. https://doi.org/10.1038/s41746-020-00341-z

iNaturalist contributors (2026). iNaturalist Research-grade Observations. Occurrence dataset, iNaturalist.org, accedido vía GBIF.org. https://doi.org/10.15468/ab3s5x

IPBES (2019). Global assessment report on biodiversity and ecosystem services of the Intergovernmental Science-Policy Platform on Biodiversity and Ecosystem Services. Informe técnico, IPBES Secretariat, Bonn, Alemania. E. S. Brondizio, J. Settele, S. Díaz y H. T. Ngo (eds.). https://doi.org/10.5281/zenodo.3831673

Johnston, A., Hochachka, W. M., Strimas-Mackey, M. E., Ruiz Gutierrez, V., Robinson, O. J., Miller, E. T., Auer, T., Kelling, S. T., y Fink, D. (2021). Analytical guidelines to increase the value of community science data: An example using eBird data to estimate species distributions. *Diversity and Distributions*, 27(7):1265–1277. https://doi.org/10.1111/ddi.13271

Kahl, S., Denton, T., Klinck, H., Reers, H., Cherutich, F., Glotin, H., Goëau, H., Vellinga, W.-P., Planqué, R., y Joly, A. (2023). Overview of BirdCLEF 2023: Automated bird species identification in Eastern Africa. En *Working Notes of CLEF 2023 – Conference and Labs of the Evaluation Forum*, vol. 3497 de *CEUR Workshop Proceedings*. https://ceur-ws.org/Vol-3497/

Kahl, S., Wood, C. M., Eibl, M., y Klinck, H. (2021). BirdNET: A deep learning solution for avian diversity monitoring. *Ecological Informatics*, 61:101236. https://doi.org/10.1016/j.ecoinf.2021.101236

Levatich, T. y Ligocki, S. (2026). EOD – eBird Observation Dataset. Occurrence dataset, Cornell Lab of Ornithology, accedido vía GBIF.org. https://doi.org/10.15468/aomfnb

Lin, T.-Y., Goyal, P., Girshick, R., He, K., y Dollár, P. (2017). Focal loss for dense object detection. En *IEEE International Conference on Computer Vision (ICCV)*, pp. 2980–2988. https://doi.org/10.1109/ICCV.2017.324

Lobo, J. M., Jiménez-Valverde, A., y Real, R. (2008). AUC: A misleading measure of the performance of predictive distribution models. *Global Ecology and Biogeography*, 17(2):145–151. https://doi.org/10.1111/j.1466-8238.2007.00358.x

Loshchilov, I. y Hutter, F. (2019). Decoupled weight decay regularization. En *International Conference on Learning Representations (ICLR)*. https://openreview.net/forum?id=Bkg6RiCqY7

Medrano, F., Barros, R., Norambuena, H. V., Matus, R., y Schmitt, F., eds. (2018). *Atlas de las Aves Nidificantes de Chile*. Red de Observadores de Aves y Vida Silvestre de Chile (ROC), Santiago, Chile.

Ministerio del Medio Ambiente (2021). Reporte del Estado del Medio Ambiente 2021. Capítulo 7: Biodiversidad. Informe técnico, Sistema Nacional de Información Ambiental (SINIA), Ministerio del Medio Ambiente, Santiago, Chile. https://sinia.mma.gob.cl/wp-content/uploads/2022/01/C7-biodiversidad-rema-2021.pdf

Ministerio del Medio Ambiente (2022). Estrategia Nacional de Conservación de Aves 2021–2030. Informe técnico, Ministerio del Medio Ambiente – ONU Medio Ambiente, Proyecto GEF Humedales Costeros, Santiago, Chile. Elaborada por T. A. Altamirano. 98 p. https://estrategia-aves.mma.gob.cl

Ministerio del Medio Ambiente (2026). Listado de especies clasificadas según estado de conservación, actualizado a marzo de 2026 (incluye hasta el 20.º proceso del RCE). https://clasificacionespecies.mma.gob.cl. Planilla oficial con hojas “Especies” y “Estadísticas”. Consultada en septiembre de 2026.

Müller, M. (2021). *Fundamentals of Music Processing: Using Python and Jupyter Notebooks*. Springer, Cham, 2.ª ed. https://doi.org/10.1007/978-3-030-69808-9

Myers, N., Mittermeier, R. A., Mittermeier, C. G., da Fonseca, G. A. B., y Kent, J. (2000). Biodiversity hotspots for conservation priorities. *Nature*, 403:853–858. https://doi.org/10.1038/35002501

O’Shaughnessy, D. (1987). *Speech Communication: Human and Machine*. Addison-Wesley, Reading, MA.

Park, D. S., Chan, W., Zhang, Y., Chiu, C.-C., Zoph, B., Cubuk, E. D., y Le, Q. V. (2019). SpecAugment: A simple data augmentation method for automatic speech recognition. En *Proceedings of Interspeech 2019*, pp. 2613–2617. https://doi.org/10.21437/Interspeech.2019-2680

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., et al. (2019). PyTorch: An imperative style, high-

performance deep learning library. En *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, pp. 8024–8035. https://proceedings.neurips.cc/paper/2019/hash/bdbca288fee7f92f2bfa9f7012727740-Abstract.html

Pérez-Granados, C. (2023). BirdNET: Applications, performance, pitfalls and future opportunities. *Ibis*, 165(3):1068–1075. https://doi.org/10.1111/ibi.13193

Phillips, S. J., Anderson, R. P., y Schapire, R. E. (2006). Maximum entropy modeling of species geographic distributions. *Ecological Modelling*, 190(3–4):231–259. https://doi.org/10.1016/j.ecolmodel.2005.03.026

Phillips, S. J., Dudík, M., Elith, J., Graham, C. H., Lehmann, A., Leathwick, J., y Ferrier, S. (2009). Sample selection bias and presence-only distribution models: Implications for background and pseudo-absence data. *Ecological Applications*, 19(1):181–197. https://doi.org/10.1890/07-2153.1

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., y Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8):913–929. https://doi.org/10.1111/ecog.02881

Sullivan, B. L., Aycrigg, J. L., Barry, J. H., Bonney, R. E., Bruns, N., Cooper, C. B., Damoulas, T., Dhondt, A. A., Dietterich, T., Farnsworth, A., Fink, D., Fitzpatrick, J. W., Fredericks, T., Gerbracht, J., Gomes, C., Hochachka, W. M., Iliff, M. J., Lagoze, C., La Sorte, F. A., Merrifield, M., Morris, W., Phillips, T. B., Reynolds, M., Rodewald, A. D., Rosenberg, K. V., Trautmann, N. M., Wiggins, A., Winkler, D. W., Wong, W.-K., Wood, C. L., Yu, J., y Kelling, S. (2014). The eBird enterprise: An integrated approach to development and application of citizen science. *Biological Conservation*, 169:31–40. https://doi.org/10.1016/j.biocon.2013.11.003

Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., y Wojna, Z. (2016). Rethinking the Inception architecture for computer vision. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2818–2826. https://doi.org/10.1109/CVPR.2016.308

Tan, M. y Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. En *Proceedings of the 36th International Conference on Machine*

Learning (ICML), vol. 97 de *Proceedings of Machine Learning Research*, pp. 6105–6114. https://proceedings.mlr.press/v97/tan19a.html

Teng, M., Elmustafa, A., Akera, B., Bengio, Y., Radi, H., Larochelle, H., y Rolnick, D. (2024). SatBird: A dataset for bird species distribution modeling using remote sensing and citizen science data. En *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36. https://arxiv.org/abs/2311.00936

Tucker, C. J. (1979). Red and photographic infrared linear combinations for monitoring vegetation. *Remote Sensing of Environment*, 8(2):127–150. https://doi.org/10.1016/0034-4257(79)90013-0

Valavi, R., Elith, J., Lahoz-Monfort, J. J., y Guillera-Arroita, G. (2019). blockCV: An R package for generating spatially or environmentally separated folds for *k*-fold cross-validation of species distribution models. *Methods in Ecology and Evolution*, 10(2):225–232. https://doi.org/10.1111/2041-210X.13107

Valavi, R., Guillera-Arroita, G., Lahoz-Monfort, J. J., y Elith, J. (2022). Predictive performance of presence-only species distribution models: A benchmark study with reproducible code. *Ecological Monographs*, 92(1):e01486. https://doi.org/10.1002/ecm.1486

Van Horn, G., Mac Aodha, O., Song, Y., Cui, Y., Sun, C., Shepard, A., Adam, H., Perona, P., y Belongie, S. (2018). The iNaturalist species classification and detection dataset. En *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 8769–8778. https://doi.org/10.1109/CVPR.2018.00914

Van Horn, G., Qian, R., Wilber, K., Adam, H., Mac Aodha, O., y Belongie, S. (2022). Exploring fine-grained audiovisual categorization with the SSW60 dataset. En *European Conference on Computer Vision (ECCV)*, vol. 13668 de *Lecture Notes in Computer Science*, pp. 271–289. https://doi.org/10.1007/978-3-031-20074-8_16

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., y Polosukhin, I. (2017). Attention is all you need. En *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30. https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html

Vellinga, W.-P. y Planqué, R. (2015). The Xeno-canto collection and its relation to sound recognition and classification. En *Working Notes of CLEF 2015 – Conference and Labs of the Evaluation Forum*, vol. 1391 de *CEUR Workshop Proceedings*. https:

//ceur-ws.org/Vol-1391/166-CR.pdf

Virtanen, T., Plumbley, M. D., y Ellis, D., eds. (2018). *Computational Analysis of Sound Scenes and Events*. Springer, Cham. https://doi.org/10.1007/978-3-319-63450-0

Wah, C., Branson, S., Welinder, P., Perona, P., y Belongie, S. (2011). The Caltech-UCSD Birds-200-2011 dataset. Informe técnico CNS-TR-2011-001, California Institute of Technology. https://www.vision.caltech.edu/datasets/cub_200_2011/

Wei, X.-S., Song, Y.-Z., Mac Aodha, O., Wu, J., Peng, Y., Tang, J., Yang, J., y Belongie, S. (2022). Fine-grained image analysis with deep learning: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(12):8927–8948. https://doi.org/10.1109/TPAMI.2021.3126648

Zanaga, D., Van De Kerchove, R., De Keersmaecker, W., Souverijns, N., Brockmann, C., Quast, R., Wevers, J., Grosu, A., Paccini, A., Vergnaud, S., Cartus, O., Santoro, M., Fritz, S., Georgieva, I., Lesiv, M., Carter, S., Herold, M., Li, L., Tsendbazar, N.-E., Ramoino, F., y Arino, O. (2021). ESA WorldCover 10 m 2020 v100. Zenodo. https://doi.org/10.5281/zenodo.5571936

Zhang, H., Cissé, M., Dauphin, Y. N., y Lopez-Paz, D. (2018). mixup: Beyond empirical risk minimization. En *International Conference on Learning Representations (ICLR)*. https://openreview.net/forum?id=r1Ddp1-Rb

A Conjunto de especies objetivo

La Tabla A.1 lista las 55 especies del conjunto objetivo con su categoría vigente en el Reglamento de Clasificación de Especies (Ministerio del Medio Ambiente, 2026), su condición de endémica, el grupo al que pertenecen dentro del diseño del corpus y la disponibilidad de datos según el censo de metadatos realizado en Xeno-canto y GBIF. "NE" indica que la especie no ha sido evaluada por el RCE. La columna "XC Chile" es la que define el corpus de audio de este trabajo; "XC global" se reporta solo para las especies de interés de conservación, para las que se relevó la disponibilidad fuera del país.

Tabla A.1: Conjunto objetivo de 55 especies y disponibilidad de datos.

Nombre científico	Nombre común	RCE	Endémica	Grupo	XC Chile	XC global	Fotos GBIF
Laterallus jamaicensis	pidencito	EN	No	Amenazada	34	181	42
Conirostrum tamarugense	comesebo de los tamarugales	EN	No	Amenazada	22	23	38
Chloephaga melanoptera	piuquén	EN	No	Amenazada	17	55	421
Rallus antarcticus	pidén austral	VU	No	Amenazada	16	22	24
Chloephaga picta	caiquén	VU	No	Amenazada	14	38	991
Cyanoliseus patagonus	tricahue	EN	No	Amenazada	14	55	414
Recurvirostra andina	caití	VU	No	Amenazada	6	32	130
Limosa haemastica	zarapito de pico recto	VU	No	Amenazada	4	31	261
Agriornis albicauda	mero de la puna	VU	No	Amenazada	2	23	5
Anous stolidus	gaviotín de San Félix	VU	No	Amenazada	0	41	11
Calidris canutus	playero ártico	EN	No	Amenazada	0	311	21
Charadrius nivosus	chorlo nevado	VU	No	Amenazada	0	39	2
Podiceps gallardoi	pimpollo tobiano	CR	No	Amenazada	0	40	0
Pteroptochos megapodius	turca	NE	Sí	Endémica	86		
Scelorchilus albicollis	tapaculo	NE	Sí	Endémica	65		
Mimus thenca	tenca	NE	Sí	Endémica	48		
Scytalopus fuscus	churrín del norte	NE	Sí	Endémica	46		
Pteroptochos castaneus	hued-hued castaño	NE	Sí	Endémica	41		
Enicognathus leptorhynchus	choroy	LC	Sí	Endémica	35	35	258
Ochetorhynchus melanurus	chiricoca	NE	Sí	Endémica	34		
Turdus falcklandii	zorzal	NE	No	Común	186		
Aphrastura spinicauda	rayadito	NE	No	Común	105		
Troglodytes aedon	chercán	NE	No	Común	102		
Zonotrichia capensis	chincol	NE	No	Común	92		
Scelorchilus rubecula	chucao	LC	No	Común	92		
Curaeus curaeus	tordo	NE	No	Común	88		
Elaenia chilensis	fío-fío	NE	No	Común	85		
Eugralla paradoxa	churrín de la Mocha	NE	No	Común	84		
Scytalopus magellanicus	churrín del sur	NE	No	Común	75		
Leptasthenura aegithaloides	tijeral	NE	No	Común	68		

Tabla A.1 (continuación)

Nombre científico	Nombre común	RCE	Endémica	Grupo	XC Chile	XC global	Fotos GBIF
Sephanoides sephaniodes	picaflor chico	NE	No	Común	67		
Pseudasthenes humicola	canastero	NE	No	Común	67		
Anairetes parulus	cachudito	NE	No	Común	56		
Sylviorthorhynchus desmurii	colilarga	NE	No	Común	55		
Glaucidium nana	chuncho	NE	No	Común	54		
Spinus barbatus	jilguero	NE	No	Común	54		
Pteroptochos tarnii	hued-hued del sur	LC	No	Común	52		
Phrygilus patagonicus	cometocino patagónico	NE	No	Común	51		
Phrygilus gayi	cometocino de Gay	NE	No	Común	46		
Pardirallus sanguinolentus	pidén	NE	No	Común	45		
Vanellus chilensis	queltehue	NE	No	Común	45		
Geositta rufipennis	minero cordillerano	NE	No	Común	44		
Anthus correndera	bailarín chico	NE	No	Común	43		
Veniliornis lignarius	carpinterito	NE	No	Común	42		
Leistes loyca	loica	NE	No	Común	41		
Diuca diuca	diuca	NE	No	Común	41		
Strix rufipes	concón	NT	No	Común	39		
Rhopospina fruticeti	yal	NE	No	Común	38		
Pygarrhichas albogularis	comesebo grande	NE	No	Común	38		
Sicalis luteola	chirihue	NE	No	Común	38		
Pyrope pyrope	diucón	NE	No	Común	37		
Cinclodes fuscus	churrete acanelado	NE	No	Común	36		
Cinclodes patagonicus	churrete	NE	No	Común	33		
Colorhamphus parvirostris	viudita	NE	No	Común	32		
Tachycineta leucopyga	golondrina chilena	NE	No	Común	32		

B Hiperparámetros y detalles de entrenamiento

Las tablas siguientes recogen la configuración exacta de cada modelo, tal como quedó en el archivo de configuración del repositorio y en los *scripts* de entrenamiento. Todos los entrenamientos se ejecutaron en un Mac con procesador Apple M4 Pro (GPU mediante Metal/MPS), con semilla 42 y selección del mejor *checkpoint* por F1 macro en validación.

Tabla B.1: Clasificadores de audio.

	EfficientNet-B0 (CNN)	AST
Preentrenamiento	ImageNet (timm: `efficientnet_b0.ra_in1k`)	AudioSet (`MIT/ast-finetuned-audioset-10-10-0.4593`)
Entrada	ventana de 5 s a 32 kHz; log-mel de 128 bandas, $N_{\text{FFT}} = 1024$, salto de 320 muestras (100 cuadros/s), normalizada por ventana	ventana de 10 s remuestreada a 16 kHz; banco de filtros de 128 bandas $\times$ 1024 cuadros con la normalización de AudioSet
Ventana en entrenamiento / evaluación	aleatoria / central y agregado de hasta 12	aleatoria / central y agregado de hasta 8
Aumentación	ganancia ± 6 dB, ruido gaussiano (p = 0,5), SpecAugment (2$\times$ máscaras de 24 bandas y 48 cuadros), *mixup* $\alpha =$ 0,2	ninguna
Pérdida	entropía cruzada con pesos $1/n_k$ normalizados y suavizado 0,1	ídem
Regularización	*dropout* 0,3; profundidad estocástica 0,2; *weight decay* 0,01	*weight decay* 0,01
Optimizador	AdamW, lr 10^{-3}, coseno	AdamW, lr 2×10^{-5}, coseno
Lote / épocas	32 / 100 (mejor: 67)	8 / 20 (mejor: 11)
Parámetros	4,1 M	86,2 M
Tiempo por época	22 s	$\approx$ 480 s
Corrida de control sin regularizar	misma receta sin aumentación, *mixup* 0, suavizado 0, *dropout* 0 y profundidad estocástica 0; 100 épocas (mejor: 45)	–

Tabla B.2: Clasificador de imagen y cabezas de fusión.

Elemento	Configuración
Backbone	EfficientNet-B3 preentrenada en ImageNet (`efficientnet_b3.ra2_in1k`); variante NoisyStudent (`tf_efficientnet_b3.ns_jft_in1k`)
Entrada	384 px; entrenamiento: `RandomResizedCrop` (escala 0,7–1,0), volteo horizontal, variación de color 0,2; evaluación: redimensión a 441 px y recorte central; TTA de diez recortes
Pérdida y regularización	entropía cruzada con suavizado 0,1; *mixup* $\alpha = 0{,}2$; *dropout* 0,3; profundidad estocástica 0,2; *weight decay* 0,01
Optimizador	AdamW, lr 5×10^{-4}, coseno; lote 32; 50 épocas (mejor: 38)
Parámetros / tiempo	10,8 M; 250–500 s por época
ViT-S/16 (comparación)	`vit_small_patch16_224. augreg_in21k_ft_in1k`; entrada de 224 px (redimensión a 257 px y recorte); misma pérdida, regularización y aumentación; AdamW, lr 10^{-4}, coseno; mismo lote; 30 épocas (mejor: 30); 21,7 M; ≈ 100 s por época
Late fusion (sistema)	$\alpha = 0{,}5$ sobre los *softmax*; imagen proyectada de 53 a 55 clases
Cabezas de fusión (comparación)	*frozen embeddings* de 1 280 (audio, media de 12 ventanas) y 1 536 (imagen) dimensiones, estandarizados; *late fusion*: una capa lineal por modalidad; *early fusion*: concatenación $\rightarrow$ 256 $\rightarrow$ clases; *intermediate fusion*: proyección de cada modalidad a 256 $\rightarrow$ concatenación $\rightarrow$ 256 $\rightarrow$ clases; *dropout* 0,3; AdamW lr 10^{-3}, lote 64, 40 épocas; 150 pares de entrenamiento y 30 de prueba por especie

Tabla B.3: Modelos de distribución de especies.

Elemento	Configuración
Datos por especie	presencias (hasta 500) frente a 1500 puntos de fondo de grupo objetivo muestreados con semilla 42; especies con al menos 20 presencias (54)
Covariables	NDVI, temperatura media anual, precipitación anual, elevación, seno y coseno del mes; estandarizadas para MaxEnt y la red
Partición	estratificada 70/30 (comparación principal); bloques espaciales de 200 km en 5 *folds* (validación espacial)
MaxEnt	regresión logística con características de grado 2, clases balanceadas, penalización L2 (C = 1), 1000 iteraciones
Random Forest	300 árboles, clases balanceadas, resto por defecto de `scikit-learn`
Gradient boosting	`HistGradientBoosting`, 300 iteraciones, tasa 0,05, clases balanceadas
Red neuronal conjunta	*embedding* de especie de 8 dimensiones; capas de 64 y 64 unidades con ReLU y *dropout* 0,3; entropía cruzada binaria con peso positivo; AdamW lr 10^{-3}, *weight decay* 0,01; lote 512; 40 épocas
Experimentos satelitales	parches de cobertura de suelo (ESA WorldCover, 3 km) con CNN pequeña; *embedding* satelital anual de 64 dimensiones (Google AlphaEarth) fijo (2023) y pareado al año de observación (2017–2025)

Tabla B.4: *Baselines* de referencia de la identificación de especies.

Elemento	Configuración
Frozen embeddings	EfficientNet-B0 de ImageNet (`efficientnet_b0`, un canal de entrada, *pooling* global, 1 280 dimensiones; promedio de hasta 8 ventanas de 5 s); AST de AudioSet (salida *pooler*, 768 dimensiones; promedio de hasta 4 ventanas de 10 s); EfficientNet-B3 de ImageNet (1 536 dimensiones, recorte central de 384 px). Ningún peso se ajusta.
Clasificador lineal	estandarización con la media y la varianza del conjunto de entrenamiento; regresión logística multinomial con clases balanceadas y hasta 3 000 iteraciones; C elegido por F1 macro en validación entre $\{0{,}01; 0{,}1; 1; 10\}$ (resultó 1 para la CNN de audio, 0,1 para el AST y 0,01 para la imagen)
IA generativa	`claude-opus-5-5` vía API; instrucción de sistema con la lista cerrada de 53 especies (nombre científico y común) y la fotografía de prueba a tamaño original; esfuerzo de razonamiento `low`; temperatura por defecto (1,0); hasta 4 096 tokens de salida; respuesta en JSON con esquema que restringe la especie a la lista y pide una confianza en $[0, 1]$
Zero-shot / *few-shot*	*zero-shot*: solo la fotografía de prueba (4 respuestas inválidas de 1 040, contadas como errores); *few-shot*: una fotografía de referencia por especie (lado mayor reducido a 320 px) en un primer turno compartido y almacenado en la caché de *prompts*, seguido de la fotografía de prueba. Costo: US$2,19 y US$4,27 por las 1 040 fotografías; latencia mediana 2,4 y 2,7 s

C Métricas por especie

Tabla C.1: Métricas por especie en los conjuntos de prueba: F1 del clasificador de audio (CNN EfficientNet-B0 y AST, agregado por grabación), F1 del clasificador de imagen (EfficientNet-B3 con TTA) y AUC-ROC del modelo de distribución (MaxEnt y Random Forest, partición aleatoria). "–" indica que la especie no participa de ese modelo.

Especie	Grupo	n_{test}	F1 audio (CNN)	F1 audio (AST)	n_{test}	F1 imagen	n_{pres}	AUC MaxEnt	AUC RF
A. albicauda	Amenazada	3	0,500	0,400	2	0,000	206	0,983	0,991
A. stolidus	Amenazada	6	0,923	0,909	22	0,955	–	–	–
C. canutus	Amenazada	8	0,875	0,824	22	0,889	437	0,944	0,974
C. nivosus	Amenazada	6	0,800	0,727	–	–	52	0,901	0,864
C. melanoptera	Amenazada	8	1,000	0,933	22	0,870	500	0,946	0,980
C. picta	Amenazada	5	0,769	0,889	22	0,884	437	0,949	0,955
C. tamarugense	Amenazada	3	1,000	1,000	3	0,444	500	0,978	0,985
C. patagonus	Amenazada	8	1,000	1,000	22	0,870	500	0,931	0,974
L. jamaicensis	Amenazada	8	1,000	0,941	10	0,741	500	0,906	0,959
L. haemastica	Amenazada	5	0,909	0,833	22	0,884	445	0,871	0,943
P. gallardoi	Amenazada	5	1,000	1,000	17	0,824	90	0,986	0,995
R. antarcticus	Amenazada	3	1,000	0,800	–	–	471	0,994	0,997
R. andina	Amenazada	4	1,000	1,000	22	0,952	500	0,981	0,983
E. leptorhynchus	Endémica	5	1,000	0,833	22	0,818	494	0,925	0,927
M. thenca	Endémica	8	0,824	0,800	22	0,789	492	0,761	0,800
O. melanurus	Endémica	5	0,667	0,727	17	0,944	500	0,946	0,949
P. castaneus	Endémica	6	0,923	1,000	6	0,727	497	0,960	0,969
P. megapodius	Endémica	8	0,933	1,000	22	0,884	491	0,898	0,900
S. albicollis	Endémica	8	0,800	1,000	22	0,900	500	0,885	0,938
S. fuscus	Endémica	6	0,909	0,909	5	0,000	496	0,916	0,935
A. parulus	Común	8	1,000	0,889	22	0,837	489	0,799	0,797
A. correndera	Común	8	0,933	0,933	22	0,884	496	0,821	0,896
A. spinicauda	Común	8	0,824	0,857	22	0,844	491	0,798	0,812
C. fuscus	Común	8	0,933	0,824	22	0,810	479	0,847	0,855
C. patagonicus	Común	8	0,462	0,500	22	0,898	445	0,815	0,840
C. parvirostris	Común	6	1,000	0,923	22	0,957	494	0,909	0,912
C. curaeus	Común	8	0,800	0,769	22	0,837	497	0,752	0,801
D. diuca	Común	8	0,889	0,800	22	0,739	495	0,809	0,830
E. chilensis	Común	8	0,875	0,889	22	0,810	489	0,830	0,822
E. paradoxa	Común	8	1,000	0,941	5	0,800	488	0,905	0,921
G. rufipennis	Común	8	0,824	0,889	22	0,898	500	0,931	0,948
G. nana	Común	8	0,941	1,000	22	0,783	493	0,748	0,798
L. loyca	Común	8	0,875	0,889	22	0,933	486	0,769	0,814
L. aegithaloides	Común	8	0,625	0,824	22	0,727	492	0,822	0,826
P. sanguinolentus	Común	8	0,857	0,933	22	0,952	491	0,873	0,904
P. gayi	Común	8	0,615	0,500	22	0,750	489	0,848	0,867
P. patagonicus	Común	8	0,762	0,778	22	0,783	465	0,865	0,894
P. humicola	Común	8	0,778	0,941	22	0,850	486	0,874	0,869

Tabla C.1 (continuación)

Especie	Grupo	n_{test}	F1 audio (CNN)	F1 audio (AST)	n_{test}	F1 imagen	n_{pres}	AUC MaxEnt	AUC RF
P. tarnii	Común	8	1,000	1,000	22	0,818	495	0,894	0,913
P. albogularis	Común	8	0,857	0,857	22	0,791	497	0,864	0,886
P. pyrope	Común	7	0,667	0,923	22	0,800	488	0,697	0,761
R. fruticeti	Común	8	0,800	0,875	22	0,837	493	0,889	0,906
S. rubecula	Común	8	1,000	0,933	22	0,936	484	0,926	0,919
S. magellanicus	Común	8	0,941	0,933	19	0,850	487	0,859	0,854
S. sephaniodes	Común	8	0,889	0,889	22	0,829	484	0,802	0,809
S. luteola	Común	8	0,941	0,769	22	0,857	483	0,849	0,859
S. barbatus	Común	8	0,714	0,824	22	0,913	487	0,781	0,806
S. rufipes	Común	8	1,000	1,000	18	0,850	493	0,863	0,894
S. desmurii	Común	8	0,615	0,842	14	0,786	497	0,854	0,872
T. leucopyga	Común	6	1,000	1,000	22	0,875	474	0,816	0,805
T. aedon	Común	8	0,933	0,941	22	0,889	499	0,905	0,954
T. falcklandii	Común	8	0,800	0,750	22	0,913	488	0,759	0,824
V. chilensis	Común	8	0,750	0,933	22	0,821	466	0,725	0,795
V. lignarius	Común	8	0,800	0,769	22	0,783	494	0,798	0,791
Z. capensis	Común	8	0,632	0,667	22	0,837	485	0,649	0,669
Media			**0,858**	**0,864**		**0,808**		**0,863**	**0,884**